

Universidad Nacional de Colombia

Departamento de Estadística

Riesgo municipal de lavado de activos y financiación del terrorismo

Estadística Bayesiana
Prof. Juan Camilo Sosa Martínez

Presentado por:

M. Paula Arévalo F.
Álvaro A. García G.

27 de julio de 2026

Contenido

Abreviaturas y símbolos IV

1. Contextualización del problema **2**
1.1. Planteamiento del problema y objetivos . . . 3
1.2. Justificación . . . 4

2. Análisis exploratorio descriptivo **5**
2.1. Puntajes temáticos estructurales . . . 5
2.2. Indicadores observados de fenómenos asociados al riesgo de LAFT . . . 11

3. Especificación de los modelos **14**
3.1. Modelo Latente de Riesgo LAFT . . . 14
3.2. Modelo Latente de Riesgo LAFT con Efectos Departamentales . . . 19
3.3. Modelo Latente de Riesgo LAFT con Efectos Espaciales Departamentales . . . 20
3.4. Resumen de los modelos . . . 22

4. Implementación y diagnóstico de los modelos **24**
4.1. Elección de los hiperparámetros . . . 24
4.2. Convergencia . . . 25
4.3. Tamaños efectivos de muestra . . . 25
4.4. Criterio de información de la devianza (DIC) . . . 26
4.5. Criterio de información de Watanabe-Akaike (WAIC) . . . 27
4.6. Desempeño predictivo . . . 28

5. Inferencia **30**
5.1. Inferencia usando el Modelo MLR-LAFT-EED . . . 30
5.2. Medias posteriores de los efectos espaciales departamentales . . . 32

6. Clasificación según el riesgo de LAFT **33**
6.1. Nivel promedio posterior del factor latente por departamento . . . 33
6.2. Clasificación departamental mediante terciles . . . 35
6.3. Clasificación municipal mediante terciles . . . 36

7. Conclusiones **37**

8. Limitaciones y posibles extensiones **38**

A. Tasas de aceptación obtenidas **40**

B. Distribuciones involucradas **40**

C. Distribuciones condicionales completas **42**

D. Tratamiento de los datos **50**

Referencias **57**

Abreviaturas y símbolos

ANM	Agencia Nacional de Minería
ART	Agencia de Renovación del Territorio
BO	Banca de las Oportunidades
DAG	Grafo acíclico dirigido (*directed acyclic graph*)
DAICMA	Dirección para la Acción Integral contra Minas Antipersonal
DANE	Departamento Administrativo Nacional de Estadística
DIVIPOLA	División Político-Administrativa del DANE
DNP	Departamento Nacional de Planeación
FATF	Grupo de Acción Financiera Internacional
FGN	Fiscalía General de la Nación
GLM	Modelo lineal generalizado (*generalized linear model*)
ICAR	Modelo autorregresivo condicional intrínseco (*intrinsic conditional autoregressive*)
INMLCF	Instituto Nacional de Medicina Legal y Ciencias Forenses
LAFT	Lavado de activos y financiación del terrorismo
MAE	Error absoluto medio (*mean absolute error*)
MCMC	Algoritmos Monte Carlo de cadena de Márkov (*Markov Chain Monte Carlo*)
MDN	Ministerio de Defensa Nacional
MEN	Ministerio de Educación Nacional
MGN	Marco Geoestadístico Nacional
MJD	Ministerio de Justicia y del Derecho de Colombia
MOE	Misión de Observación Electoral
MSE	Error cuadrático medio (*mean squared error*)
ODC	Observatorio de Drogas de Colombia
PN	Policía Nacional
ROS	Reportes de Operaciones Sospechosas
SARLAFT	Sistema de Administración del Riesgo de Lavado de Activos y de la Financiación del Terrorismo
SEM	Modelo de ecuaciones estructurales (*structural equation model*)
SFC	Superintendencia Financiera de Colombia
SPOA	Sistema Penal Oral Acusatorio
UIAF	Unidad de Información y Análisis Financiero

x, $\mathbf{x}$, $\mathbf{X}$	Escalar, vector y matriz respectivamente (a menos que se indique otra cosa)
$\sum$	Sumatoria
$\prod$	Productoria
ln	Logaritmo natural
exp	Función exponencial natural
logit	Función logit
$\Gamma(\bullet)$	Función gamma
$\mathrm{P}(\bullet)$	Probabilidad
$\mathrm{E}(\bullet)$	Valor esperado
$\sim$	*...se distribuye...* o la relación de vecindad definida en §§3.3
pdf	Función de densidad de probabilidad (*probability density function*)
pmf	Función de masa de probabilidad (*probability mass function*)
$[a = b]$ o $[a > b]$	Corchete de Iverson para la sentencia $a = b$ y $a > b$ respectivamente
$\mid$	Símbolo de probabilidad condicional o *...tal que...* dependiendo del contexto
$\top$	Transpuesta
$\propto$	*...es proporcional a...*
iid	Independientes e idénticamente distribuidas (a veces bajo condicionalidad)
ind	Independientes (a veces bajo condicionalidad)
Bernoulli	Distribución Bernoulli
$\mathrm{U}(a, b)$	Distribución uniforme continua entre a y b
N	Distribución normal
N_k	Distribución normal k-variada
N^+	Distribución normal truncada en $\mathbb{R}^+$
Lognormal	Distribución log-normal
Gamma o G	Distribución Gamma
IG	Distribución Gamma-inversa
ZIGamma	Distribución Gamma cero-inflada (*zero-inflated Gamma*)

1. Contextualización del problema

El lavado de activos y la financiación del terrorismo (LAFT) constituyen dos de las principales amenazas para la estabilidad del sistema financiero, la integridad de los mercados y la seguridad económica de los Estados. La naturaleza clandestina de estas actividades dificulta su detección directa, por lo que las autoridades deben recurrir al análisis de múltiples indicadores económicos, sociales y criminales para identificar territorios con mayor exposición al riesgo. A pesar de los esfuerzos institucionales, el riesgo de LAFT constituye una variable no observable. En la práctica, únicamente se dispone de indicadores indirectos asociados con actividades susceptibles de favorecer estos delitos, por lo que resulta necesario desarrollar metodologías que permitan sintetizar dicha información en una medida latente de riesgo.

El Ministerio de Justicia y del Derecho de Colombia (MJD) define el lavado de activos como 'una actividad criminal que busca ocultar el verdadero origen ilícito de los recursos que obtienen los criminales mediante operaciones financieras y no financieras' (MJD, s.f., párr. 1); es decir, el problema no son los recursos en sí, sino su procedencia. En Colombia, las principales fuentes de este tipo de fondos incluyen la minería ilegal, el tráfico ilícito de estupefacientes y el contrabando. El lavado de activos se puede describir en tres etapas: en la primera se introducen los fondos al sistema financiero, en la segunda, se realizan operaciones cuyo objetivo es alejar los fondos de su origen ilícito, y en la tercera, se convierte ese dinero en fondos aparentemente provenientes de un negocio legal. El lavado de activos representa un peligro importante, no sólo a nivel nacional, sino también internacional, debido a que los fondos obtenidos de fuentes ilegales son, en ocasiones, transferidos de un país a otro, y las organizaciones a cargo de ellos cuentan con instrumentos cada vez más sofisticados, gracias al avance de la tecnología, para ocultar su procedencia.

Asimismo, el financiamiento del terrorismo constituye otra definición relativamente sencilla, la cual implica brindar apoyo financiero a cualquier tipo de terrorismo, incluyendo aquel que aún se encuentra en etapa de planeación. Por otra parte, como señala Schott (2006), es difícil definir el terrorismo, pues tiene implicaciones distintas —incluyendo políticas y religiosas— dependiendo del país en el que se encuentre. Sin embargo, el Grupo de Acción Financiera Internacional (FATF) brinda una definición más específica, según la cual el terrorismo incluye actos que van en contra de ciertos convenios internacionales —desde la toma de rehenes hasta la protección del material nuclear—, además de acciones que afecten grave o mortalmente a personas que no son partícipes activos de un conflicto armado, con el objetivo de intimidar a una población (FATF, 2012).

El lavado de activos (LA) y el financiamiento del terrorismo (FT) siguen una secuencia de pasos similar. El paso inicial del FT consiste en depositar el dinero en el sistema financiero, con la diferencia de que, en este caso, el dinero puede proceder de fuentes legales. El siguiente paso consiste en mover el dinero hasta lograr ocultar su origen, y por último se distribuye a las organizaciones terroristas. Como respuesta a este fenómeno, se han creado distintas organizaciones como el FAFT, un organismo intergubernamental creado en 1989 cuyo objetivo es 'crear y promover políticas para proteger el sistema financiero global contra el lavado de dinero, el financiamiento del terrorismo y la financiación de la proliferación de armas de destrucción en masa' (id., p. 1).

Particularmente, en Colombia, existen distintas entidades de control y regulación en materia de LAFT. La primera de ellas es la Unidad de Información y Análisis Financiero (UIAF), la cual se encarga de dos funciones principales: prevención y detección. La prevención consiste en el desarrollo de normativas que ayuden a gestionar el riesgo de LAFT; y la detección, en la identificación de los grupos criminales y los recursos que generan a partir de actividades ilegales, para lo cual se hace uso de los Reportes de Operaciones Sospechosas (ROS), que son enviados a la UIAF y posteriormente remitidos, junto con el análisis correspondiente, a la Fiscalía General de la Nación (FGN) como criterio orientador. Esta última es la encargada de investigar y tomar las acciones legales pertinentes ante casos materializados.

Continuando con el contexto colombiano, la Superintendencia Financiera de Colombia (SFC) es la

autoridad administrativa encargada de la supervisión del sistema financiero colombiano, con el objetivo de preservar su estabilidad, seguridad y confianza, así como promover el mercado de valores y la protección de inversionistas, ahorradores y asegurados (SFC, 2022, Concepto 2022186729-001). En materia de LAFT, esta entidad ejerce inspección, vigilancia y control sobre las entidades financieras, exigiéndoles administrar este riesgo mediante el Sistema de Administración del Riesgo de LAFT (SARLAFT), el cual incluye instrumentos como los ROS enviados a la UIAF. Además, la normativa de la SFC incorpora los estándares internacionales establecidos en las 40 Recomendaciones del FATF, marco básico para la lucha contra estos delitos. Aunque estas entidades cuentan con diversos mecanismos de monitoreo y prevención, la identificación temprana de territorios con mayor exposición al riesgo continúa siendo un desafío debido a la naturaleza indirecta y multidimensional del fenómeno.

En Colombia, existen marcadas diferencias territoriales en materia de actividades ilícitas, capacidades institucionales, dinámicas económicas y presencia de organizaciones criminales. Estas diferencias sugieren que el riesgo de LAFT difícilmente puede considerarse homogéneo entre municipios y departamentos, lo cual justifica el desarrollo de modelos que incorporen explícitamente la dependencia espacial.

En este contexto, el desarrollo de metodologías estadísticas que integren múltiples indicadores observables en una medida latente de riesgo constituye una herramienta de gran utilidad para apoyar los procesos de vigilancia, priorización y toma de decisiones por parte de las autoridades competentes. Particularmente, los modelos Bayesianos de ecuaciones estructurales (SEM Bayesianos) permiten representar explícitamente la naturaleza no observable del riesgo, mientras que la incorporación de componentes espaciales facilita capturar la dependencia territorial presente entre departamentos vecinos.

1.1. Planteamiento del problema y objetivos

El trabajo original de Muñoz Chamorro (2024) se centra en el desarrollo de un modelo de aprendizaje estadístico para la identificación del LAFT, para lo cual la autora realizó un análisis factorial múltiple y un agrupamiento jerárquico por componentes principales sobre la base de datos consolidada `LAFT.xlsx`. En contraste, el presente trabajo aborda el problema desde una perspectiva de modelación probabilística, incorporando explícitamente una variable latente que representa el riesgo municipal de LAFT y cuya distribución posterior constituye el principal objeto de inferencia.

La principal dificultad radica en que el riesgo de LAFT no constituye una variable directamente observable, por lo que no existe una respuesta predefinida que pueda emplearse como variable dependiente en un modelo de regresión tradicional. Esta característica hace particularmente apropiado el empleo de SEM Bayesianos, los cuales permiten representar explícitamente la naturaleza no observable del riesgo mediante una variable latente relacionada simultáneamente con covariables estructurales e indicadores observados.

El enfoque de este trabajo se centra en estimar la variable latente R_i para cada municipio de Colombia, que represente su riesgo frente al LAFT; y luego, con base en la distribución posterior de R_i, clasificar municipios y departamentos en grupos de riesgo, tales como bajo, medio y alto. En consecuencia, el problema central de esta investigación consiste en desarrollar una metodología que permita cuantificar un fenómeno no observable, explicar su comportamiento mediante variables estructurales, incorporar la dependencia espacial entre territorios y, finalmente, generar una clasificación objetiva del riesgo de LAFT en Colombia.

Específicamente, nuestro objetivo general consiste en desarrollar una medida estadística del riesgo no observable de LAFT mediante tres modelos SEM Bayesianos que permitan estimar, explicar y clasificar el riesgo municipal y departamental en Colombia a partir de una variable latente R_i, modelada estructuralmente por índices temáticos y vinculada mediante un modelo de medición con indicadores observables del fenómeno. Los modelos considerados difieren en la especificación de los efectos residuales, incorporando sucesivamente efectos independientes y dependencia espacial mediante un modelo ICAR.

Los objetivos específicos son:

- ✤ Explicar el riesgo latente R_i mediante covariables estructurales del entorno social, económico, político y territorial, incorporando adicionalmente efectos departamentales independientes y efectos espaciales departamentales bajo un modelo ICAR.
- ✤ Estimar para cada municipio la variable latente R_i que represente su nivel de riesgo de LAFT empleando los tres modelos.
- ✤ Comparar el desempeño inferencial y predictivo de los modelos propuestos mediante criterios Bayesianos de selección de modelos y medidas de capacidad predictiva, con el fin de identificar el modelo más adecuado para describir el riesgo municipal de LAFT.
- ✤ Proponer una clasificación del riesgo municipal y departamental de LAFT en niveles de riesgo (bajo, medio y alto) a partir de la distribución posterior de R_i.

1.2. Justificación

Este trabajo resulta relevante desde el punto de vista institucional, territorial y metodológico. A nivel institucional, los resultados pueden ser de utilidad para entidades como la UIAF y la FGN al ofrecer un criterio cuantitativo que apoye la focalización de esfuerzos de prevención, monitoreo y control. A nivel territorial, la desagregación municipal y departamental permite identificar zonas del país con mayor exposición al riesgo de LAFT, lo cual resulta relevante dada la heterogeneidad regional de fenómenos como el conflicto armado, el narcotráfico y el contrabando en Colombia.

Desde el punto de vista metodológico, esta investigación propone una aproximación Bayesiana al problema de medir un fenómeno que no puede observarse directamente. A diferencia de los enfoques descriptivos o de aprendizaje no supervisado empleados previamente, el riesgo de LAFT se modela explícitamente como una variable latente, permitiendo cuantificar la incertidumbre asociada a su estimación mediante distribuciones posteriores e intervalos de credibilidad. Esta característica proporciona un marco probabilístico para la inferencia y favorece la interpretación de los resultados en términos de riesgo estadístico.

Asimismo, el modelo de medición propuesto constituye una contribución metodológica al incorporar simultáneamente una componente discreta y una componente continua mediante una distribución Gamma cero-inflada (ZIGamma). En este contexto, la variable latente no sólo explica la intensidad del fenómeno a través de la media de la distribución Gamma, sino también la probabilidad de ocurrencia de observaciones nulas mediante la componente Bernoulli, dando lugar a un modelo de doble efecto latente. Esta formulación permite representar adecuadamente indicadores caracterizados por una importante proporción de ceros, situación frecuente en estudios sobre criminalidad y fenómenos socioeconómicos.

Adicionalmente, el trabajo incorpora progresivamente estructuras de complejidad creciente, culminando con un modelo SEM Bayesiano espacial basado en un proceso autorregresivo condicional intrínseco (ICAR), el cual permite representar la dependencia espacial existente entre departamentos vecinos. Esta extensión posibilita distinguir entre variabilidad explicada por covariables estructurales y patrones residuales de naturaleza espacial, proporcionando una representación más realista del riesgo territorial de LAFT.

Desde el punto de vista computacional, la estimación de estos modelos requirió el desarrollo de algoritmos MCMC con múltiples etapas de Metropolis y Metropolis-Hastings dentro de un esquema de Gibbs. A pesar de la elevada complejidad de las distribuciones condicionales completas inducida por la estructura cero-inflada y espacial del modelo, los algoritmos desarrollados presentaron un comportamiento satisfactorio en términos de convergencia, estabilidad numérica y precisión de las estimaciones posteriores, lo cual respalda la viabilidad práctica de la metodología propuesta.

Finalmente, la metodología desarrollada permite estimar el riesgo latente y también evaluar rigurosamente su capacidad predictiva mediante criterios Bayesianos de selección de modelos y medidas de desempeño predictivo, así como generar clasificaciones objetivas del riesgo municipal y departamental. En

consecuencia, el trabajo ofrece una herramienta estadística integral que combina inferencia, predicción y clasificación territorial, susceptible de apoyar procesos de priorización y toma de decisiones en materia de prevención y control del LAFT.

2. Análisis exploratorio descriptivo de los datos observados

Como puede verse con más detalle en el Apéndice D, la base de datos que sirvió como insumo para este estudio resultó, después de la construcción de puntajes temáticos, en un conjunto de 1122 observaciones a lo largo de 8 variables. Sin embargo, la base de datos original de Muñoz Chamorro (2024) cuenta con 55 variables divididas en ocho bloques temáticos.

En esta sección, presentamos un análisis exploratorio descriptivo de los ocho puntajes finales construidos a partir de la base de Muñoz Chamorro, analizando las características más relevantes de los valores observados, así como posibles relaciones entre estos últimos.

2.1. Puntajes temáticos estructurales

El primer grupo de medidas agregadas está conformado por los bloques de contexto estructural, contexto político, contrabando y sector primario y minero, los cuales contienen covariables que reúnen información del contexto socioeconómico de los municipios para explicar el nivel de riesgo municipal frente al LAFT. Estos puntajes son denotados como $\mathbf{x}_i := (x_{i,1}, x_{i,2}, x_{i,3}, x_{i,4})$, donde cada $x_{i,j}$ representa el puntaje de cada bloque temático para el municipio i. Estos puntajes no son interpretados como manifestaciones del riesgo, sino que presentan un contexto que ayuda a entender la materialización del LAFT.

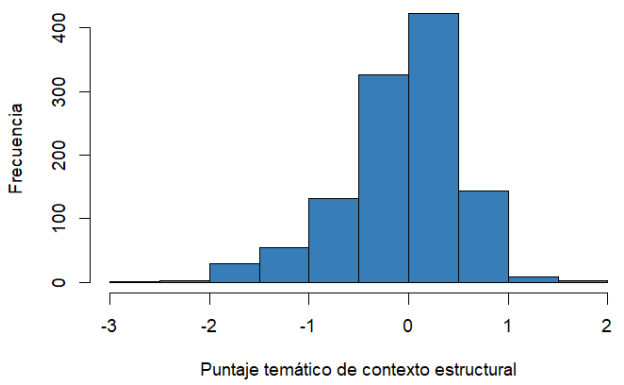
En primer lugar, presentamos a continuación, en la Figura 1, los histogramas de estos puntajes. En el primer histograma, que corresponde al puntaje de contexto estructural, se puede observar una concentración mayor en los puntajes alrededor de 0. Aunque se observa una distribución acampanada, también se ve una ligera asimetría hacia la izquierda; i.e., existe una cola mayor hacia los valores negativos.

El segundo gráfico, que corresponde al puntaje de contexto político, muestra una distribución discreta unimodal en el valor 0.5, donde se registra la mayor frecuencia. En contraste, los demás valores presentan una frecuencia pequeña. Se puede observar que existe asimetría positiva. Es importante recalcar que se observa un único pico muy pronunciado y que la cola hacia la derecha abarca los valores 1.5 y 2.

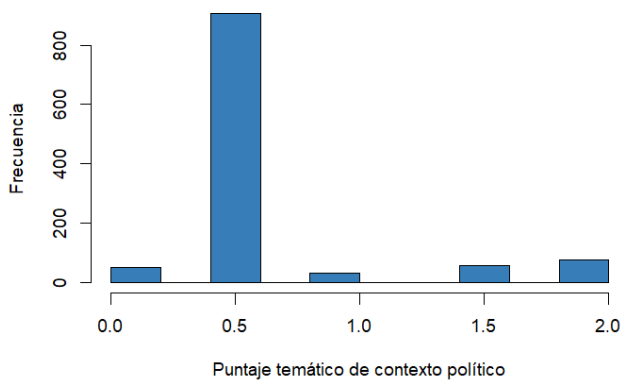
El tercer histograma, que contiene los puntajes de contrabando, deja ver nuevamente una distribución discreta unimodal con una marcada concentración de observaciones en 0. A medida que aumenta el valor del puntaje, disminuye su frecuencia, lo que deja una cola a la derecha que toma los valores 0.25, 0.5, 0.75 y 1.

En la cuarta subfigura se observa el histograma del puntaje de sector primario y minero, concepto ligado a la susceptibilidad de los municipios al lavado de activos, el cual, basados en el gráfico, tiene una distribución acampanada, cercana a la normal, con frecuencias muy altas en valores que van de -1 a 1. Las colas no son muy pronunciadas y no tienen frecuencias muy altas, por lo que se ve una distribución casi simétrica.

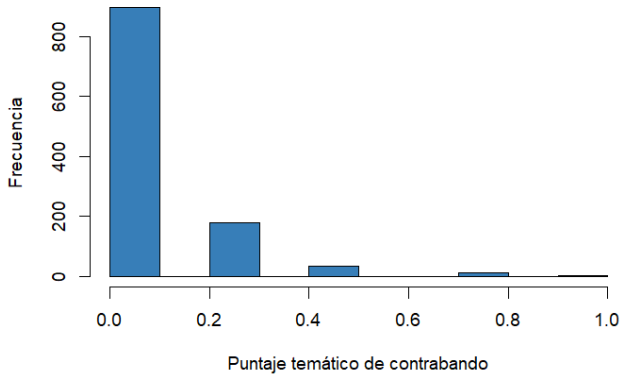
Las gráficas de la Figura 2 son una mezcla entre *violin plot*, *boxplot* y *jitter plot*, y con ellas pretendemos hacer un análisis descriptivo más completo de los bloques pertenecientes al primer grupo de medidas agregadas construidas. En el primer gráfico, que pertenece a contexto estructural, podemos observar, gracias al ancho de la densidad *kernel*, una alta concentración en valores cercanos a 0, lo cual nos confirma lo visto en el histograma de la Figura 1(a). La mediana se ubica en 0.01632, mientras que la media es -0.06915, lo cual nos indica la presencia de datos atípicos en la parte izquierda de los datos que influyen en el valor de la media. El rango intercuartílico indica una dispersión moderada de la mitad central de los datos y se puede observar que la densidad disminuye hacia ambos extremos de las colas, aunque, según el gráfico y lo que indica la media, hay una mayor densidad en la cola izquierda.



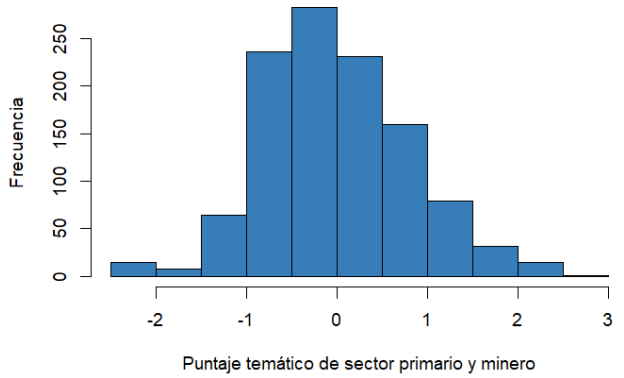
(a) Puntaje temático de contexto estructural $x_{\bullet,1}$.



(b) Puntaje temático de contexto político $x_{\bullet,2}$.



(c) Puntaje temático de contrabando $x_{\bullet,3}$.



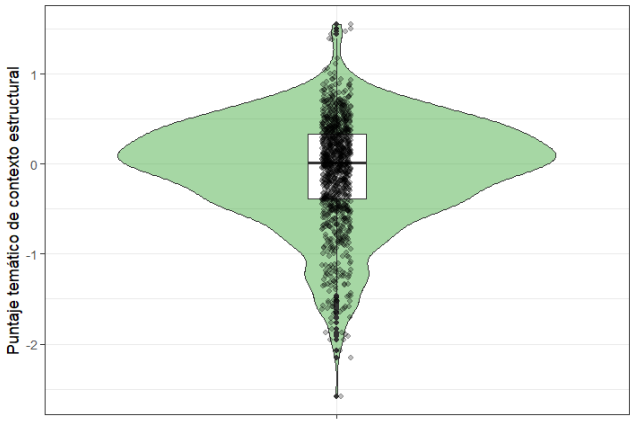
(d) Puntaje temático de sectores susceptibles al lavado de activos $x_{\bullet,4}$.

FIGURA 1. Histogramas de los puntajes temáticos de contexto estructural.

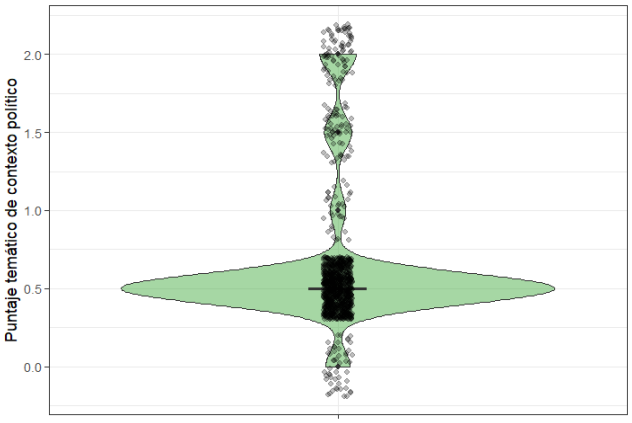
El segundo gráfico, que representa el puntaje de contexto político, permite observar una alta concentración en el valor 0.5, que parecieran ser muchos valores alrededor de esta cantidad, pero son en realidad el mismo, pues, por efectos de visualización, estos gráficos incorporan una pequeña perturbación aleatoria. La mediana se ubica en el valor 0.5 y la media en 0.644, lo que evidencia la existencia de valores atípicos en la parte derecha de los datos que afectan el valor de la media, que también es confirmado por la gráfica. El rango intercuartílico vale 0 e indica que más del 50 % central de los datos corresponde al valor 0.5. El valor máximo de este puntaje es 2 y está asociado a varios municipios, entre los cuales están Anorí y Briceño, ambos del departamento de Antioquia.

El tercer gráfico, correspondiente al puntaje de contrabando, evidencia una alta densidad de observaciones en 0, valor que también representa la mediana; sin embargo, el valor de la media es 0.065, lo cual nos indica la presencia de valores atípicos y una cola más larga hacia el lado derecho en valores discretos; es decir, asimetría positiva. Se puede observar que la densidad de las observaciones va disminuyendo a medida que se aleja más de 0 y que existen 2 datos bastante alejados de los otros puntos, correspondientes al valor 1; éstos pertenecen a Uribia (La Guajira) y San Andrés de Tumaco (Nariño).

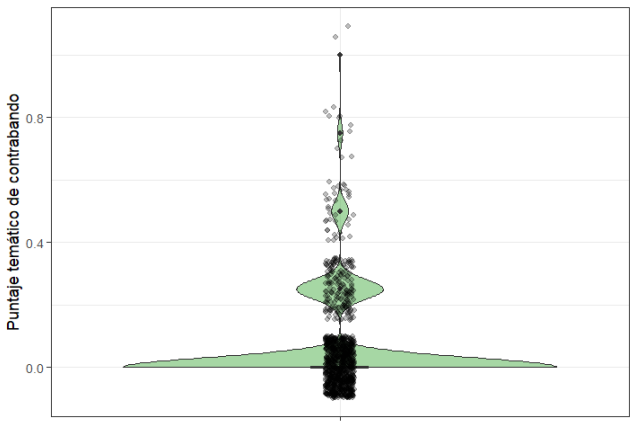
Por último, en el cuarto gráfico, que representa el puntaje de sectores susceptibles a lavado de activos, se puede observar una alta densidad de observaciones en valores que se encuentran entre -1 y 1, lo cual es consistente con lo visto en el histograma de la Figura 1(d). La mediana se ubica en -0.081 y la media



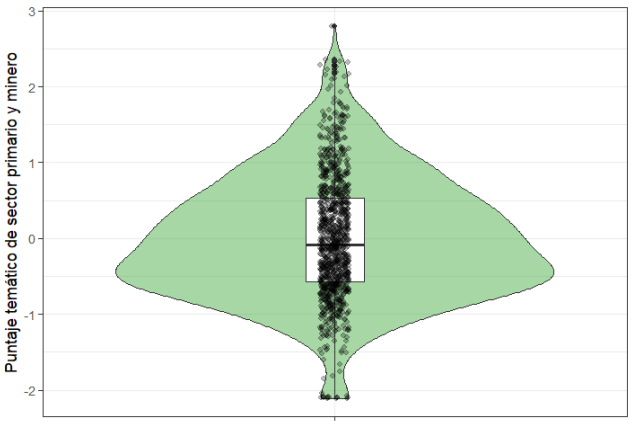
(a) Puntaje temático de contexto estructural $x_{\bullet,1}$.



(b) Puntaje temático de contexto político $x_{\bullet,2}$.



(c) Puntaje temático de contrabando $x_{\bullet,3}$.

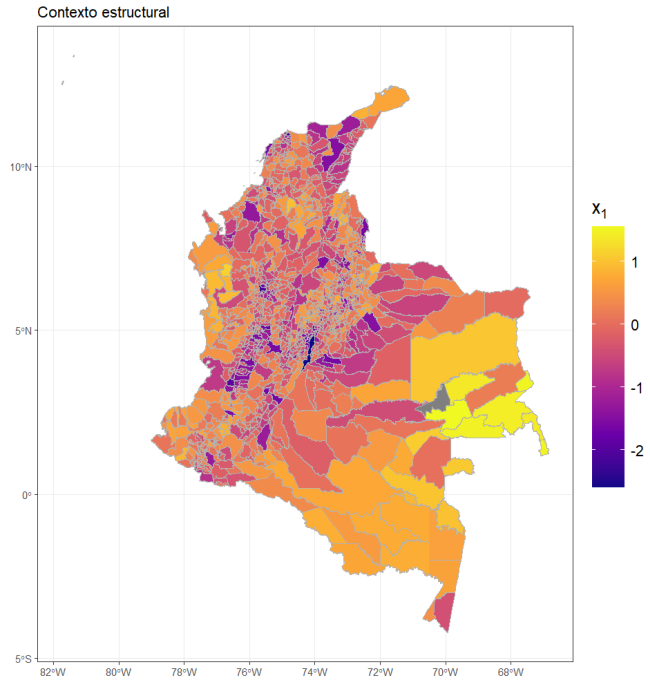


(d) Puntaje temático de sectores susceptibles al lavado de activos $x_{\bullet,4}$.

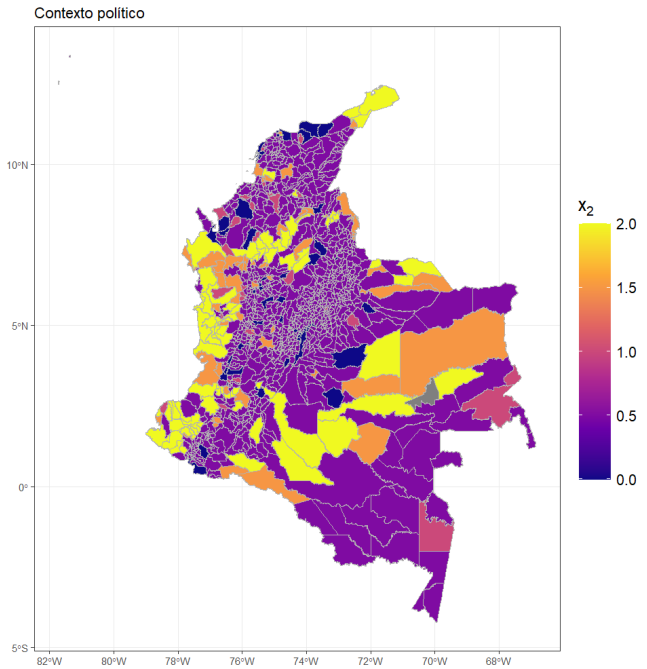
FIGURA 2. Gráficos resumen de la distribución empírica de los puntajes temáticos de contexto estructural.

en 0; por lo tanto, existen datos atípicos en la parte derecha de la distribución empírica que arrastran el valor de la media. El valor máximo de este puntaje pertenece a Acacias, Meta (2.794) y el valor mínimo pertenece a Pana Pana, Guainía (-2.108).

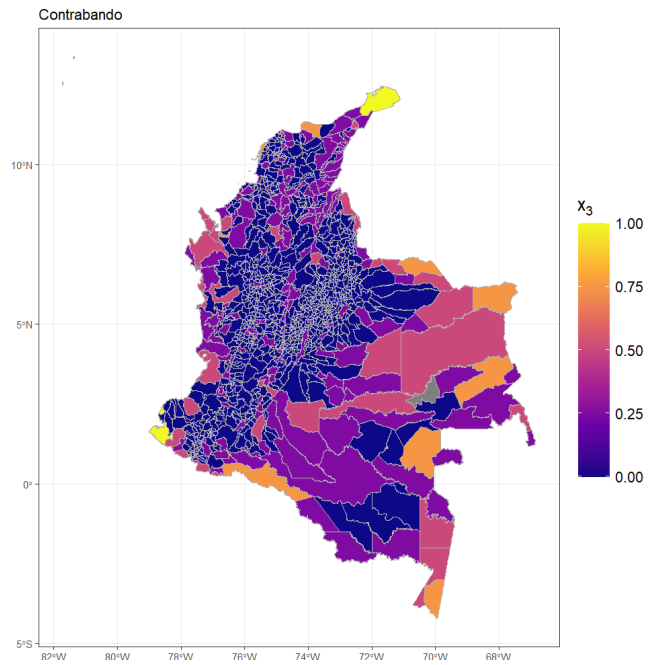
Ahora bien, en la Figura 3, se pueden visualizar los puntajes temáticos estructurales para los 1122 municipios de Colombia en 4 mapas con escala de colores. Durante el diseño de estos puntajes como medidas agregadas por bloque de variables temáticas municipales, los autores intentamos preservar la *dirección* de las medidas, de manera que ámbitos como número de habitantes, cobertura de servicios públicos y número de bancos, por ejemplo, para el puntaje del Contexto estructural, aportaran negativamente al puntaje $x_{\bullet,1}$ al ir en la misma dirección: entre más grandes son estas medidas para un municipio i, se deduce naturalmente que éste posee buen desarrollo en materia estructural, luego $x_{i,1}$ será bajo (al menos gracias al aporte de esas variables) y veremos en los mapas que están coloreados en tonos cercanos al púrpura. Y ámbitos como el índice de pobreza multidimensional o la tasa de analfabetismo, contribuirán en el crecimiento de $x_{i,1}$ a medida que éstas también registren valores altos; se deduce, por tanto, que el municipio en cuestión posee deficiencia en su desarrollo estructural (al menos gracias al aporte de esas variables) y veremos en los mapas que están coloreados en tonos cercanos al amarillo. Algunas medidas no



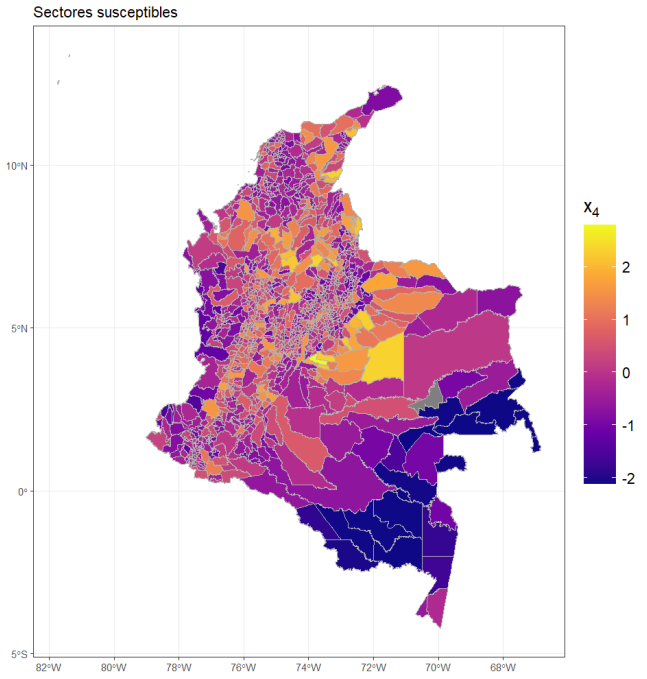
(a) Mapa del puntaje temático de contexto estructural $x_{\bullet,1}$.



(b) Mapa del puntaje temático de contexto político $x_{\bullet,2}$.



(c) Mapa del puntaje temático de contrabando $x_{\bullet,3}$.



(d) Mapa del puntaje temático de sectores susceptibles al lavado de activos $x_{\bullet,4}$.

FIGURA 3. Mapa de Colombia a nivel municipal para los puntajes temáticos de contexto estructural.

pudieron ser tratadas bajo el mismo criterio, como la variable que mide la facción política del candidato presidencial que predominó en las votaciones del 2022 ('Derecha' o 'Izquierda') en el bloque de Contexto

político, pues no resulta apropiado que la preferencia política de los ciudadanos influya a consideración nuestra en la dirección de los puntajes temáticos, de manera que la interpretabilidad de éstos no es la misma que la de los indicadores observados (los cuales mencionamos de antemano que son más altos en la medida que la problemática tiene mayor presencia en los municipios, y tienden a cero en caso de ausencia de fenómenos adversos). No obstante, los $x_{\bullet,i}$ se pueden interpretar aproximadamente de la misma manera que los $y_{\bullet,i}$ al ser sólo unas pocas variables a las que no pudimos asignarles una *dirección* concreta. Por eso, se puede ver que los cuatro mapas de esta sección y los otros cuatro de la sección siguiente son típicamente coherentes en los colores.

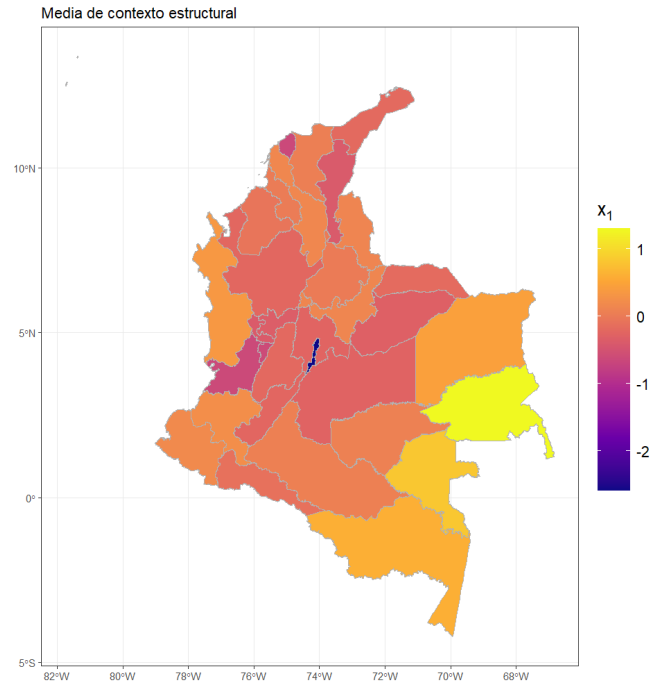
Lo primero que resulta evidente en la interpretación de los mapas es que el de puntaje de Contexto estructural difiere de los de Contexto político, Contrabando y Sectores susceptibles a lavado de activos. En estos últimos tres, podemos observar una tendencia: municipios del centro del país y de la Amazonía presentan los valores más bajos; mientras que los periféricos y de la Orinoquía, los más altos. En contraste, el mapa de Contexto estructural parece romper esta tendencia al mostrar puntajes deficientes para los municipios de la Amazonía, y también presentar diferencias abruptas entre municipios cercanos de las Regiones Andina y Caribe del país, donde se habría esperado observar una homogeneidad espacial como en los otros tres mapas. Esto puede deberse a la cantidad de variables de cobertura de servicios públicos, las cuales se evidencia en los datos tabulares de Muñoz Chamorro (2024) difieren considerablemente de municipio a municipio en esta zona del país, mientras que en las regiones Pacífica, Orinoquía y Amazonía, sencillamente las coberturas son precarias de forma homogénea.

Nótese especialmente la similitud entre los mapas de Contexto político y Contrabando, pues el patrón espacial es prácticamente el mismo: estamos hablando de municipios donde los fenómenos políticos y la propensión al contrabando parecen estar correlacionados. Pensamos que posiblemente se deba a la variable Zona franca dentro de Contexto político y a las variables Puerto marítimo, Aeropuerto y Puerto fluvial en Contrabando. Como mencionábamos, el mapa de Sectores susceptibles no queda exento de este patrón geográfico, con lo cual la actividad minera también estaría relacionada con las variables que acabamos de mencionar.

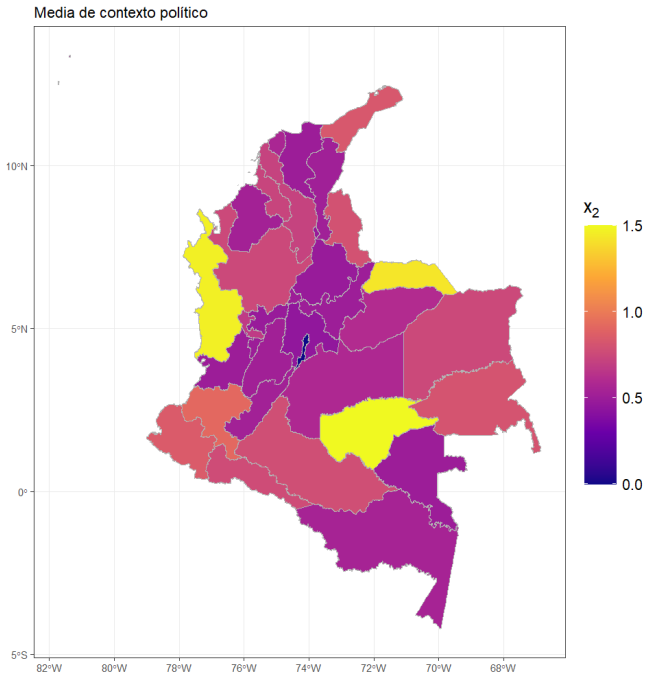
Ahora bien, a partir de estos índices, se construyeron cuatro medidas agregadas departamentales estructurales como el promedio de cada uno de los cuatro puntajes temáticos municipales. Con ello, se obtiene una medida resumen departamental por cada uno de los $x_{i,j}$ que se consignan en cuatro mapas departamentales en la Figura 4.

Como puede apreciarse, las medias de los puntajes son un buen resumen de lo medido para los municipios, pues, entre departamentos, no se evidencia una marcada heterogeneidad respecto a la temática medida. A pesar de ello, vemos cierta heterogeneidad entre mapas. Nótese que el menor puntaje de contexto estructural se lo lleva Bogotá, debido a su enorme desarrollo urbano, mientras que, como sector susceptible, registra el mayor puntaje. Lo propio ocurre para el Vichada, que posee puntajes bajos en los índices de contexto político y sectores susceptibles, pero altos en los índices de contexto estructural y contrabando. Otros departamentos que presentan diferencias en la tendencia de sus puntajes estructurales son Guaviare, Amazonas, Caquetá, Nariño, Chocó, Antioquia y Cesar.

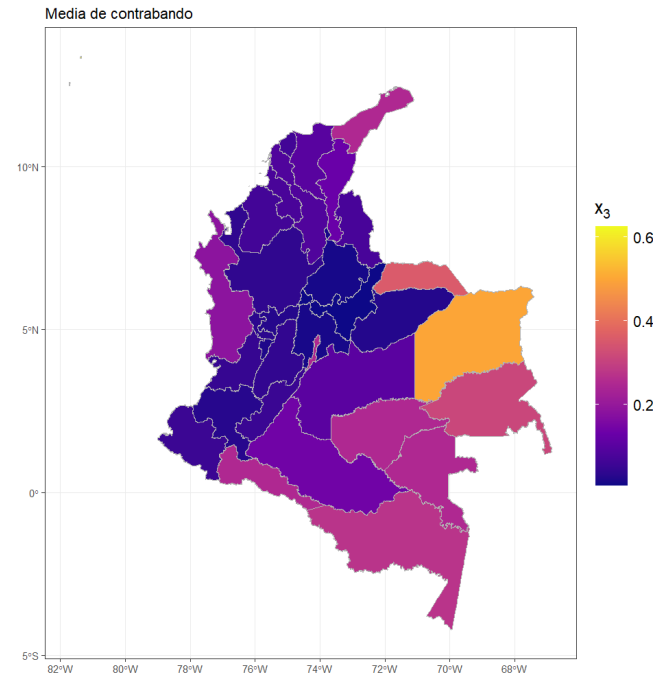
Destacamos también que el índice de sectores susceptibles se ve dominado por Bogotá, y posee los puntajes más bajos en Amazonas, Vaupés y Guainía; esto es consistente con que es una medida agregada de desarrollo industrial. El índice departamental de contrabando tiene su máximo en Vichada, mas recordemos que esto denota la presencia de municipios con múltiples canales de comunicación territorial (frontera con otro países, puertos marítimos, aeropuertos, etc.). El contexto político departamental se ve dominado por Arauca, Chocó y Guaviare, mas no puede interpretarse directamente como un resultado de riesgo político alto por la variable categórica de facción política preponderante en las últimas elecciones; a pesar de ello, es una buena aproximación a departamentos con riesgo electoral crítico; mientras que Bogotá se situó como el departamento con el menor 'riesgo político'. En materia de desarrollo estructural, los peores puntajes se los llevan Guainía, Vaupés, Vichada, Amazonas y Chocó. Destacamos cómo algunos



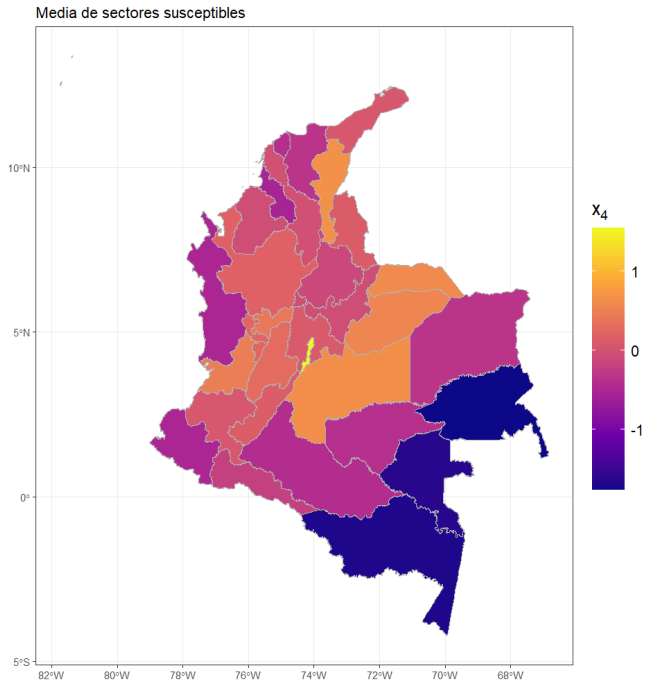
(a) Mapa del puntaje temático agregado de contexto estructural $\bar{x}_{\bullet,1}$.



(b) Mapa del puntaje temático agregado de contexto político $\bar{x}_{\bullet,2}$.



(c) Mapa del puntaje temático agregado de contrabando $\bar{x}_{\bullet,3}$.



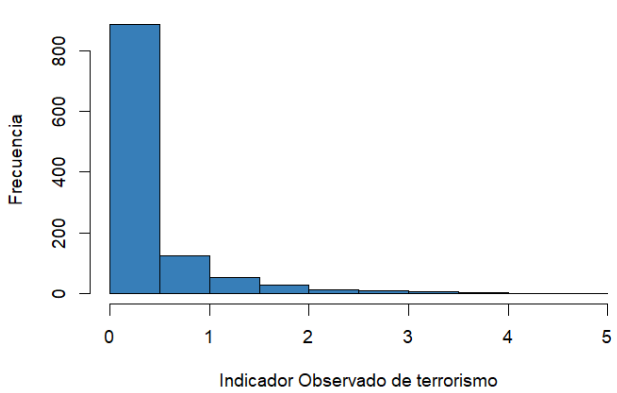
(d) Mapa del puntaje temático agregado de sectores susceptibles al lavado de activos $\bar{x}_{\bullet,4}$.

FIGURA 4. Mapa de Colombia a nivel departamental para los puntajes temáticos promedio de contexto estructural.

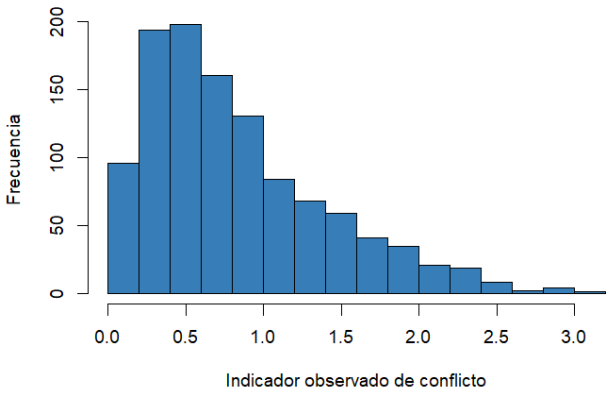
departamentos de la Amazonía presentan un pobre desarrollo urbano, mas poseen puntajes muy bajos en sus indicadores observados de riesgo LAFT como se discute en §§2.2.

2.2. Indicadores observados de fenómenos asociados al riesgo de LAFT

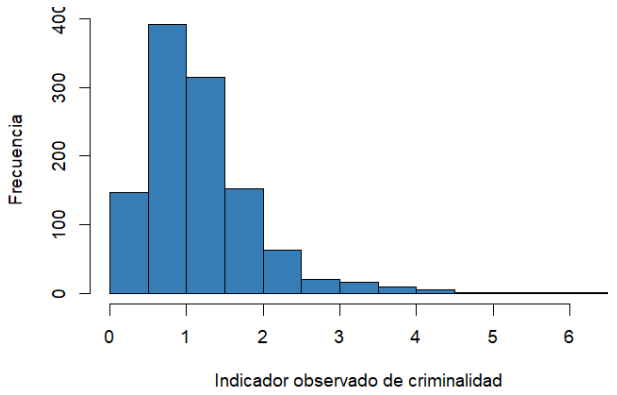
Para el análisis exploratorio de los indicadores observados, iniciamos con cuatro histogramas en la Figura 5. En el primero, que representa al puntaje de terrorismo, podemos ver que la mayoría de las observaciones



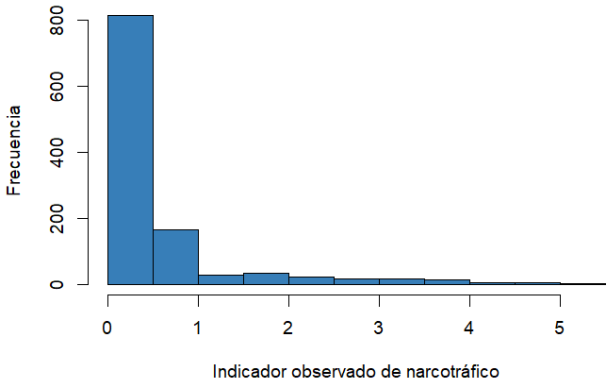
(a) Indicador observado de terrorismo $y_{\bullet,1}$.



(b) Indicador observado de conflicto $y_{\bullet,2}$.



(c) Indicador observado de criminalidad $y_{\bullet,3}$.



(d) Indicador observado de narcotráfico $y_{\bullet,4}$.

FIGURA 5. Histogramas de los indicadores observados de fenómenos asociados al riesgo de LAFT.

se encuentran en valores bajos del indicador, mientras que muy pocos municipios presentan valores altos. La distribución del puntaje $y_{i,1}$ no es simétrica y, por lo tanto, sugiere que no se cumple el supuesto de normalidad para este puntaje.

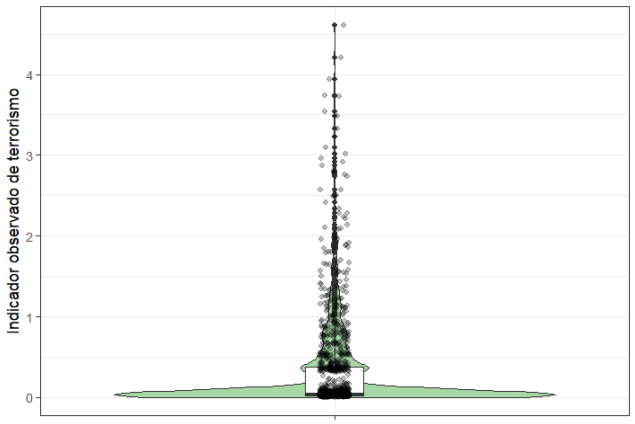
El segundo histograma corresponde al puntaje del grupo de conflicto. En este gráfico, se evidencia que las observaciones se distribuyen mayormente en valores del indicador entre 0 y 1, mientras que, a medida que aumenta el valor del indicador, menor es el número de municipios que lo presentan. Se puede ver que también existe asimetría positiva para $y_{i,2}$.

El tercer histograma presenta el puntaje $y_{i,3}$ del bloque de criminalidad: los datos presentan asimetría positiva marcada, igual que los dos anteriores, y podemos ver que la moda se encuentra en valores cercanos a 1. Se ve que, aunque es un grupo pequeño, hay municipios con valores muy altos del indicador, denotando así evidencia de criminalidad considerablemente más marcada que la observada en la mayoría

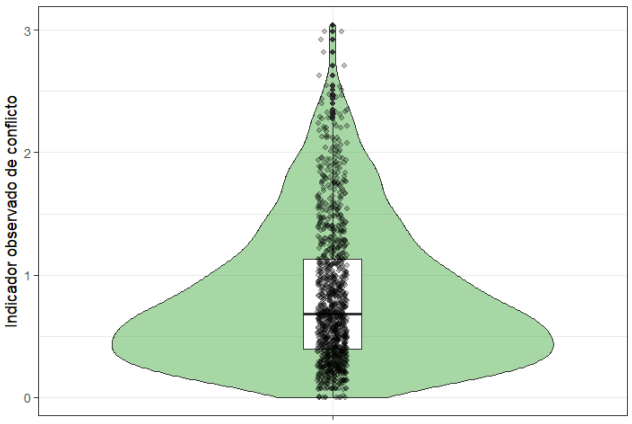
de municipios.

Por último, el histograma del puntaje de narcotráfico presenta una distribución unimodal con asimetría positiva muy marcada, lo cual indica que, aunque la mayoría de los municipios presentan valores bajos del indicador, existe un grupo de municipios sustancialmente afectados por el narcotráfico por encima del grueso. Remarcamos que dicha interpretabilidad se habría perdido si hubiéramos modelado los indicadores observados con una distribución simétrica a partir de transformaciones a las medidas agregadas que conservaran la localización de los valores, mas no su dispersión.

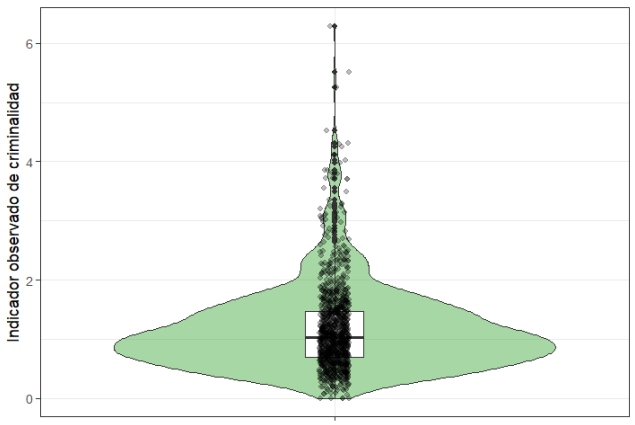
A continuación, en la Figura 6, se presentan los diagramas resumen que introdujimos en §§2.1, pero esta vez para los puntajes de los bloques del grupo de indicadores observados.



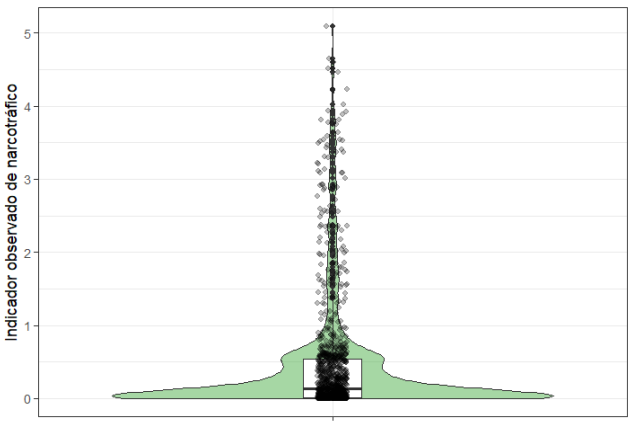
(a) Indicador observado de terrorismo $y_{\bullet,1}$.



(b) Indicador observado de conflicto $y_{\bullet,2}$.



(c) Indicador observado de criminalidad $y_{\bullet,3}$.



(d) Indicador observado de narcotráfico $y_{\bullet,4}$.

FIGURA 6. Gráficos resumen de la distribución empírica de los indicadores observados de fenómenos asociados al riesgo de LAFT.

En el gráfico correspondiente al puntaje $y_{i,1}$, se observa, a partir del ancho de la densidad *kernel*, una concentración muy alta en valores cercanos al cero. La mediana se puede ubicar en valores pequeños (0.0478) y el rango intercuartílico también es reducido, lo cual indica poca variabilidad en el 50 % central de los datos. El valor de la media es de 0.331, lo cual, como se puede ver en la gráfica, indica la presencia de valores atípicos en la parte superior de los datos, como el valor máximo (4.60856) que pertenece al municipio de Anorí, Antioquia. El valor mínimo de este puntaje es 0, registrado para un solo municipio,

indicando ausencia absoluta de registros en materia de terrorismo, al menos para los años involucrados en la consolidación del indicador.

En el segundo gráfico, correspondiente al puntaje del bloque de Conflicto $y_{i,2}$, se puede observar que, aunque existe una densidad mayor en valores alrededor de 0.5, hay una mayor dispersión de los datos en comparación al gráfico de $y_{i,1}$; de igual forma, el rango intercuartílico es más amplio, lo que indica una mayor variabilidad en el 50 % central de los datos. El valor de la mediana se encuentra en 0.6802 y el de la media en 0.8283, lo que señala la presencia de valores atípicos en la parte superior de los datos que afectan el valor de la media, pero con una concentración mayor en comparación al puntaje de terrorismo. El valor máximo pertenece a San José del Guaviare, capital del Guaviare, con un puntaje de 3.0397, mientras que el mínimo es 0 y lo comparten 8 municipios, entre los cuales están Piojo (Atlántico) y Beteitiva (Boyacá).

El gráfico del puntaje de criminalidad $y_{i,3}$ muestra, gracias al ancho de la densidad *kernel*, una mayor concentración en valores alrededor de 1 y con una dispersión menor a la del gráfico anterior. El rango intercuartílico refleja una variabilidad moderada en el 50 % intermedio de los datos. El valor de la mediana es 1.0236 y el de la media es 1.1764, lo cual nos deja ver que hay datos atípicos afectando el valor de la media como el valor máximo (6.285), perteneciente a Bogotá, D.C. El valor mínimo de este puntaje es 0 y lo comparten 5 municipios, entre los cuales están La Victoria y Puerto Arica (Amazonas).

El último gráfico, correspondiente al puntaje de Narcotráfico $y_{i,4}$ evidencia una clara asimetría positiva de los datos. Se puede observar una densidad grande en valores cercanos al 0. La mediana es 0.12698 y la media es 0.47841, lo que indica la presencia de municipios con valores muy altos de este puntaje, siendo el mayor de ellos 5.093, perteneciente al municipio de Puerto Asís (Putumayo). El rango intercuartílico indica una variabilidad moderada de la mitad central de los datos. El valor mínimo de este puntaje es 0 y pertenece a la considerable cantidad de 183 municipios. Fue particularmente este indicador con presencia de ceros absolutos en sus observaciones el que nos motivó a proponer una distribución cero-inflada continua como distribución de la ecuación de medición de los modelos SEM Bayesianos y como distribución muestral al mismo tiempo.

A continuación, en la Figura 7, se presenta un *corrplot* de los puntajes correspondientes a los cuatro bloques que conforman este grupo, con el fin de visualizar la correlación existente entre las variables $y_{i,j}$. Como se observa, todas las correlaciones lineales entre los puntajes son positivas, lo que sugiere que

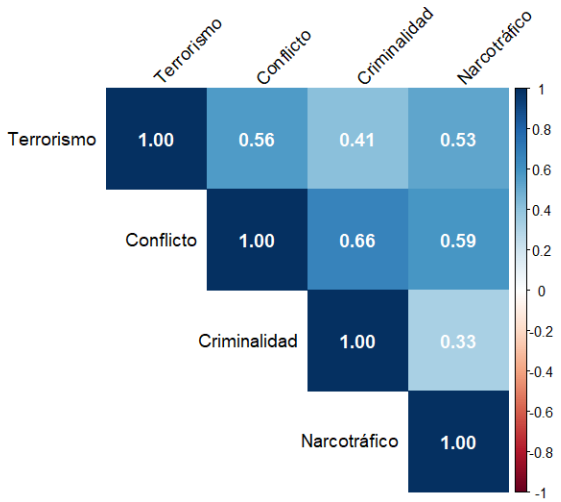


FIGURA 7. Diagrama de correlaciones entre los cuatro indicadores observados de fenómenos asociados al riesgo de LAFT.

incrementos en uno de los indicadores tienden a estar asociados con incrementos en los demás. La mayor asociación lineal se presenta entre los puntajes de conflicto y criminalidad ($r = 0.66$), seguida por la

existente entre conflicto y narcotráfico ($r = 0.59$). En contraste, la menor correlación lineal se encuentra entre los puntajes de criminalidad y narcotráfico ($r = 0.33$).

Finalmente, hacemos una exploración de la distribución geográfica de los indicadores observados, tanto a nivel desagregado por municipios como agregado por departamentos. Los primeros mapas corresponden a los presentados en la Figura 8, y muestran en escala de colores los valores observados para los cuatro indicadores a lo largo de los 1122 municipios de Colombia. Dada la construcción de estas medidas a partir de los bloques temáticos consolidados en Muñoz Chamorro (2024), los 4 indicadores van de 0 a infinito, y valores cercanos a 0 quedan representados por un púrpura intenso, mientras que valores grandes y positivos quedan en amarillo.

A grandes rasgos, es evidente que estos mapas siguen un patrón más definido que los de la Figura 3, y esto va en consonancia con lo registrado en el diagrama de correlaciones (véase la Figura 7). En general, los municipios del centro del país presentan valores bajos en los indicadores de riesgo (a excepción de Bogotá, cuyo patrón difiere de mapa a mapa), al igual que municipios del Amazonas, Vaupés y Guainía. Por su parte, municipios de la costa Pacífica poseen niveles de riesgo altos, así como los del Magdalena medio, pertenecientes a Putumayo, algunos de Norte de Santander que colindan con Venezuela y algunos municipios de la Orinoquía. Otros valores rompen esta tendencia cuando se cambia de indicador, como ciertos municipios de La Guajira, de Vichada y del Huila.

En virtud del marcado sesgo positivo evidenciado en los datos, para los indicadores agregados departamentales empleamos la mediana como medida resumen robusta ante valores altos en la escala de medición. Los mapas departamentales por indicador observado de riesgo LAFT a partir de las medianas de los $y_{i,j}$ se sintetizan en la Figura 9. En términos generales, dada la relativamente baja heterogeneidad dentro de los departamentos respecto a los indicadores observados, los mapas de las medianas por departamento parecen ser un buen resumen de lo evidenciado en la Figura 8. En cuanto a terrorismo, encabezan la lista el Guaviare, Bogotá y Arauca; en materia de conflicto, Bogotá; en cuanto a criminalidad, nuevamente Bogotá; y en lo referente a narcotráfico, Guaviare otra vez y Putumayo. Nótese la similitud en general que presentan los cuatro mapas resumen.

3. Especificación de los modelos

Se presenta a continuación una descripción de los modelos Bayesianos empleados en este caso de estudio. Más información sobre la notación empleada y la caracterización de las distribuciones puede ser consultada en el Apéndice B. Las distribuciones condicionales completas de cada modelo son mencionadas en el Apéndice C con una breve demostración del respectivo resultado.

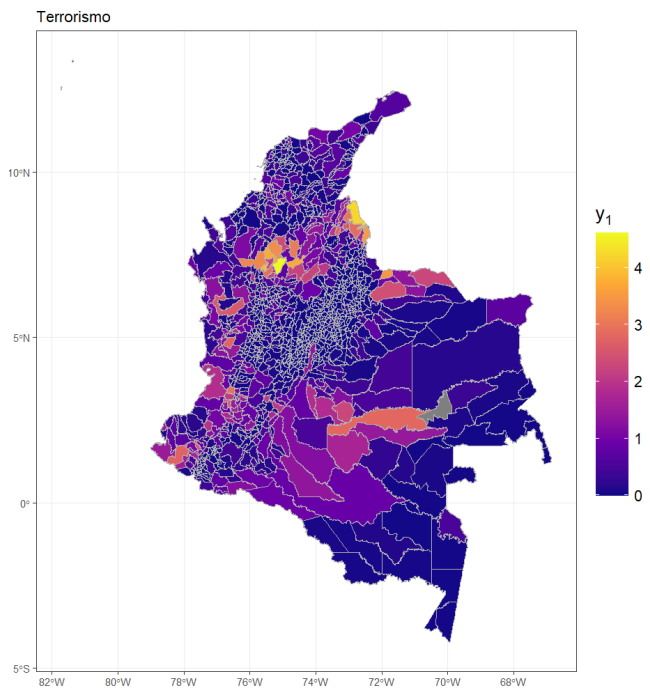
3.1. $\mathcal{M}_1$: Modelo Latente de Riesgo LAFT (MLR-LAFT)

El Modelo 1 corresponde a un modelo de ecuaciones estructurales (SEM) Bayesiano jerárquico de respuesta continua cero-inflada, pues se compone de un modelo de medición, involucrado directamente en la distribución muestral, y de un modelo estructural para los factores latentes, incorporando en ambas partes parámetros con distribuciones previas asociadas.

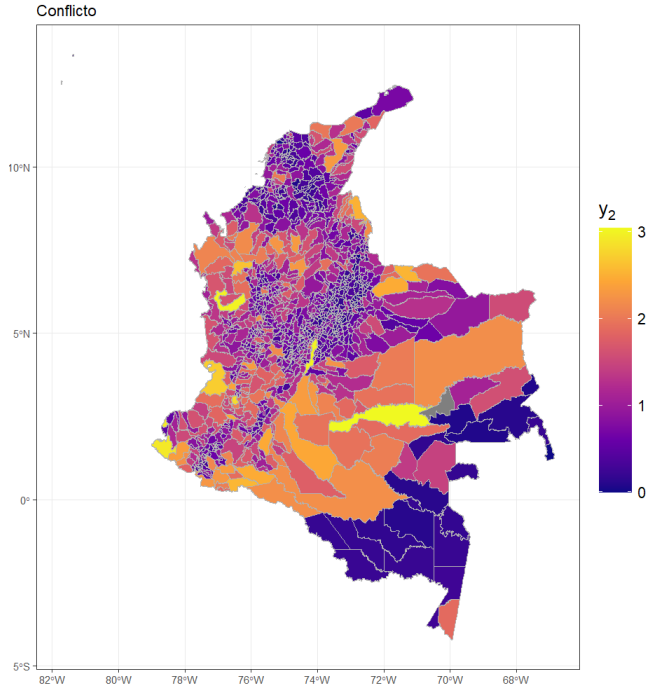
Específicamente, bajo la justificación discutida en el Apéndice D, proponemos modelar los indicadores observados $y_{i,j}$ mediante la distribución Gamma cero-inflada (ZIGamma), donde $y_{i,j}$ es el j-ésimo indicador observado ($j = 1, \ldots, 4$) para el i-ésimo municipio de Colombia ($i = 1, \ldots, 1122$, donde 1122 es el número de municipios registrados actualmente en el código DIVIPOLA).

✤ **Distribución muestral**

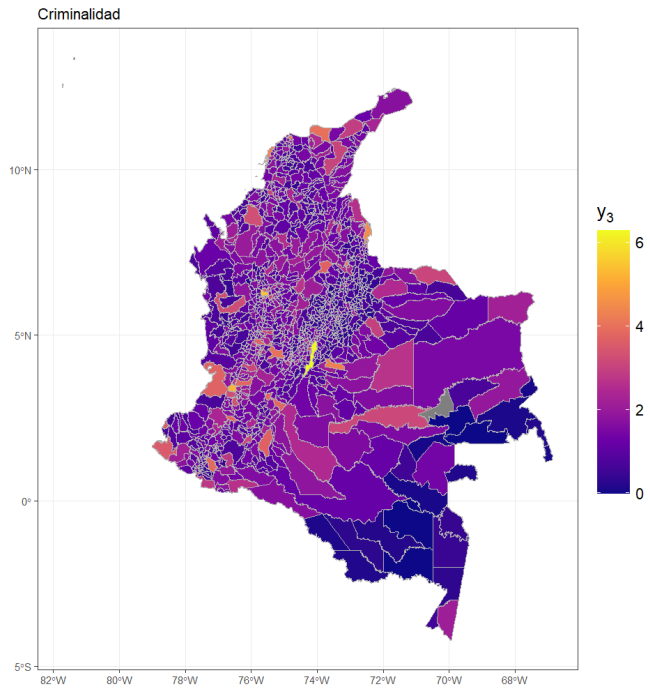
La distribución Gamma cero-inflada es una distribución de probabilidad mixta; es decir, mezcla una función de masa de probabilidad Bernoulli con una función de densidad de probabilidad Gamma.



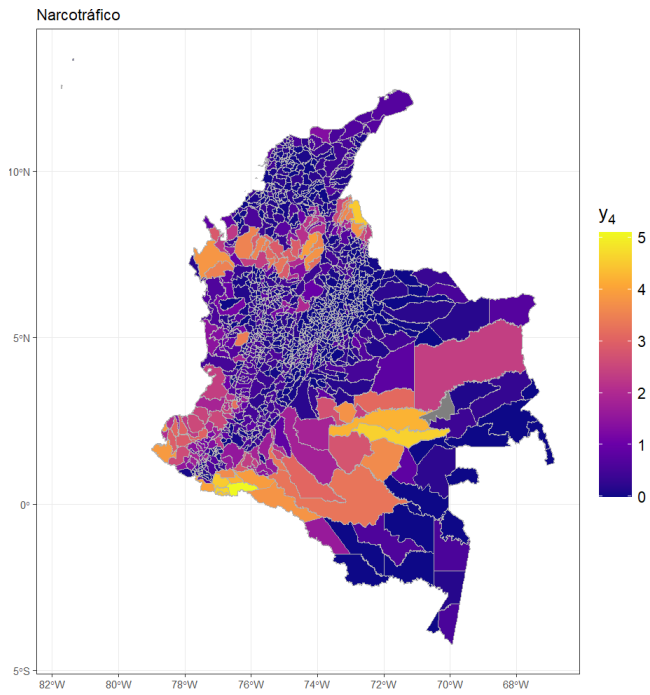
(a) Indicador observado de terrorismo $y_{\bullet,1}$.



(b) Indicador observado de conflicto $y_{\bullet,2}$.



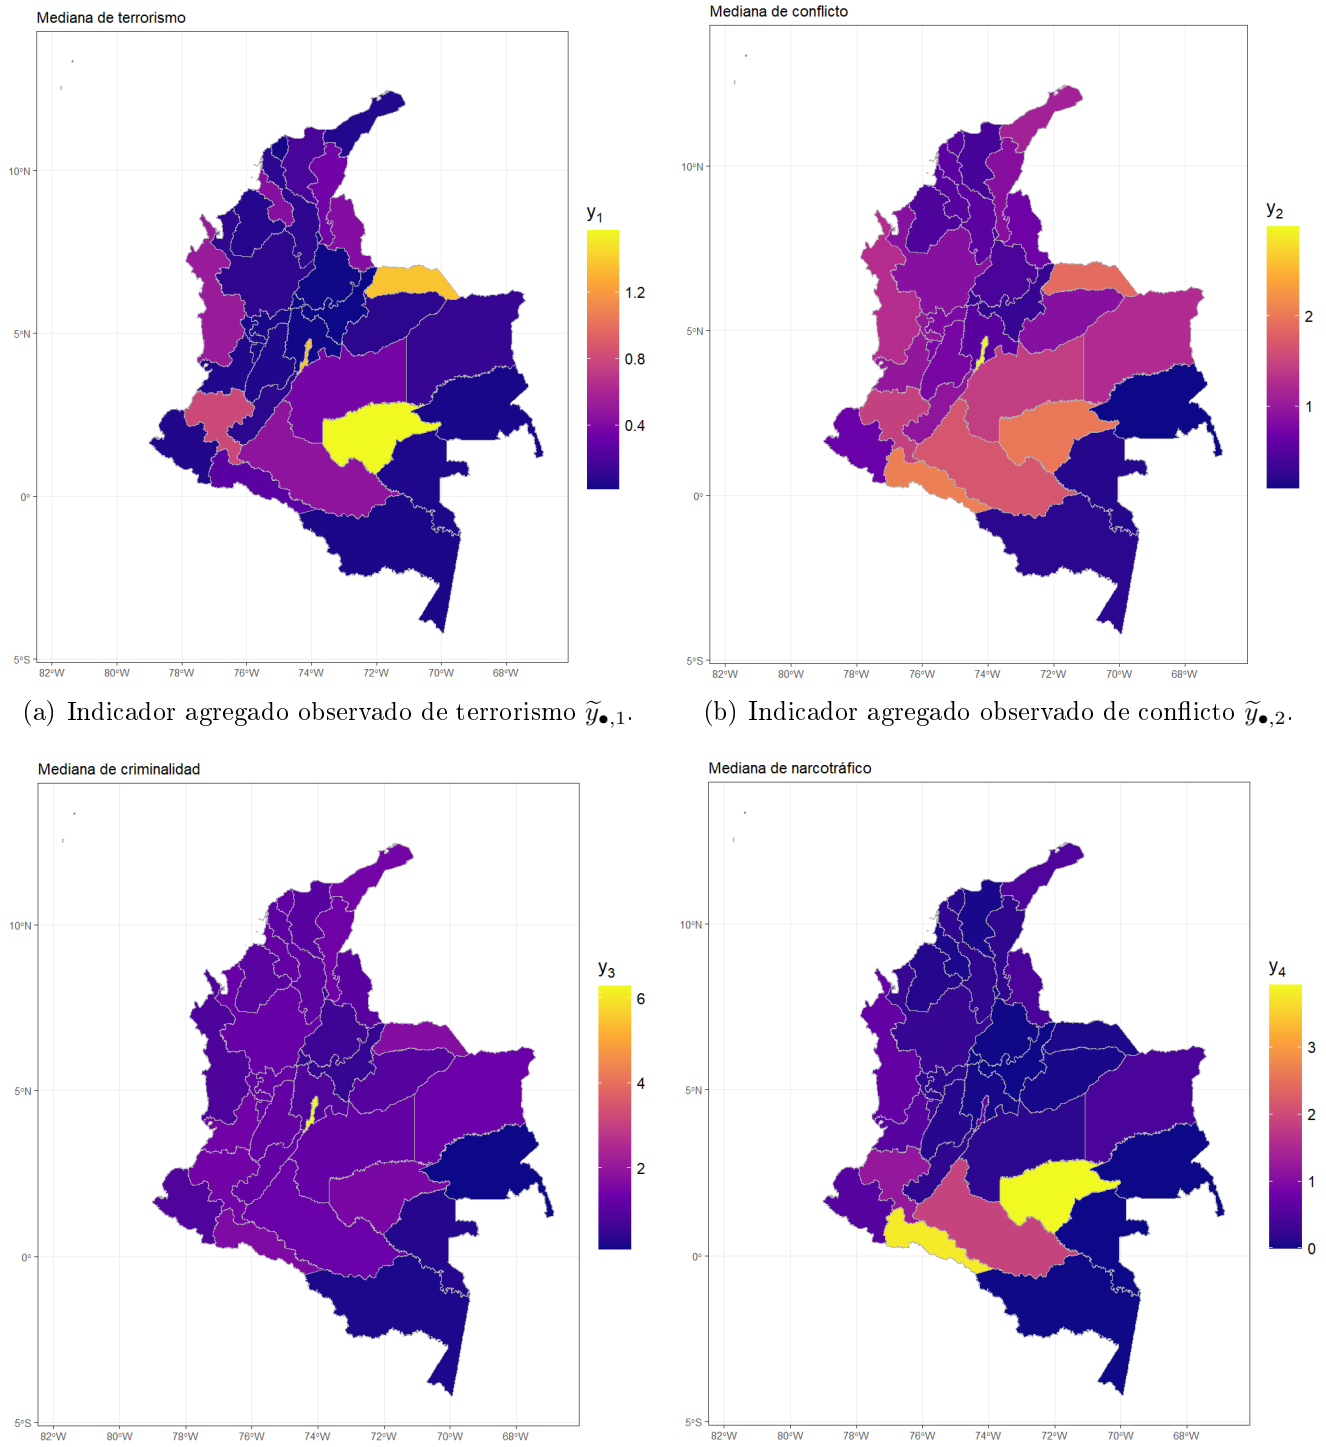
(c) Indicador observado de criminalidad $y_{\bullet,3}$.



(d) Indicador observado de narcotráfico $y_{\bullet,4}$.

FIGURA 8. Mapa de Colombia a nivel municipal para los indicadores observados de fenómenos asociados al riesgo de LAFT.

Como el soporte de esta última es $\mathbb{R}^+$, lo extendemos al 0 incorporando una probabilidad puntual



(a) Indicador agregado observado de terrorismo $\widetilde{y}_{\bullet,1}$.

(b) Indicador agregado observado de conflicto $\widetilde{y}_{\bullet,2}$.

(c) Indicador agregado observado de criminalidad $\widetilde{y}_{\bullet,3}$.

(d) Indicador agregado observado de narcotráfico $\widetilde{y}_{\bullet,4}$.

FIGURA 9. Mapa de Colombia a nivel departamental para las medianas por departamento de los indicadores observados municipales.

$\pi \in (0,1)$ en ese valor. De esta manera, aparece la distribución Bernoulli:

$$\mathrm{P}(y_{i,j}=0)=\pi_{i,j} \quad \text{y} \quad \mathrm{P}(y_{i,j}>0)=1-\pi_{i,j}.$$

Si denotamos como p a la función de probabilidad mixta de la Gamma cero-inflada, entonces

$$p(y_{i,j}) = \begin{cases} \pi_{i,j} & \text{si } y_{i,j} = 0 \\ (1-\pi_{i,j})\text{Gamma}(\phi_{i,j}, \eta_{i,j}) & \text{si } y_{i,j} > 0 \end{cases},$$

donde $\phi_{i,j}, \eta_{i,j} \in \mathbb{R}^+$ son los parámetros de forma y razón de la distribución Gamma, respectivamente, que modela a cada $y_{i,j}$. Es decir, la distribución Gamma cero-inflada es triparamétrica: π, ϕ, η.

Ahora bien, el SEM propuesto para modelar los $y_{i,j}$ tiene como esencia lo siguiente: existe un factor latente de riesgo LAFT dentro de cada municipio, que denotamos como R_i para el i-ésimo municipio, el cual no es medible directamente, sino que se manifiesta en los cuatro indicadores observados; y dicho factor latente, a pesar de no ser medible, lo suponemos modelable a partir de una combinación lineal de los valores fijos de los cuatro índices estructurales de los municipios, los $x_{i,j}$.

Teniendo en cuenta lo anterior, la ecuación estructural del SEM se propone como

$$R_i := \alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i, \qquad \varepsilon_i \overset{\text{iid}}{\sim} \text{N}(0, \sigma^2), \tag{3.1}$$

donde, en virtud del enfoque Bayesiano, α, $\boldsymbol{\beta}$ y σ^2 son variables aleatorias con distribuciones previas definidas más adelante. Luego lo anterior es, equivalentemente,

$$R_i \,|\, \alpha, \boldsymbol{\beta}, \sigma^2, \mathbf{x}_i \overset{\text{ind}}{\sim} \text{N}\left(\alpha + \mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2\right).$$

Y la ecuación de medición del SEM se propone como el modelo lineal generalizado (GLM) dado por

$$y_{i,j} \,|\, R_i, \mu_j, \lambda_j, \phi_j, \delta_{0j}, \delta_{1j} \overset{\text{ind}}{\sim} \text{ZIGamma}\left(\pi_{i,j}, \phi_j, \frac{\phi_j}{\mu_{i,j}}\right), \quad y_{i,j} \in [0, \infty) \tag{3.2}$$

donde ϕ_j es el parámetro de forma común para los 1122 municipios en el j-ésimo indicador observado y

$$\mu_{i,j} := \text{E}(y_{i,j} \,|\, R_i, \mu_j, \lambda_j, \phi_j, \delta_{0j}, \delta_{1j}) := \exp\left(\mu_j + \lambda_j R_i\right) \tag{3.3}$$

es la media de la distribución Gamma completamente determinada por el valor $\mu_j + \lambda_j R_i$ mediante la función de enlace ln. En el modelo de medición bajo el paradigma Bayesiano, los cuatro μ_j son interceptos comunes a todos los municipios, al igual que las cargas factoriales λ_j, y corresponden a parámetros que nuevamente poseen una distribución previa asociada. En cuanto a esta especificación del GLM, la deducción es:

$$\text{E}(y_{i,j} \,|\, R_i, \mu_j, \lambda_j, \phi_j, \delta_{0j}, \delta_{1j}) = \frac{\phi_j}{\frac{\phi_j}{\exp(\mu_j + \lambda_j R_i)}} = \exp\left(\mu_j + \lambda_j R_i\right).$$

Si λ_j es grande y positivo, entonces el indicador $y_{i,j}$ tiende a aumentar o disminuir conforme R_i crece o disminuye; en cambio, si λ_j es cercano a 0, R_i aporta poca información sobre $y_{i,j}$. Como R_i es una variable latente, su escala no queda determinada de manera única: En efecto, si definimos

$$R_i^* := cR_i \quad \text{y} \quad \lambda_j^* := \frac{\lambda_j}{c}, \qquad c \in \mathbb{R} \setminus \{0\},$$

entonces la media de la componente Gamma en el modelo de medición queda como

$$\exp\left(\mu_j + \lambda_j^* R_i^*\right) = \exp\left(\mu_j + \frac{\lambda_j}{c} cR_i\right) = \exp\left(\mu_j + \lambda_j R_i\right),$$

luego el ajuste del modelo permanece inalterado a cambios de escala en los parámetros. Para evitar este problema de identificabilidad, se impone una restricción sobre una carga factorial; en particular, $\lambda_1 := 1$, con lo cual perdemos un parámetro por estimar. De este modo, la escala de R_i queda definida con respecto al primer indicador observado, el puntaje de terrorismo. En consecuencia, las demás cargas se interpretan en relación con dicha escala.

Finalmente, explicamos en qué consisten los cuatro δ_{0j} y los cuatro δ_{1j} involucrados en (3.2). Para ello, definimos la variable auxiliar

$$z_{i,j} := \begin{cases} 0 & \text{si } y_{i,j} = 0 \\ 1 & \text{si } y_{i,j} > 0 \end{cases}.$$

Nótese que $z_{i,j} \overset{\text{ind}}{\sim} \text{Bernoulli}(\pi_{i,j})$. A $\pi_{i,j}$ lo modelamos con otro GLM a partir de los riesgos latentes como

$$\text{logit}(\pi_{i,j}) := \delta_{0j} - \delta_{1j} R_i,$$

donde los δ_{0j} son interceptos comunes por cada indicador observado, análogos a los μ_j, y los δ_{1j} desempeñan un papel análogo al de las cargas factoriales λ_j, pues cuantifican el efecto del factor latente sobre el componente de inflación de ceros del modelo. Equivalentemente a lo anterior,

$$\pi_{i,j} := \frac{\exp(\delta_{0j} - \delta_{1j} R_i)}{1 + \exp(\delta_{0j} - \delta_{1j} R_i)}, \tag{3.4}$$

con lo cual se espera que, si R_i sube, haya menos probabilidad de que el indicador marque 0, y viceversa. Por lo tanto, proponemos que los cuatro δ_{1j} sean positivos, para lo cual les asignamos como previa a la distribución normal truncada en cero por derecha (N^+) y fijamos desde un inicio su parámetro de localización en 0, pues la media de la normal truncada resulta ser mayor a dicho parámetro y además cambia en función del parámetro de escala, de manera que esperamos valores positivos no tan alejados de 0.

Además de la restricción de $\lambda_1 := 1$ por motivos de identificabilidad, es necesario también aplicar otras restricciones sobre algunos parámetros para escoger una representación única en el espacio de representaciones de equivalencia del modelo. Si definimos $R_i^* := R_i + c$ y $\alpha^* := \alpha + c$, reemplazando en (3.1), tenemos:

$$\begin{aligned} R_i^* &= \alpha^* + \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i \\ R_i + c &= \alpha + c + \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i \\ R_i &= \alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i, \end{aligned}$$

de manera que el modelo permanece invariante frente a cambios de escala en estos parámetros. Así, imponemos

$$\sum_{i=1}^{1122} R_i = 0,$$

lo cual se logra actualizando cada R_i como $R_i - \frac{1}{1122}\sum_{i=1}^{1122} R_i$, y con ello, se actualiza también α restándole la misma diferencia, los μ_j sumándoles las cargas factoriales multiplicadas por la media de los R_i, y los δ_{0j} como $\delta_{0j} - \delta_{1j}\bar{R}$.

Teniendo en cuenta todo lo anterior, la distribución muestral Gamma cero-inflada del Modelo 1, así como la de los dos modelos siguientes, es

$$p(y_{i,j} \mid R_i, \mu_j, \lambda_j, \phi_j, \delta_{0j}, \delta_{1j}) = \begin{cases} \frac{\exp(\delta_{0j}-\delta_{1j}R_i)}{1+\exp(\delta_{0j}-\delta_{1j}R_i)} & \text{si } y_{i,j}=0 \\ \left[1-\frac{\exp(\delta_{0j}-\delta_{1j}R_i)}{1+\exp(\delta_{0j}-\delta_{1j}R_i)}\right] \frac{\left[\frac{\phi_j}{(\mu_j+\lambda_j R_i)}\right]^{\phi_j}}{\Gamma(\phi_j)} y_{i,j}^{\phi_j-1} \exp\left[-\frac{\phi_j}{(\mu_j+\lambda_j R_i)} y_{i,j}\right] & \text{si } y_{i,j}>0 \end{cases}.$$

Para efectos de comodidad en los cálculos de los *kernels* las distribuciones condicionales completas (véase el Apéndice C), lo anterior puede escribirse de manera compacta mediante el corchete de Iverson, definido como

$$[P] := \begin{cases} 1 & \text{si la sentencia } P \text{ es verdadera} \\ 0 & \text{si la sentencia } P \text{ es falsa} \end{cases},$$

en los exponentes de la siguiente manera:

$$p(y_{i,j} \mid \boldsymbol{\theta}) = \pi_{i,j}^{[y_{i,j}=0]} \left[(1-\pi_{i,j}) \frac{(\phi_j/\mu_{i,j})^{\phi_j}}{\Gamma(\phi_j)} y_{i,j}^{\phi_j-1} \exp\left(-\frac{\phi_j}{\mu_{i,j}} y_{i,j}\right)\right]^{[y_{i,j}>0]},$$

donde $\boldsymbol{\theta} := (R_i, \mu_j, \lambda_j, \phi_j, \delta_{0j}, \delta_{1j})$, y $\pi_{i,j}$ y $\mu_{i,j}$ están dados en (3.4) y (3.3) respectivamente.

✤ **Distribución previa**

La distribución previa del modelo viene dada por:

$$\alpha \sim \mathrm{N}(a_\alpha, b_\alpha), \qquad \phi_j \overset{\text{iid}}{\sim} \mathrm{Gamma}(a_\phi, b_\phi), \quad j=1,\ldots,4,$$

$$\boldsymbol{\beta} \sim \mathrm{N}_4(\boldsymbol{\beta}_0, \mathbf{B}_0), \qquad \delta_{0j} \overset{\text{iid}}{\sim} \mathrm{N}(a_{\delta_0}, b_{\delta_0}), \quad j=1,\ldots,4,$$

$$\sigma^2 \sim \mathrm{IG}(a_\sigma, b_\sigma), \qquad \delta_{1j} \overset{\text{iid}}{\sim} \mathrm{N}^+(a_{\delta_1}:=0, b_{\delta_1}), \quad j=1,\ldots,4,$$

$$\mu_j \overset{\text{iid}}{\sim} \mathrm{N}(a_\mu, b_\mu), \quad j=1,\ldots,4, \qquad R_i \mid \alpha, \boldsymbol{\beta}, \sigma^2, \mathbf{x}_i \overset{\text{ind}}{\sim} \mathrm{N}\left(\alpha + \mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2\right), \quad i=1,\ldots,1122.$$

$$\lambda_j \overset{\text{iid}}{\sim} \mathrm{N}(a_\lambda, b_\lambda), \quad j=2,3,4,$$

3.2. $\mathcal{M}_2$: Modelo Latente de Riesgo LAFT con Efectos Departamentales (MLR-LAFT-ED)

El Modelo 2 añade una extensión al Modelo 1 incorporando un efecto aleatorio u_d por departamento dentro de la ecuación estructural del SEM; es decir, se modifica el predictor lineal de la media de los riesgos latentes R_i. El objeto de esta modificación es capturar heterogeneidad no observada entre departamentos independiente de las covariables estructurales $x_{i,j}$. En particular, se propone

$$R_i \mid \alpha, \boldsymbol{\beta}, u_{\xi_i}, \sigma^2, \mathbf{x}_i \overset{\text{ind}}{\sim} \mathrm{N}\left(\alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + u_{\xi_i}, \sigma^2\right),$$

donde $\xi_i = d$ si y sólo si el i-ésimo municipio pertenece al d-ésimo departamento con $d=1,\ldots,33$ (los 32 departamentos de Colombia más el distrito capital, Bogotá).

✤ **Distribución muestral**

Continuamos, exactamente como en el Modelo 1, con la distribución Gamma cero-inflada dentro de la ecuación de medición para modelar los $y_{i,j}$ a partir de dos procesos latentes que siguen el siguiente esquema:

$$R_i \xrightarrow{\delta_{1j}} \pi_{i,j} \quad \text{(Probabilidad de ceros estructurales)}$$
$$R_i \xrightarrow{\lambda_j} \mu_{i,j} \quad \text{(Media de la componente Gamma)}$$

Es decir, el mismo riesgo latente de LAFT controla tanto la propensión a producir ceros como la magnitud esperada de las observaciones positivas en todos los 4488 indicadores municipales involucrados ($1122 \cdot 4$).

Explícitamente, la distribución previa es como en (3.2):

$$y_{i,j} \,|\, R_i, \mu_j, \lambda_j, \phi_j, \delta_{0j}, \delta_{1j} \overset{\text{ind}}{\sim} \text{ZIGamma}\left(\pi_{i,j}, \phi_j, \frac{\phi_j}{\mu_{i,j}}\right), \quad y_{i,j} \in [0, \infty)$$

para todo $i = 1, \ldots, 1122$ y para todo $j = 1, \ldots, 4$, donde

$$\text{logit}(\pi_{i,j}) := \delta_{0j} - \delta_{1j} R_i \qquad \text{y} \qquad \ln(\mu_{i,j}) := \mu_j + \lambda_j R_i.$$

En efecto, la extensión del Modelo 2 conserva la estructura básica del Modelo 1 y permite que municipios con covariables similares presenten distintos niveles esperados de riesgo latente cuando pertenecen a departamentos diferentes.

✤ **Distribución previa**

La distribución previa del modelo es una extensión de la del modelo anterior, salvo que se añaden nuevos parámetros y se modifica la previa de los R_i:

$$\alpha \sim \text{N}(a_\alpha, b_\alpha), \qquad \mu_j \overset{\text{iid}}{\sim} \text{N}(a_\mu, b_\mu), \quad j = 1, \ldots, 4,$$

$$\boldsymbol{\beta} \sim \text{N}_4(\boldsymbol{\beta}_0, \mathbf{B}_0), \qquad \lambda_j \overset{\text{iid}}{\sim} \text{N}(a_\lambda, b_\lambda), \quad j = 2, 3, 4,$$

$$\omega^2 \sim \text{IG}(a_\omega, b_\omega), \qquad \phi_j \overset{\text{iid}}{\sim} \text{Gamma}(a_\phi, b_\phi), \quad j = 1, \ldots, 4,$$

$$u_d \,|\, \omega^2 \overset{\text{iid}}{\sim} \text{N}\left(a_u := 0, \omega^2\right), \; d = 1, \ldots, 33, \qquad \delta_{0j} \overset{\text{iid}}{\sim} \text{N}(a_{\delta_0}, b_{\delta_0}), \quad j = 1, \ldots, 4,$$

$$\sigma^2 \sim \text{IG}(a_\sigma, b_\sigma), \qquad \delta_{1j} \overset{\text{iid}}{\sim} \text{N}^+(a_{\delta_1} := 0, b_{\delta_1}), \quad j = 1, \ldots, 4,$$

$$R_i \,|\, \alpha, \boldsymbol{\beta}, u_{\xi_i}, \sigma^2, \mathbf{x}_i \overset{\text{ind}}{\sim} \text{N}\left(\alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + u_{\xi_i}, \sigma^2\right), \quad i = 1, \ldots, 1122.$$

3.3. $\mathcal{M}_3$: Modelo Latente de Riesgo LAFT con Efectos Espaciales Departamentales (MLR-LAFT-EED)

El Modelo 3 añade una extensión al Modelo 2 incorporando un efecto espacial departamental en la ecuación estructural del SEM. Esta modificación permite capturar dependencia espacial entre departamentos vecinos,

de manera que municipios ubicados en departamentos cercanos tiendan a presentar niveles de riesgo más similares que los esperados bajo dependencia.

Para ello, se propone un modelo espacial condicional autorregresivo intrínseco en la ecuación estructural, conocido como ICAR por sus siglas en inglés, el cual fue propuesto por Besag (1972) y desarrollado posteriormente en Besag, York y Mollié (1991). Específicamente, modelamos

$$R_i \,|\, \alpha, \boldsymbol{\beta}, \psi_{\xi_i}, \sigma^2, \mathbf{x}_i \overset{\text{ind}}{\sim} \mathrm{N}\left(\alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + u_{\xi_i}, \sigma^2\right),$$

donde ξ_i es definida en §§3.2 y ψ_{ξ_i} representa el efecto espacial asociado al departamento al que pertenece el i-ésimo municipio.

Para incorporar dependencia espacial entre departamentos, se introduce el vector de efectos espaciales $\boldsymbol{\psi} := (\psi_1, \ldots, \psi_{33})$, y se asume que estos efectos siguen la distribución normal del modelo ICAR:

$$\psi_d \,|\, \boldsymbol{\psi}_{-d}, \omega^2 \sim \mathrm{N}\left(\frac{\sum_{\ell \sim d} \psi_\ell}{m_d}, \frac{\omega^2}{m_d}\right),$$

donde $\boldsymbol{\psi}_{-d}$ es el 32-vector de todos los efectos departamentales excepto ψ_d, $m_d = \sum_{\ell=1}^{33} w_{d,\ell}$ es el número de departamentos vecinos del d-ésimo departamento, $\ell \sim d$ denota que los departamentos ℓ y d comparten frontera y $\mathbf{W} := [w_{d,\ell}]_{33\times 33}$ es la matriz de vecindad del modelo ICAR, para la cual $w_{d,\ell} = 1$ si $d \sim \ell$ y $w_{d,\ell} = 0$ en caso contrario. Esta especificación induce suavizamiento espacial en el sentido de que cada efecto departamental espacial tiende a ser cercano al promedio de los efectos de sus vecinos.

Nuevamente, por motivos de identificabilidad, fijamos restricciones: Adicional a las que ya teníamos en los Modelos 1 y 2, establecemos

$$\sum_{d=1}^{33} \psi_d = 0,$$

que se logra en el muestreador de Gibbs actualizando ψ_d como $\psi_d - \bar{\psi}$ y α como $\alpha + \bar{\psi}$, con $\bar{\psi} := \frac{1}{33}\sum_{d=1}^{33} \psi_d$, lo cual nos permite fijar una representación paramétrica única para el Modelo 3.

- **Distribución muestral**

  Debido a que la ecuación de medición se mantiene inalterada ante la incorporación del modelo ICAR, la distribución muestral del Modelo 3 es la misma dada en (3.2):

  $$y_{i,j} \,|\, R_i, \mu_j, \lambda_j, \phi_j, \delta_{0j}, \delta_{1j} \overset{\text{ind}}{\sim} \text{ZIGamma}\left(\pi_{i,j}, \phi_j, \frac{\phi_j}{\mu_{i,j}}\right), \quad y_{i,j} \in [0, \infty)$$

  para todo $i = 1, \ldots, 1122$ y para todo $j = 1, \ldots, 4$, donde

  $$\text{logit}(\pi_{i,j}) := \delta_{0j} - \delta_{1j} R_i \qquad \text{y} \qquad \ln(\mu_{i,j}) := \mu_j + \lambda_j R_i.$$

  En efecto, la extensión conserva la estructura básica del modelo original e incorpora de manera explícita la estructura geográfica del país en la modelación del riesgo latente.

- **Distribución previa**

  La distribución previa del modelo es una extensión de la del Modelo 1, salvo que se añaden nuevos parámetros y se modifica la previa de los R_i:

$$\alpha \sim \mathrm{N}\left(a_\alpha, b_\alpha\right),$$

$$\boldsymbol{\beta} \sim \mathrm{N}_4\left(\boldsymbol{\beta}_0, \mathbf{B}_0\right),$$

$$\omega^2 \sim \mathrm{IG}\left(a_\omega, b_\omega\right),$$

$$\psi_d \,|\, \boldsymbol{\psi}_{-d}, \omega^2 \sim \mathrm{N}\left(\tfrac{\sum_{\ell \sim d} \psi_\ell}{m_d}, \tfrac{\omega^2}{m_d}\right), \quad \boldsymbol{\psi}_{-d} \in \mathbb{R}^{32}, \; d = 1, \ldots, 33,$$

$$\sigma^2 \sim \mathrm{IG}\left(a_\sigma, b_\sigma\right),$$

$$\mu_j \overset{\text{iid}}{\sim} \mathrm{N}\left(a_\mu, b_\mu\right), \quad j = 1, \ldots, 4,$$

$$\lambda_j \overset{\text{iid}}{\sim} \mathrm{N}\left(a_\lambda, b_\lambda\right), \quad j = 2, 3, 4,$$

$$\phi_j \overset{\text{iid}}{\sim} \mathrm{Gamma}\left(a_\phi, b_\phi\right), \quad j = 1, \ldots, 4,$$

$$\delta_{0j} \overset{\text{iid}}{\sim} \mathrm{N}\left(a_{\delta_0}, b_{\delta_0}\right), \quad j = 1, \ldots, 4,$$

$$\delta_{1j} \overset{\text{iid}}{\sim} \mathrm{N}^+\left(a_{\delta_1} := 0, b_{\delta_1}\right), \quad j = 1, \ldots, 4,$$

$$R_i \,|\, \alpha, \boldsymbol{\beta}, \psi_{\xi_i}, \sigma^2, \mathbf{x}_i \overset{\text{ind}}{\sim} \mathrm{N}\left(\alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + \psi_{\xi_i}, \sigma^2\right), \quad i = 1, \ldots, 1122.$$

3.4. Resumen de los modelos

A manera de resumen, en la Tabla 1 se muestran los vectores de parámetros y de hiperparámetros por cada uno de los tres modelos, así como sus respectivas cantidades de componentes.

Modelo			Cantidad
$\mathcal{M}_1$	**Par.:**	$\left(R_i, \alpha, \boldsymbol{\beta}, \sigma^2, \mu_j, \lambda_j, \phi_j, \delta_{0j}, \delta_{1j}\right)$	1147
	Hip.:	$(a_\alpha, b_\alpha, \boldsymbol{\beta}_0, \mathbf{B}_0, a_\sigma, b_\sigma, a_\mu, b_\mu, a_\lambda, b_\lambda, a_\phi, b_\phi, a_{\delta_0}, b_{\delta_0}, a_{\delta_1}, b_{\delta_1})$	28
$\mathcal{M}_2$	**Par.:**	$\left(R_i, \alpha, \boldsymbol{\beta}, \omega^2, u_d, \sigma^2, \mu_j, \lambda_j, \phi_j, \delta_{0j}, \delta_{1j}\right)$	1181
	Hip.:	$(a_\alpha, b_\alpha, \boldsymbol{\beta}_0, \mathbf{B}_0, a_\omega, b_\omega, a_u, a_\sigma, b_\sigma, a_\mu, b_\mu, a_\lambda, b_\lambda, a_\phi, b_\phi, a_{\delta_0}, b_{\delta_0}, a_{\delta_1}, b_{\delta_1})$	31
$\mathcal{M}_3$	**Par.:**	$\left(R_i, \alpha, \boldsymbol{\beta}, \omega^2, \psi_d, \sigma^2, \mu_j, \lambda_j, \phi_j, \delta_{0j}, \delta_{1j}\right)$	1181
	Hip.:	$(a_\alpha, b_\alpha, \boldsymbol{\beta}_0, \mathbf{B}_0, a_\omega, b_\omega, a_\sigma, b_\sigma, a_\mu, b_\mu, a_\lambda, b_\lambda, a_\phi, b_\phi, a_{\delta_0}, b_{\delta_0}, a_{\delta_1}, b_{\delta_1})$	30

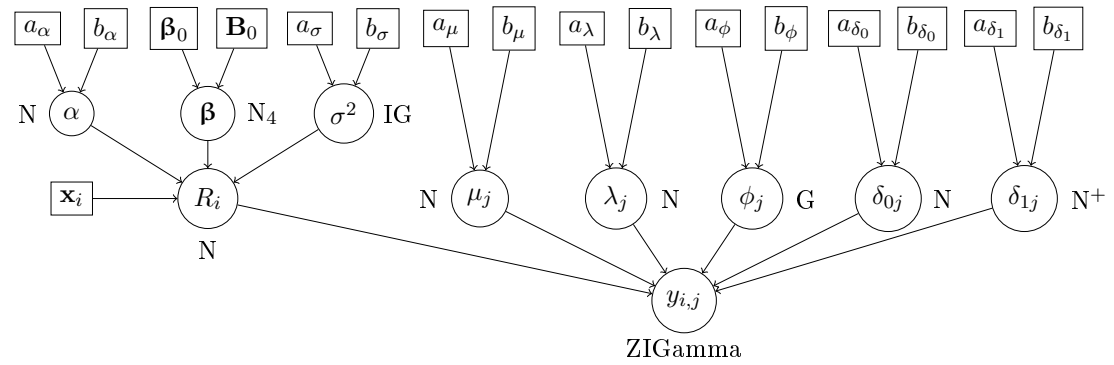
TABLA 1. Resumen de los parámetros e hiperparámetros de los modelos.

En la Tabla 1, los R_i suman 1122 parámetros porque son tantos como municipios registrados hay en la base de datos. Los u_d, así como los ψ_d, suman 33 parámetros porque son tantos como departamentos hay en el actual código DIVIPOLA. Los parámetros con subíndice j —que son los del modelo de medición, el cual involucra los indicadores observados $y_{\bullet,j}$— corresponden a 4 por cada uno, salvo las cargas factoriales λ_j, donde $\lambda_1 := 1$ por motivos de identificabilidad. Además, $\boldsymbol{\beta}$ posee 4 coeficientes de regresión, uno por cada índice estructural $x_{\bullet,j}$. Los demás parámetros indicados en los vectores de parámetros de $\mathcal{M}_1$, $\mathcal{M}_2$ y $\mathcal{M}_3$ corresponden a un parámetro por término.

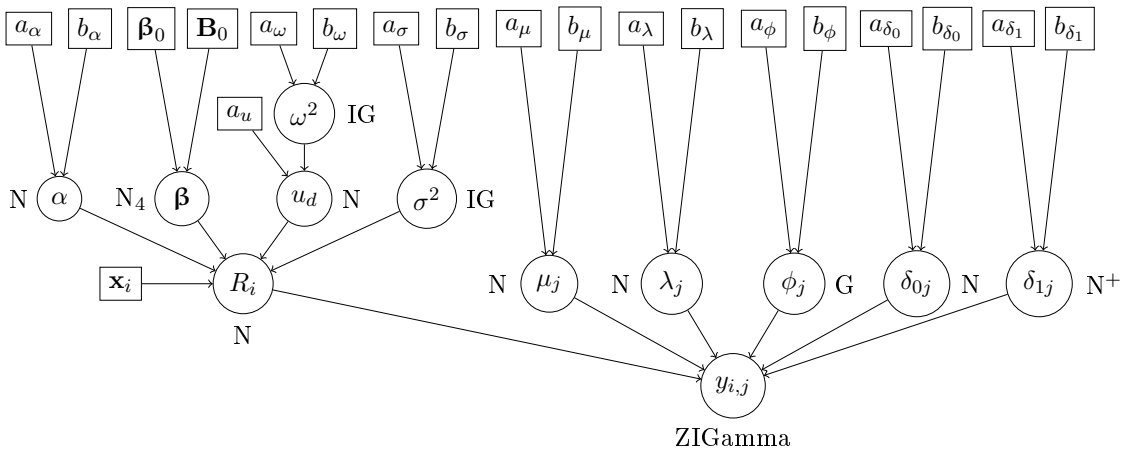
En cuanto a los hiperparámetros, se fijan a_{δ_1} y a_u desde la construcción del modelo con el valor 0. En cuanto a $\boldsymbol{\beta}_0$ y $\mathbf{B}_0$, éstos poseen 4 y 10 hiperparámetros respectivamente dentro (los 10 hiperparámetros de $\mathbf{B}_0 \in \mathbb{R}^{4\times4}$ corresponden a los elementos libres de la matriz). Los demás hiperparámetros indicados corresponden a un solo elemento.

Según la construcción de cada modelo, podemos observar las relaciones de dependencia, estructuras jerárquicas y mecanismos aleatorios asociados a los parámetros de $\mathcal{M}_1$, $\mathcal{M}_2$ y $\mathcal{M}_3$ en la Figura 10 a través

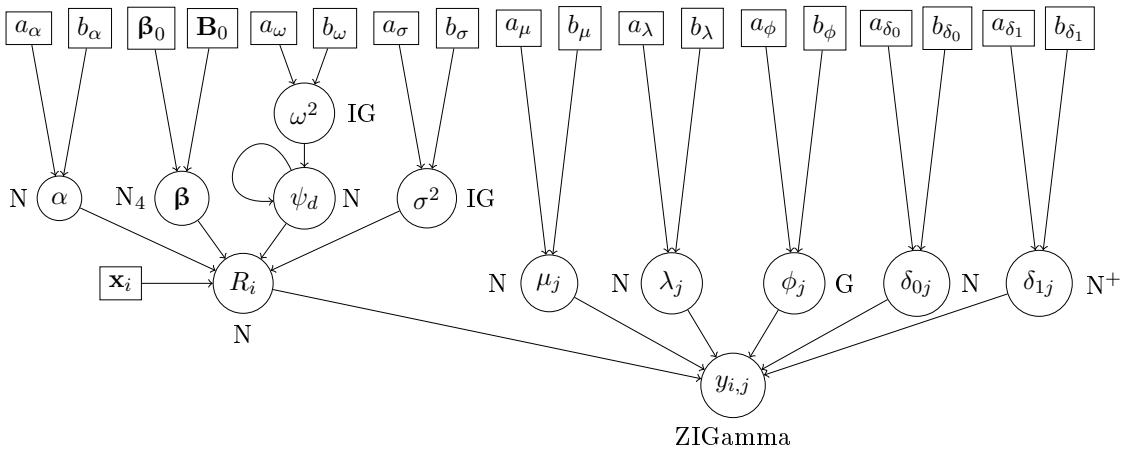
de grafos acíclicos dirigidos.



(a) Grafo acíclico dirigido asociado al modelo MLR-LAFT.



(b) Grafo acíclico dirigido asociado al modelo MLR-LAFT-ED.



(c) Grafo acíclico dirigido asociado al modelo MLR-LAFT-EED.

FIGURA 10. Grafos acíclicos dirigidos asociados a los tres modelos Bayesianos involucrados en el caso de estudio.

4. Implementación y diagnóstico de los modelos

Los tres modelos fueron ajustados mediante tres muestreadores de Gibbs respectivos (cf. Sosa Martínez, 2026a) construidos a partir de las distribuciones condicionales completas de los dos modelos, las cuales se exponen brevemente en el Apéndice C. Para cada muestreador, se ejecutó el algoritmo con un total de 110000 iteraciones, de las cuales las primeras 10000 se tomaron como periodo de calentamiento (*burn-in*), y se iban almacenando muestras únicamente cada 10 iteraciones (*thinning*) para reducir la autocorrelación en todas las cadenas; resultando esto en un arreglo de 10000 filas con 1148 columnas para $\mathcal{M}_1$ y 1182 para $\mathcal{M}_2$ y $\mathcal{M}_3$, donde cada fila almacenada contiene una actualización de los parámetros involucrados en cada modelo, adicionando al final el cálculo de la log-verosimilitud por cada iteración, que, en el caso de la Gamma cero-inflada como distribución muestral de los tres modelos, resulta en una suma entre la log-verosimilitud de la componente Bernoulli y la log-verosimilitud de la componente Gamma.

Como puede apreciarse en el Apéndice C, ninguna de las distribuciones condicionales completas de los parámetros involucrados en la ecuación de medición del SEM pertenece a una familia conocida de distribuciones de probabilidad; hablamos de las condicionales completas de los 4 μ_j, los 3 λ_j, los 4 ϕ_j, los 4 δ_{0j}, los 4 δ_{1j} y los 1122 R_i en cualquiera de los tres modelos Bayesianos. Esto debido a que la distribución muestral Gamma cero-inflada involucra dos modelos lineales generalizados subyacentes, aparte de que no posee una familia conjugada.

Por esta razón, los tres muestreadores de Gibbs incluyen una calibración del algoritmo de Metropolis adaptativo (id., 2026b) para generar muestras de las distribuciones condicionales completas de los parámetros con soporte en $\mathbb{R}$: μ_j, λ_j, δ_{0j} y R_i (1133 pasos de Metropolis por iteración), y una calibración del algoritmo general de Metropolis-Hastings adaptativo para los parámetros con soporte en $\mathbb{R}^+$: ϕ_j, δ_{1j} (8 pasos de Metropolis-Hastings adicionales por iteración); esto para los tres modelos SEM bayesianos, pues, como se mencionó en §§3.2-3.3, la ecuación de medición permaneció inalterada ante transformaciones de la media de los riesgos latentes conforme modificábamos el Modelo 1 en los modelos 2 y 3, luego los parámetros que no se actualizan directamente con los R_i no incorporan cambios en sus condicionales completas (gráficamente, esto también se puede notar en los DAG's de §§3.4).

Para el algoritmo de Metropolis, simulamos propuestas de la distribución normal, y para Metropolis-Hastings, propuestas de la log-normal. Para la decisión de aceptar o rechazar nuevas propuestas, se contrastó el cociente de los respectivos *log-kernels* de las condicionales completas con un valor simulado de la distribución uniforme continua entre 0 y 1 en cada paso de Metropolis o Metropolis-Hastings, siguiendo el resto de procedimientos técnicos dados en (id., 2026b). Las 1141 tasas de aceptación resultantes para cada ejecución de los muestreadores quedan diligenciadas en el Apéndice

4.1. Elección de los hiperparámetros

Teniendo en cuenta la información técnica de la Prueba, $\mathcal{M}_1$ se ajustó utilizando los siguientes valores fijos para los hiperparámetros:

$$\mu_\mu := 250, \quad \sigma_\mu^2 := 1, \quad \nu_\tau := 2, \quad \sigma_\tau^2 := 2, \quad a_\sigma := \frac{1}{2}, \quad b_\sigma := \frac{1}{2},$$

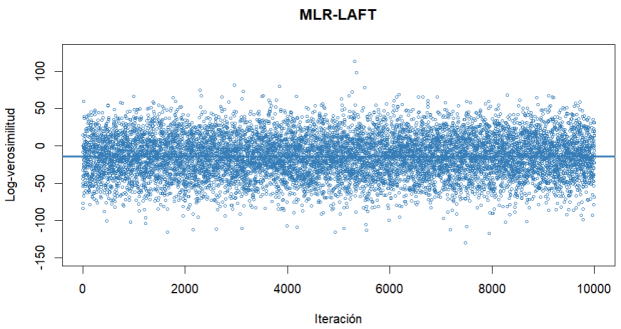
$$a_{\alpha_\kappa} := 2, \quad b_{\alpha_\kappa} := 140, \quad a_{\beta_\kappa} := 250000, \quad b_{\beta_\kappa} := \frac{1}{2}, \quad \nu_\sigma := 2, \quad \nu_\kappa := 2.$$

Valores iniciales para los parámetros, que se actualizan en la primera iteración del algoritmo, fueron establecidos según algunos estadísticos muestrales; es decir, empleando como insumo información de la base de datos construida.

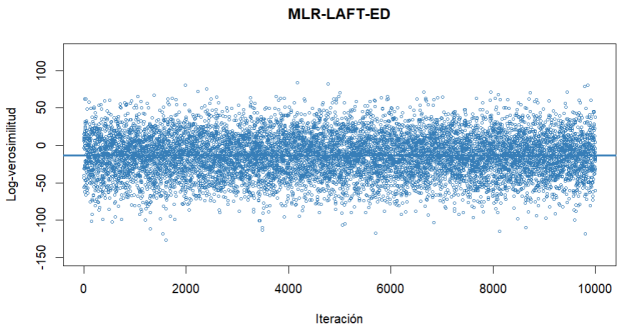
4.2. Convergencia

Con el fin de evaluar la calidad de las simulaciones, un primer paso es analizar la estacionariedad de las cadenas de log-verosimilitud, lo cual permite darnos cuenta de cuándo las muestras generadas por los muestreadores de Gibbs aún no han convergido a la distribución posterior de los modelos.

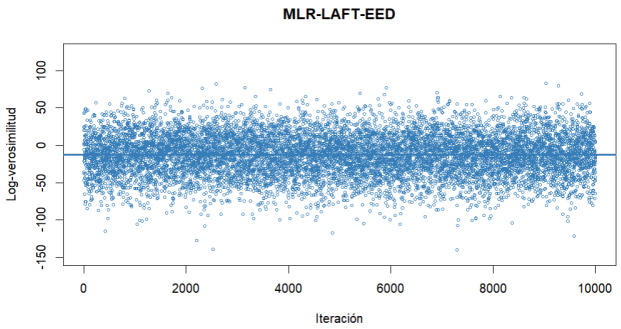
En la Figura 11, puede apreciarse la estacionariedad de la log-verosimilitud generada por los muestreadores de los tres modelos.



(a) Cadena de log-verosimilitud del modelo $\mathcal{M}_1$: MLR-LAFT.



(b) Cadena de log-verosimilitud del modelo $\mathcal{M}_2$: MLR-LAFT-ED.



(c) Cadena de log-verosimilitud del modelo $\mathcal{M}_3$: MLR-LAFT-EED.

FIGURA 11. Cadenas de log-verosimilitud obtenidas del ajuste de $\mathcal{M}_1$, $\mathcal{M}_2$ y $\mathcal{M}_3$. Cada punto corresponde al cálculo de la log-verosimilitud gamma cero-inflada según las muestras simuladas en su respectiva iteración. Se obtienen, por tanto, 10000 valores para la log-verosimilitud resultantes de las tres ejecuciones de los muestreadores de Gibbs. La línea horizontal en cada gráfico representa la media aritmética de estos valores; para el caso de $\mathcal{M}_1$, es -13.79846; para $\mathcal{M}_2$, -13.09654; y para $\mathcal{M}_3$, -12.70501.

4.3. Tamaños efectivos de muestra

El tamaño efectivo de muestra para cada uno de los parámetros ajustados en los muestreadores de Gibbs representa la cantidad de muestras independientes e idénticamente distribuidas que contendrían la misma información que la cadena que fue simulada para dicho parámetro (Sosa Martínez, 2025). Es decir, tomando como ejemplo a los parámetros de $\mathcal{M}_1$, obtenemos, al final de la ejecución de su respectivo algoritmo, un tamaño efectivo de muestra para α según sus simulaciones almacenadas, otro tamaño efectivo de muestra para β_1 (la primera componente del parámetro vectorial $\boldsymbol{\beta}$), y así sucesivamente hasta R_{1122}, que es el último parámetro del modelo MLR-LAFT almacenado en el arreglo-salida de los muestreadores.

Para los parámetros que pertenecen a una familia grande, como los R_i o los u_d, se resumen sus tamaños efectivos de muestra mediante un reporte de seis números clave en la Tabla 3; y para los parámetros

únicos o pertenecientes a familias de cuatro o menos (para los cuales un resumen de seis números resulta inoficioso), los tamaños efectivos de muestra se sintetizan en una tabla aparte de la de resúmenes de seis números, en la Tabla 2. Cabe recordar que se almacenaron 10000 muestras por parámetro tras un proceso de *burn-in* y *thinning*.

Modelo	Parámetro												
MLR-LAFT	α	β_1	β_2	β_3	β_4	σ^2	μ_1	μ_2	μ_3	μ_4	λ_2	λ_3	λ_4
	3415	8582	3593	7096	8344	2048	3810	9067	8288	4283	2309	1633	2890
	ϕ_1	ϕ_2	ϕ_3	ϕ_4	δ_{01}	δ_{02}	δ_{03}	δ_{04}	δ_{11}	δ_{12}	δ_{13}	δ_{14}	
	3570	6869	3959	5636	7751	3415	4200	2608	7025	3360	4084	2026	
MLR-LAFT-ED	α	β_1	β_2	β_3	β_4	σ^2	μ_1	μ_2	μ_3	μ_4	λ_2	λ_3	λ_4
	4329	5849	3393	8474	6990	2112	4838	9348	7142	4483	2406	1568	2907
	ϕ_1	ϕ_2	ϕ_3	ϕ_4	δ_{01}	δ_{02}	δ_{03}	δ_{04}	δ_{11}	δ_{12}	δ_{13}	δ_{14}	ω^2
	3956	7571	3518	5241	7360	3773	3928	2383	6619	3723	3867	2047	8055
MLR-LAFT-EED	α	β_1	β_2	β_3	β_4	σ^2	μ_1	μ_2	μ_3	μ_4	λ_2	λ_3	λ_4
	5384	6112	4252	7966	8073	2294	4425	9203	7589	3956	2291	1582	2786
	ϕ_1	ϕ_2	ϕ_3	ϕ_4	δ_{01}	δ_{02}	δ_{03}	δ_{04}	δ_{11}	δ_{12}	δ_{13}	δ_{14}	ω^2
	3591	6961	3321	4857	7767	3568	4507	2685	7016	3462	4439	2176	7121

TABLA 2. Tamaños efectivos de muestra para los parámetros únicos de los tres modelos SEM Bayesianos.

Modelo	Parámetros	Mínimo	Cuartil 1	Mediana	Media	Cuartil 3	Máximo
MLR-LAFT	R_i	6421	9316	9586	9542	10000	12056
MLR-LAFT-ED	R_i	6814	9136	9479	9405	9716	11334
	u_d	3891	8319	8821	8443	9173	9668
MLR-LAFT-EED	R_i	6893	9128	9478	9390	9697	12663
	ψ_d	4169	8526	8818	8518	9351	10000

TABLA 3. Resumen de los tamaños efectivos de muestra para cada familia de parámetros en los tres modelos SEM Bayesianos, donde $i = 1, \ldots, 1122$ y $d = 1, \ldots, 33$.

4.4. Criterio de información de la devianza (DIC)

En la Table 4, se muestran los resultados obtenidos por nuestros modelos en materia del criterio de información de la devianza (DIC). Los valores del DIC se calcularon siguiendo la definición de Spiegelhalter et al. (2002) en Sosa Martínez (2026b), considerando los efectos latentes R_i ($i = 1, \ldots, 1122$) como parámetros del modelo (i.e., un DIC condicional).

Modelo	$\ln p(\mathbf{Y} \mid \widehat{\boldsymbol{\theta}}_{\text{Bayes}})$	$\frac{1}{B}\sum_{b=1}^{B} \ln p(\mathbf{Y} \mid \boldsymbol{\theta}^{(b)})$	p_{DIC}	DIC
MLR-LAFT	417.7472	-13.7985	863.0913	**890.6883**
MLR-LAFT-ED	335.1858	-13.0965	696.5647	**722.7578**
MLR-LAFT-EED	335.6794	-12.7050	696.7688	**722.1789**

TABLA 4. Comparación del DIC para los tres modelos SEM bayesianos ajustados, reportando además la log-verosimilitud evaluada en la media posterior de los parámetros, la media posterior de log-verosimilitud y el número efectivo de parámetros p_{dic}.

Para el modelo latente de riesgo de LAFT, se obtuvo un **dic** de 890.6883; y para el modelo latente con efectos departamentales, de 722.7578. Es claro que el segundo modelo tiene una complejidad efectiva considerablemente menor, lo cual era de esperarse al introducir los u_d en el modelo de los riesgos latentes original; i.e.,

$$R_i = \alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + u_{\psi_i} + \varepsilon_i.$$

La actualización del Modelo 1 en el Modelo 2 plantea que municipios pertenecientes a un mismo departamento comparten parte de la información, con lo cual los R_i ya no tienen que explicar individualmente toda la heterogeneidad. Dicho de otro modo, los 33 efectos departamentales están absorbiendo variabilidad que antes tenían que absorber los 1122 factores latentes individualmente. Esto redunda en la reducción del número efectivo de parámetros (p_{dic}), que en este caso fue de 863 a 697. De esta manera, bajo el criterio de información de la devianza, MLR-LAFT-ED es un modelo más parsimonioso que MLR-LAFT.

Por otro lado, la incorporación de una estructura espacial ICAR en el Modelo 3 sobre los efectos aleatorios departamentales produjo una reducción del DIC de 722.7578 a 722.1789, diferencia insuficiente para considerar que el modelo espacial ofrece una mejora apreciable en el equilibrio entre ajuste y complejidad. En consecuencia, la mayor parte de la dependencia entre municipios parece quedar adecuadamente capturada mediante efectos departamentales no estructurados introducidos en MLR-LAFT-ED.

4.5. Criterio de información de Watanabe-Akaike (WAIC)

La Tabla 5 presenta los valores del criterio de información de Watanabe-Akaike (WAIC) para nuestros tres modelos considerados. A diferencia del DIC, cuya penalización por complejidad se obtiene a partir

Modelo	Densidad predictiva puntual logarítmica	p_{WAIC}	WAIC
MLR-LAFT	162.0402	351.6772	**379.2742**
MLR-LAFT-ED	149.7246	325.6422	**351.8353**
MLR-LAFT-EED	150.0917	325.5934	**351.0034**

TABLA 5. Comparación del WAIC para los tres modelos SEM bayesianos ajustados, reportando además la densidad predictiva puntual logarítmica (lppd) y el número efectivo de parámetros p_{waic}.

de la diferencia entre la log-verosimilitud evaluada en las medias posteriores y la log-verosimilitud media (cf. Sosa Martínez, 2026b), el WAIC calcula tanto el ajuste como la complejidad efectiva, promediando sobre toda la distribución posterior y evaluando la contribución predictiva de cada observación. Por esta razón, el WAIC se considera un criterio *plenamente Bayesiano* y generalmente más adecuado para modelos jerárquicos con efectos latentes, como los modelos SEM propuestos en este trabajo (Gelman, Hwang y Vehtari, 2014).

Los resultados obtenidos muestran una reducción importante del WAIC al incorporar efectos departamentales en MLR-LAFT-ED (379.2742 frente a 351.8353), lo que evidencia una mejora sustancial en el equilibrio entre ajuste y capacidad predictiva respecto al modelo base (MLR-LAFT). Posteriormente, la incorporación de una estructura espacial ICAR en MLR-LAFT-EEF produjo una disminución adicional del WAIC hasta llegar casi a 351; sin embargo, la diferencia respecto a MLR-LAFT-ED fue inferior a una unidad, valor que se considera insuficiente para establecer una superioridad predictiva concluyente entre ambos modelos (id.). En consecuencia, los resultados indican que la mayor ganancia predictiva proviene de modelar explícitamente la heterogeneidad departamental, mientras que la incorporación de dependencia espacial entre departamentos aporta únicamente una mejora minúscula.

4.6. Desempeño predictivo

Como parte de la evaluación del desempeño predictivo de los tres modelos propuestos, se utilizó la distribución predictiva posterior para generar predicciones de los indicadores observados. A partir de cada iteración de los muestreadores de Gibbs, se simuló una realización de cada variable $y_{i,j}$ condicionada a los valores muestreados de los parámetros y de las variables latentes. Posteriormente, para cada municipio e indicador, se calculó la media de dichas simulaciones, obteniendo las predicciones posteriores $\widehat{y}_{i,j}$. Con base en éstas, se evaluó la capacidad predictiva de cada modelo mediante tres medidas: el error cuadrático medio (MSE), el error absoluto medio (MAE) y el coeficiente de determinación (R^2). Los resultados se sintetizan en las Tablas 6-8.

Medida	Indicador observado			
	$y_{\bullet,1}$	$y_{\bullet,2}$	$y_{\bullet,3}$	$y_{\bullet,4}$
MSE	0.198	0.090	0.157	0.745
MAE	0.237	0.230	0.277	0.415
R^2	0.452	0.732	0.708	-0.052

TABLA 6. Cálculo del error cuadrático medio, error absoluto medio y coeficiente de determinación para cada uno de los cuatro indicadores observados usando las predicciones del Modelo 1.

Medida	Indicador observado			
	$y_{\bullet,1}$	$y_{\bullet,2}$	$y_{\bullet,3}$	$y_{\bullet,4}$
MSE	0.231	0.100	0.163	0.800
MAE	0.247	0.245	0.281	0.414
R^2	0.360	0.702	0.697	-0.129

TABLA 7. Cálculo del error cuadrático medio, error absoluto medio y coeficiente de determinación para cada uno de los cuatro indicadores observados usando las predicciones del Modelo 2.

Medida	Indicador observado			
	$y_{\bullet,1}$	$y_{\bullet,2}$	$y_{\bullet,3}$	$y_{\bullet,4}$
MSE	0.234	0.100	0.163	0.800
MAE	0.248	0.245	0.281	0.415
R^2	0.352	0.702	0.697	-0.131

TABLA 8. Cálculo del error cuadrático medio, error absoluto medio y coeficiente de determinación para cada uno de los cuatro indicadores observados usando las predicciones del Modelo 3.

Las medidas de desempeño predictivo obtenidas muestran que los tres modelos presentan un comportamiento muy similar. Para los cuatro indicadores observados, los valores de MSE y MAE fueron relativamente bajos, lo que indica que, en promedio, las predicciones posteriores se encuentran cercanas a los valores observados. En particular, el MSE penaliza con mayor intensidad los errores de gran magnitud debido a que considera el cuadrado de las diferencias entre observaciones y predicciones, mientras que el MAE proporciona una medida más robusta del error promedio al considerar únicamente el valor absoluto de dichas diferencias. En efecto, valores pequeños de ambas métricas constituyen evidencia de una adecuada capacidad predictiva.

Por su parte, el coeficiente de determinación R^2 cuantifica la proporción de la variabilidad observada que es explicada por las predicciones de cada modelo. Para los tres primeros indicadores (Terrorismo, Conflicto y Criminalidad) se obtuvieron valores comprendidos aproximadamente entre 0.35 y 0.73, lo que sugiere un desempeño predictivo satisfactorio. En particular, el segundo y el tercer indicador alcanzaron valores cercanos a 0.70, indicando que los modelos logran reproducir una parte importante de su variabilidad observada.

En contraste con lo anterior, el cuarto indicador (Narcotráfico) produjo un valor negativo de R^2 en los tres modelos. Un R^2 negativo no implica que el modelo sea incorrecto; sino que significa que, para ese indicador, las predicciones presentan un error cuadrático mayor que el que se obtendría utilizando simplemente la media muestral como predictor constante. Este resultado sugiere que la estructura del cuarto indicador es considerablemente más difícil de capturar mediante el modelo propuesto. No obstante, los autores advertimos que este resultado debe interpretarse con cautela, pues las restantes medidas de desempeño (MSE y MAE) en los tres modelos para dicho indicador observado no presentan valores desproporcionadamente altos respecto a los demás.

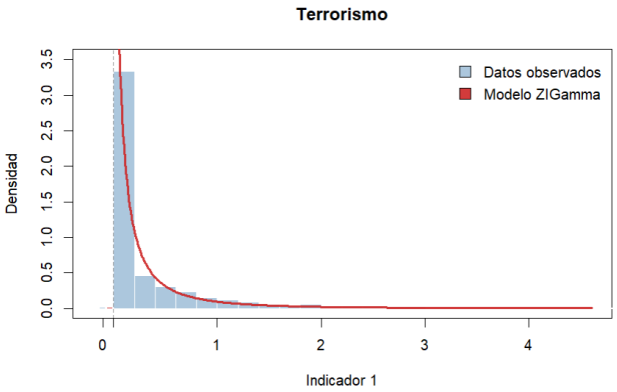
De forma complementaria, se realizó una validación gráfica mediante *posterior predictive checks*. Para cada indicador, se comparó la distribución empírica de los $y_{i,j}$ observados con la distribución predictiva posterior inducida por el Modelo 1 (omitimos para los Modelos 2 y 3 puesto que son muy similares los resultados). En particular, se representó la componente continua ($y_{i,j} > 0$) mediante un histograma de los valores positivos observados y la densidad predictiva posterior correspondiente, obtenida como una mezcla de distribuciones Gamma ponderadas por las probabilidades posteriores de pertenecer a la componente continua. Adicionalmente, se comparó la proporción observada de valores nulos con la probabilidad de cero estimada por el modelo, representando ambas como masas puntuales en el origen ($y_{i,j} = 0$). Dichos gráficos pueden apreciarse en la Figura 12.

Nótese que el *posterior predictive check* en la Figura 12(d) muestra que el Modelo 1 (y los otros dos también aunque omitamos sus gráficos) reproduce adecuadamente tanto la proporción de observaciones nulas como la forma general de la distribución continua. En consecuencia, el bajo desempeño del R^2 parece deberse más a la elevada complejidad inherente de este indicador, caracterizado por una importante concentración de ceros y una distribución positiva altamente asimétrica, que a una incapacidad general del modelo para representar su distribución.

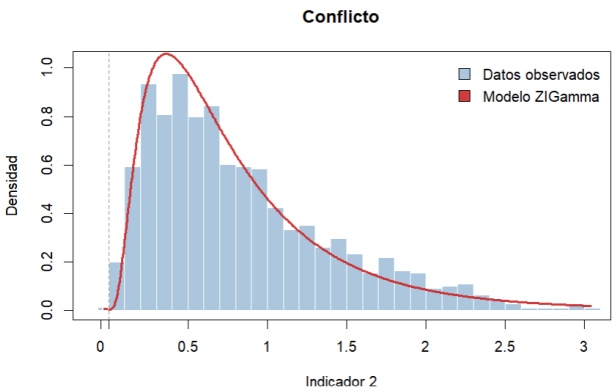
Hacemos aquí el comentario de que, como posibles líneas de trabajo futuro, podrían explorarse alternativas orientadas específicamente a mejorar el ajuste del cuarto indicador. Entre ellas se encuentran la incorporación de covariables adicionales que expliquen mejor su variabilidad, el uso de funciones de enlace o parametrizaciones alternativas para la componente Gamma, la adopción de distribuciones continuas con mayor flexibilidad en las colas (e.g., familias Gamma generalizadas o distribuciones de tipo *Generalized Beta*), o incluso la especificación de un modelo de medición diferente para dicho indicador dentro del marco SEM. Asimismo, podrían considerarse estructuras de dependencia espacial o temporal más complejas que permitan capturar heterogeneidad no explicada por el modelo actual.

En síntesis, los procedimientos expuestos en esta sección permiten evaluar, no sólo la precisión de las predicciones a través de medidas resumen, sino también la capacidad de los modelos para reproducir las principales características distribucionales de los datos, incluyendo simultáneamente la inflación de ceros, la forma de la distribución continua y el comportamiento de sus colas. En conjunto, las métricas cuantitativas y los *posterior predictive checks* proporcionan una evaluación integral del desempeño predictivo de los modelos considerados.

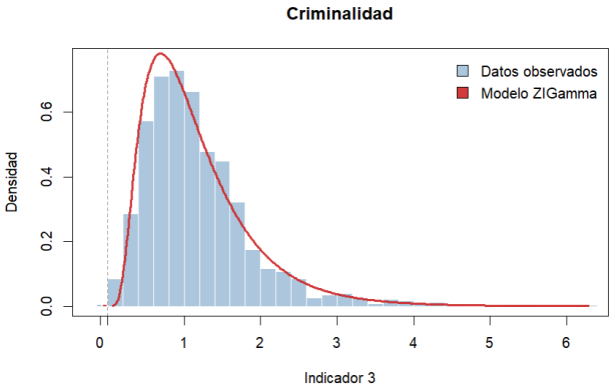
Un aspecto adicional que destacamos es que los tres modelos produjeron valores de MSE, MAE y R^2 prácticamente idénticos, lo que sugiere que la incorporación de efectos aleatorios departamentales (modelo MLR-ED) y posteriormente de la estructura espacial ICAR (MLR-EED) no modificó de manera apreciable la capacidad predictiva. Sin embargo, esos componentes sí mejoraron el ajuste global del modelo, como se reportó en §§4.4-4.5, según los criterios de información (DIC y WAIC). Ello indica que los efectos espaciales



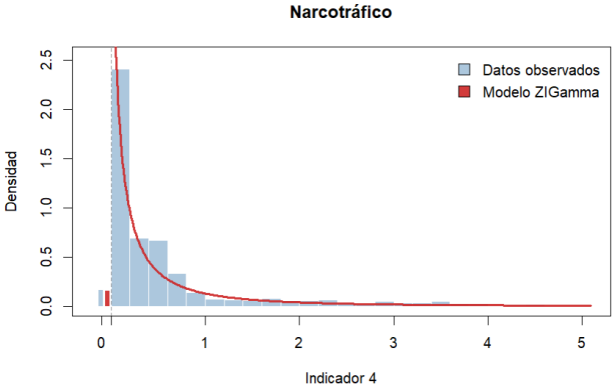
(a) Distribución predictiva posterior de $y_{\bullet,1}$ contra su histograma.



(b) Distribución predictiva posterior de $y_{\bullet,2}$ contra su histograma.



(c) Distribución predictiva posterior de $y_{\bullet,3}$ contra su histograma.



(d) Distribución predictiva posterior de $y_{\bullet,4}$ contra su histograma.

FIGURA 12. Validación gráfica del desempeño predictivo del Modelo 1 para los cuatro indicadores observados. En los cuatro gráficos, el eje vertical representa la densidad de probabilidad para la componente continua de la distribución, mientras que las barras ubicadas en el origen, a la izquierda de la línea vertical punteada, representan la probabilidad puntual de obtener una observación igual a cero bajo los datos observados y bajo la distribución predictiva posterior del modelo MLR-LAFT.

contribuyen principalmente a representar de forma más adecuada la estructura latente de los datos y la dependencia entre departamentos, por encima de incrementar la precisión de las predicciones puntuales de los indicadores observados.

Aunque las diferencias entre los tres modelos son reducidas según las métricas de desempeño predictivo, éstas muestran de forma consistente que el Modelo 1 obtiene los menores errores de predicción y los mayores valores del coeficiente de determinación para la mayoría de los indicadores. En consecuencia, desde una perspectiva estrictamente predictiva, el Modelo 1 ofrece el mejor desempeño.

5. Inferencia

5.1. Inferencia usando el Modelo MLR-LAFT-EED

Utilizando las muestras generadas para el modelo MLR-LAFT-EED, en esta parte presentamos la inferencia sobre los parámetros α, $\beta_1, \ldots, \beta_4$ y σ^2 en la Tabla 9, y sobre $\mu_1, \ldots, \mu_4$, $\lambda_2, \lambda_3, \lambda_4$ y $\phi_1, \ldots, \phi_4$ en la Tabla 10.

Parámetro	Media	Cuantil 0.025	Cuantil 0.975	Coeficiente de variación
α	-0.411	-0.535	-0.288	0.153
β_1	-0.738	-0.853	-0.627	0.079
β_2	0.770	0.644	0.900	0.085
β_3	1.266	0.879	1.658	0.159
β_4	0.471	0.395	0.549	0.083
σ^2	0.403	0.337	0.477	0.088

TABLA 9. Medias posteriores de los parámetros α, $\beta_1, \ldots, \beta_4$ y σ^2 con sus respectivos intervalos de credibilidad y coeficiente de variación usando muestras del Modelo 3.

Parámetro	Media	Cuantil 0.025	Cuantil 0.975	Coeficiente de variación
μ_1	-1.858	-1.930	-1.783	0.020
μ_2	-0.340	-0.368	-0.311	0.043
μ_3	0.048	0.026	0.069	0.231
μ_4	-1.404	-1.512	-1.295	0.039
λ_2	0.441	0.409	0.476	0.039
λ_3	0.381	0.352	0.412	0.040
λ_4	1.038	0.916	1.160	0.060
ϕ_1	0.976	0.885	1.076	0.050
ϕ_2	4.351	3.956	4.774	0.048
ϕ_3	8.138	7.237	9.103	0.059
ϕ^4	0.780	0.707	0.857	0.049

TABLA 10. Medias posteriores de los parámetros $\mu_1, \ldots, \mu_4$, $\lambda_2, \lambda_3, \lambda_4$ y $\phi_1, \ldots, \phi_4$ con sus respectivos intervalos de credibilidad y coeficiente de variación usando muestras del Modelo 3.

En términos generales, las distribuciones posteriores presentan intervalos de credibilidad relativamente estrechos y coeficientes de variación inferiores al 16 %, lo que indica una estimación precisa de todos los parámetros. La única excepción corresponde a μ_3, cuyo coeficiente de variación alcanza el 23.1 %, explicado principalmente por la cercanía de su media posterior al valor cero más que por una elevada incertidumbre absoluta.

En particular, el intercepto α presenta una media posterior de -0.411, con un intervalo de credibilidad del 95 % comprendido entre -0.535 y -0.288. Dado que dicho intervalo no contiene el cero, existe evidencia de un efecto basal negativo sobre el factor latente de riesgo. En cuanto a los coeficientes de regresión de la ecuación estructural $\beta_1, \ldots, \beta_4$, todos los intervalos de credibilidad excluyen igualmente el cero, indicando que las cuatro variables estructurales consideradas ejercen una influencia estadísticamente significativa sobre la variable latente de riesgo municipal: β_1 presenta un efecto negativo (-0.738), mientras que β_2, β_3 y β_4 muestran efectos positivos (0.770, 1.266 y 0.471 respectivamente). Entre ellos, β_3 exhibe la mayor magnitud, sugiriendo que el índice de contrabando ($x_{\bullet,3}$) es el predictor con mayor asociación positiva respecto al nivel latente de riesgo. Por el contrario, el índice de contexto estructural ($x_{\bullet,1}$) constituye el único factor con asociación negativa. Finalmente, la varianza residual del modelo estructural σ^2 presenta una media posterior 0.403, con un intervalo de credibilidad del 95 % entre 0.337 y 0.477. Este resultado indica que, aunque las variables estructurales explican una parte importante de la variabilidad del factor latente, persiste una componente residual de magnitud moderada atribuible a factores no incluidos explícitamente en el Modelo 3. Asimismo, el reducido coeficiente de variación asociado a este parámetro (8.8 %) evidencia una estimación posterior estable.

Ahora bien, los parámetros μ_j, $j = 1, \ldots, 4$, representan los interceptos del modelo de medición sobre

la escala logarítmica de la media de la componente Gamma. Sus estimaciones posteriores indican que, en ausencia del efecto del factor latente ($R_i = 0$), los cuatro indicadores observados presentan niveles medios diferentes. En particular, $\mu_1 = -1.858$ y $\mu_4 = -1.404$ corresponden a los menores niveles basales, mientras que $\mu_2 = -0.340$ y especialmente $\mu_3 = 0.048$ indican medias iniciales relativamente superiores. En todos los casos, los intervalos de credibilidad excluyen el valor cero, con excepción de μ_3, cuyo intervalo permanece muy próximo a dicho valor. Las cargas factoriales λ_j, $j = 2, 3, 4$, cuantifican la sensibilidad de cada indicador frente al incremento del factor latente de riesgo. Debido a la restricción de identificabilidad impuesta en el modelo (véase §§3.1), se fijó $\lambda_1 := 1$, tomando el primer indicador como referencia para la escala del factor latente. Las estimaciones posteriores muestran que los indicadores segundo y tercero presentan sensibilidades moderadas ($\lambda_2 = 0.441$ y $\lambda_3 = 0.381$), mientras que el cuarto indicador presenta una carga factorial muy cercana a la del indicador de referencia ($\lambda_4 = 1.038$). En consecuencia, un incremento unitario en el nivel latente de riesgo produce un efecto proporcionalmente mayor sobre el cuarto indicador que sobre los indicadores segundo y tercero. Todos los intervalos de credibilidad excluyen el valor cero, proporcionando evidencia de una asociación positiva entre el factor latente y cada uno de los indicadores observados. Finalmente, los parámetros ϕ_j, $j = 1, \ldots, 4$, describen la dispersión de la componente Gamma de cada indicador. Dado que, bajo esta parametrización (véase §§3.1), la varianza satisface $\mathrm{Var}(y_{i,j} \mid y_{i,j} > 0) = \mu_{i,j}^2/\phi_j$, valores mayores de ϕ_j corresponden a una menor dispersión relativa. En este sentido, los indicadores segundo y tercero presentan los mayores valores de precisión ($\phi_2 = 4.351$ y $\phi_3 = 8.138$), reflejando una variabilidad relativamente reducida alrededor de sus medias. Tal comportamiento puede apreciarse en la Figura 12(b-c). Por el contrario, los indicadores primero y cuarto exhiben valores cercanos a la unidad ($\phi_1 = 0.976$ y $\phi_4 = 0.780$), indicando una mayor dispersión relativa y, en consecuencia, una mayor heterogeneidad en sus observaciones positivas. Esto puede observarse en la Figura 12(a, d).

Los autores consideramos que el hecho de que el cuarto indicador presente simultáneamente una carga factorial elevada ($\lambda_4 \approx 1$) y el menor parámetro de precisión ($\phi_4 = 0.780$) es bastante consistente con $R^2 = -0.052, -0.129, -0.131$ en §§4.6, puesto que el modelo **sem** Bayesiano general estima que dicho indicador es el más sensible al nivel latente de riesgo, pero al mismo tiempo el más variable. Los resultados en R^2 pueden deberse a que la señal del factor latente de riesgo está acompañada de una variabilidad residual considerablemente grande.

5.2. Medias posteriores de los efectos espaciales departamentales

La Figura 13 presenta las medias posteriores de los efectos espaciales departamentales ψ_d, $d = 1, \ldots, 33$, estimados mediante el modelo ICAR (véase §§3.3). Estos efectos representan la variación espacial residual que permanece una vez descontado el efecto de las variables estructurales $\alpha, \beta_1, \ldots, \beta_4, \sigma^2$ y del componente latente R_i del modelo MLR-LAFT-EED. En consecuencia, un valor positivo de ψ_d indica que, en promedio, los municipios pertenecientes a dicho departamento presentan un nivel de riesgo superior al esperado a partir de las covariables incluidas en el modelo, mientras que un valor negativo sugiere un nivel de riesgo inferior al esperado.

Se observa una marcada heterogeneidad espacial entre departamentos, con valores que oscilan aproximadamente entre -1.6 y 1.3. Los departamentos representados en tonos amarillos presentan los mayores efectos espaciales positivos —en este caso, predominan Putumayo, Guaviare, Cauca y Caquetá—, indicando la presencia de factores territoriales no observados que incrementan el nivel latente de riesgo. Por el contrario, los departamentos representados en tonos púrpura oscuro exhiben efectos negativos —en este caso, predominan Santander, Cundinamarca y Boyacá—, asociados con factores espaciales que reducen el riesgo relativo respecto al esperado por el componente estructural del modelo.

Un aspecto particularmente relevante es que los departamentos geográficamente contiguos tienden a presentar efectos espaciales similares. Esta continuidad regional constituye precisamente el comportamien-

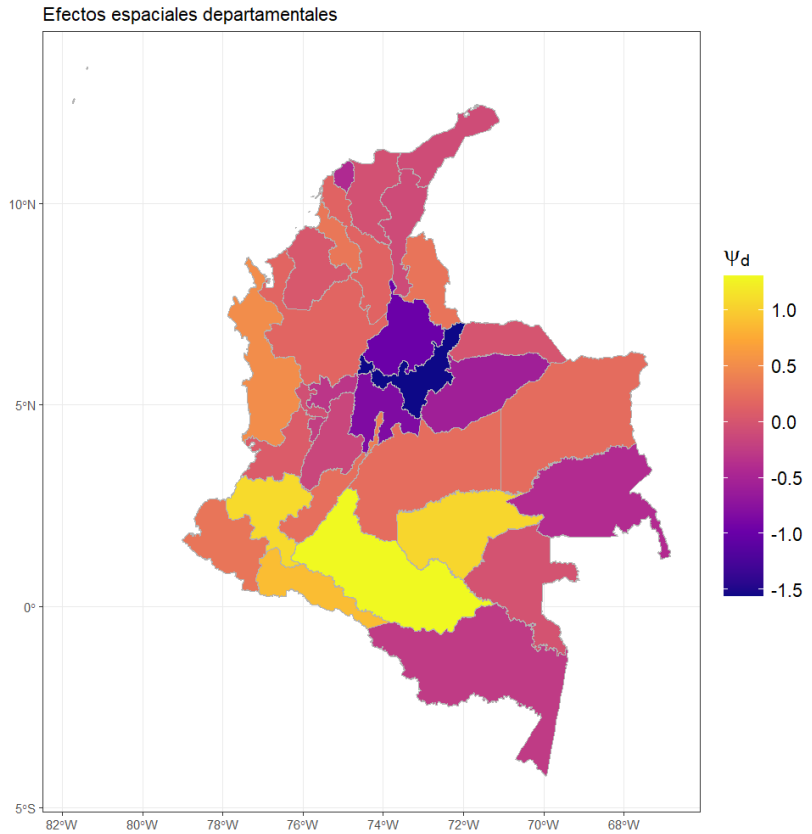


FIGURA 13. Mapa de Colombia a nivel departamental para las medias posteriores de los efectos espaciales departamentales ψ_d $(d = 1, \ldots, 33)$ a partir de las muestras del modelo MLR-LAFT-EED.

to esperado bajo un modelo ICAR (cf. Besag, York y Mollié, 1991), cuya especificación penaliza diferencias pronunciadas entre departamentos vecinos mediante la estructura de adyacencia introducida por la matriz de vecindades $\mathbf{W}$. En consecuencia, el mapa no presenta cambios abruptos entre regiones adyacentes, sino transiciones graduales entre efectos positivos y negativos, lo que evidencia que el modelo logró capturar adecuadamente la dependencia espacial existente entre los departamentos colombianos.

Finalmente, estos efectos espaciales no deben interpretarse como niveles absolutos de riesgo, sino como componentes residuales que resumen la influencia conjunta de factores departamentales no observados, como características particulares institucionales, económicas, sociales o geográficas, que no fueron incorporadas explícitamente mediante covariables en los índices estructurales $x_{\bullet,1}, \ldots, x_{\bullet,4}$. Su inclusión permite absorber parte de la variabilidad espacial residual, mejorando el ajuste global del modelo y proporcionando una representación más realista de la estructura espacial del fenómeno estudiado.

6. Clasificación según el riesgo de LAFT

6.1. Nivel promedio posterior del factor latente por departamento

Denotamos por ζ_d al riesgo departamental de LAFT en el d-ésimo departamento de Colombia, $d = 1, \ldots, 33$, cuya definición es

$$\zeta_d := \frac{1}{n_d} \sum_{i \,|\, \xi_i = d} R_i,$$

donde n_d es el número de municipios que pertenecen al departamento d. Empleando las muestras generadas para el modelo MLR-LAFT-EED, calculamos los riesgos departamentales por cada iteración y luego estimamos su respectiva media posterior $\widehat{\zeta}_1, \ldots, \widehat{\zeta}_{33}$. A partir de estas estimaciones de medidas agregadas de riesgo, ordenamos los departamentos en un ranking del mayor valor $\widehat{\zeta}$ al menor. Los resultados se sintetizan en la Figura 14.

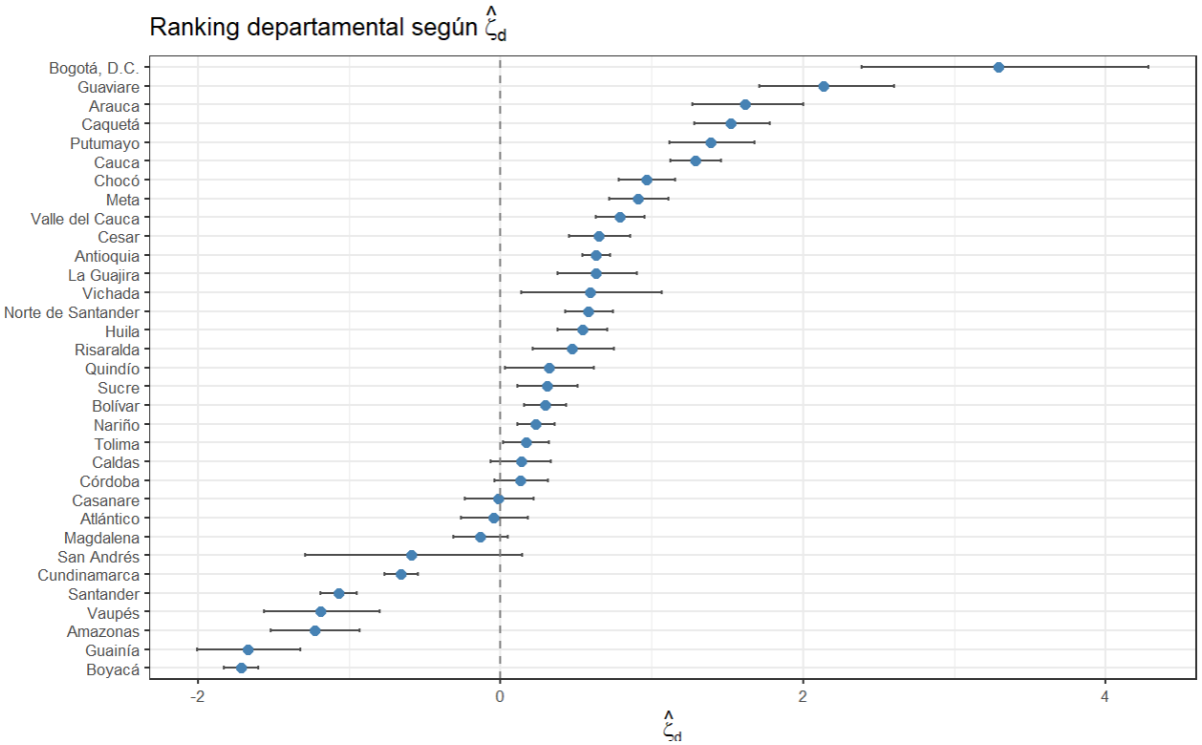


FIGURA 14. Ranking de los departamentos de Colombia a partir del nivel promedio posterior del factor latente $\widehat{\zeta}_d$ $(d = 1, \ldots, 33)$ empleando las muestras del modelo MLR-LAFT-EED. Los puntos azules indican las estimaciones puntuales y las barras horizontales muestran el respectivo intervalo de credibilidad al 95 %.

Lo primero que observamos es que las medias posteriores de ζ_d presentan una variación considerable entre departamentos: Mientras algunos alcanzan valores poco mayores a 3, otros se sitúan cerca a -2. Esto sugiere que el nivel promedio del factor latente de riesgo no es homogéneo en el territorio nacional, sino que existen diferencias importantes entre departamentos. En otras palabras, incluso después de modelar la información municipal a partir de los índices temáticos y de los ψ_d mediante el modelo ICAR, algunos departamentos concentran municipios con niveles de riesgo sistemáticamente más altos que otros.

Además, no parece existir un cambio gradual entre todos los departamentos. Ya desde aquí se distinguen tres grupos: Departamentos con riesgo de LAFT elevado, ubicados en la parte superior del ranking, como Bogotá D.C., Guaviare, Arauca, Caquetá, Putumayo, Cauca, etc.; departamentos intermedios, cuyos intervalos contienen o se encuentran muy próximos al cero, como Quindío, Sucre, Bolívar, Nariño, Tolima, Caldas, Córdoba, etc.; y departamentos con riesgo bajo, como Boyacá, Guainía, Amazonas, Vaupés, Santander y Cundinamarca. Sin duda, esto facilita identificar regiones prioritarias desde el punto de vista del lavado de activos y financiación del terrorismo.

Gracias a que los intervalos de credibilidad permiten valorar la incertidumbre de la estimación, tenemos mayor ventaja respecto a un ranking común y corriente. Por ejemplo, Bogotá aparece claramente en el primer lugar, pero su intervalo es mucho más amplio que el de la mayoría de departamentos; esto probablemente obedece a que el distrito capital constituye un único municipio dentro de los tres modelos

SEM Bayesianos, de manera que $\zeta_3 = R_3$, con Bogotá siendo el tercer departamento, sin que exista el efecto de promediar múltiples municipios. En cambio, departamentos con numerosos de éstos presentan medias posteriores mucho más estables (e.g., Antioquia, Boyacá y Cundinamarca que son departamentos con más de 100 municipios) y, por tanto, intervalos de credibilidad más estrechos.

Finalmente, consideramos que la línea vertical en cero es especialmente útil en la visualización, pues la ecuación estructural del Modelo 3 es

$$R_i = \alpha + \mathbf{x}_i^\top \beta + \psi_{\xi_i} + \varepsilon_i$$

(véase §§3.3), con lo cual el valor cero representa aproximadamente un nivel 'promedio' del factor latente. Así, podemos interpretar que departamentos completamente a la derecha del cero presentan un nivel promedio de riesgo superior al promedio nacional, departamentos completamente a la izquierda presentan un nivel inferior, y aquellos cuyos intervalos contienen el cero no muestran evidencia suficientemente fuerte para afirmar que su nivel promedio difiera del promedio nacional.

Si comparamos este gráfico con el mapa de la Figura 13, nótese que ambos sintetizan información diferente: El mapa de las medias posteriores de los efectos espaciales departamentales ψ_d describe el efecto espacial residual de cada departamento; es decir, aquello que queda sin explicar por las covariables estructurales en la ecuación estructural. En cambio, este ranking a partir de las medias posteriores de las medidas agregadas ζ_d, construidas a partir de las medias posteriores de los R_i, resume el nivel promedio del factor latente en los municipios de cada departamento. Por ello, Bogotá aparece liderando el ranking aunque su efecto espacial $\widehat{\psi}_3$ no fuera necesariamente el mayor. El valor de los $\widehat{\zeta}_d$ incorpora tanto la contribución de las covariables como del efecto espacial y del resto de componentes del modelo MLR-LAFT-EED. En síntesis, el mapa muestra cómo influye la estructura espacial residual, mientras que el ranking muestra cuál es el nivel promedio estimado del riesgo latente en cada departamento. Son dos perspectivas complementarias sobre el mismo fenómeno y enriquecen la comprensión de los resultados del Modelo 3.

6.2. Clasificación departamental mediante terciles

Una vez calculadas las medias posteriores de los ζ_d ($d = 1, \ldots, 33$), se asignaron tres niveles de riesgo a los departamentos (Bajo, Medio y Alto) usando umbrales de clasificación los dos terciles de la distribución empírica de los $\widehat{\zeta}_d$; es decir, departamentos con riesgo bajo son aquellos con $\widehat{\zeta}_d$ bajo el primer tercil, con riesgo medio entre el primer y segundo tercil, y con riesgo alto por encima del segundo tercil. De esta manera, se transforma una escala latente continua en una clasificación operativa del riesgo de LAFT. Los resultados de esta clasificación se sintetizan gráficamente en el mapa departamental de la Figura 15.

Se observa que los departamentos clasificados en riesgo bajo son algunos de la costa Caribe, del centro del país y de la Amazonía; en riego medio, vemos otros departamentos del Caribe, los del Eje cafetero, Nariño y Vichada; y en riesgo alto, departamentos de la costa Pacífica, Cesar y algunos de la Amazonía y la Orinoquía. Como patrones generales vemos que Amazonas, Vaupés y Guainía continúan evidenciando un bajo riesgo de LAFT, en total consistencia con lo observado en los indicadores $y_{i,j}$ y condensado en los mapas exploratorios de las Figuras 8 y 9. Vemos también riesgo bajo en departamentos del centro del país, nuevamente en sintonía con los mencionados mapas. Es de destacar también cómo Casanare, Putumayo, Bogotá y departamentos de la costa Pacífica dan evidencia de riesgo alto, lo cual se observó en los indicadores desde un inicio; y departamentos que, en principio, podíamos clasificar como moderados en el análisis exploratorio, tales como Cesar, Antioquia, Arauca y Meta, en esta clasificación quedan en riesgo alto. En términos generales, vemos muchas similitudes con lo observado en §§2.2 y con lo reportado en §§6.1. De aquí podemos concluir que la media posterior del factor latente de riesgo de LAFT agregado como medida de clasificación en tres niveles es, a grandes rasgos, bastante precisa.

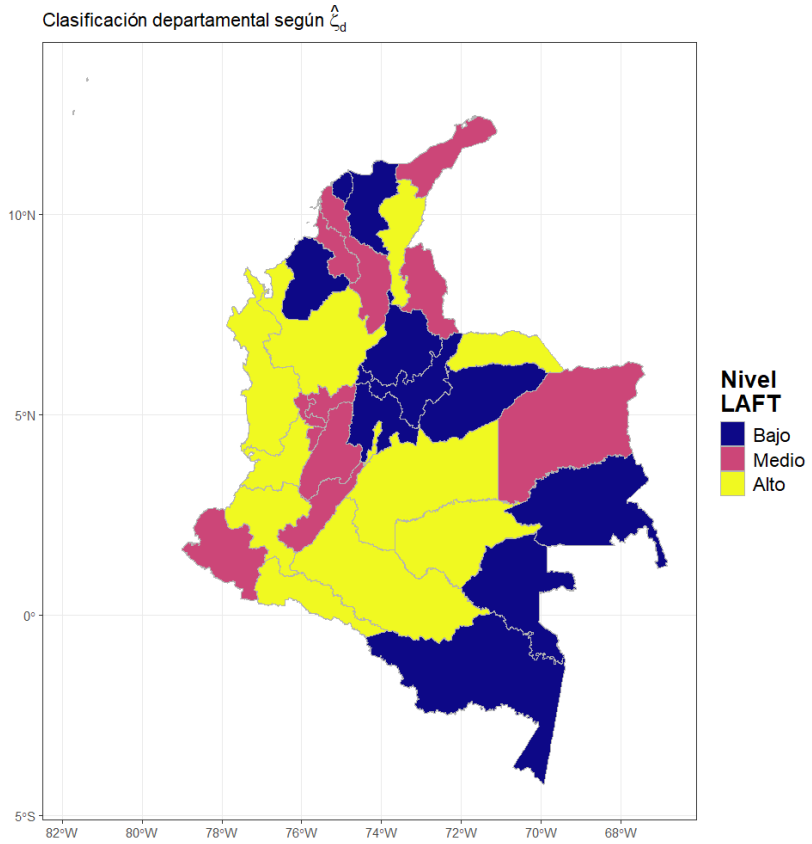


FIGURA 15. Mapa de Colombia a nivel departamental con clasificación en tres niveles de riesgo de LAFT según los terciles de la distribución empírica de las medias posteriores de las medidas agregadas de riesgo latente ζ_d $(d = 1, \ldots, 33)$ a partir de las muestras del modelo MLR-LAFT-EED.

6.3. Clasificación municipal mediante terciles

Se realizó la misma clasificación por terciles de §§6.2 pero para los 1122 municipios de Colombia, empleando como medida de clasificación las medias posteriores de los factores de riesgo de LAFT, los $\widehat{R}_i$, utilizando para tales efectos las muestras generadas con el modelo MLR-LAFT-EED.

Aquí aparecen marcadas discrepancias con lo observado en algunos mapas particulares desagregados de la Figura 8, donde municipios con niveles considerablemente bajos de riesgo LAFT en alguno de los indicadores, como los de la península de La Guajira en materia de terrorismo y narcotráfico, son clasificados como municipios de riesgo alto. Sin embargo, si nos fijamos detalladamente, vemos que la clasificación penaliza departamentos que hayan obtenido valores continuos de riesgo alto, o incluso medio-alto, en los indicadores observados, como el caso de departamentos del Vichada, del Magdalena medio, de Arauca y de Norte de Santander. Bogotá sigue consolidándose como municipio de riesgo alto, al igual que municipios del Meta, Guaviare, Caquetá, Putumayo y departamentos de la costa Pacífica.

La similitud entre este mapa y el de la Figura 9 es absolutamente evidente, y es claro que departamentos con municipios de riesgo bajo y alto (azules y amarillos) se *combinan*, de alguna manera, para clasificarse como riesgo medio en el mapa departamental con las medidas agregadas. El único caso que consideramos extraño es el del departamento de Nariño, que con pocos municipios en riesgo medio y mayoría en alto, se clasificó como riesgo medio en §§6.2; quizás esto obedezca a que la clasificación obligatoriamente divide a los departamentos en tres grupos de 11, con lo cual, al ser sólo 33, habrá alguno que se clasifique en un nivel que no sea muy consistente con lo observado a nivel municipal.

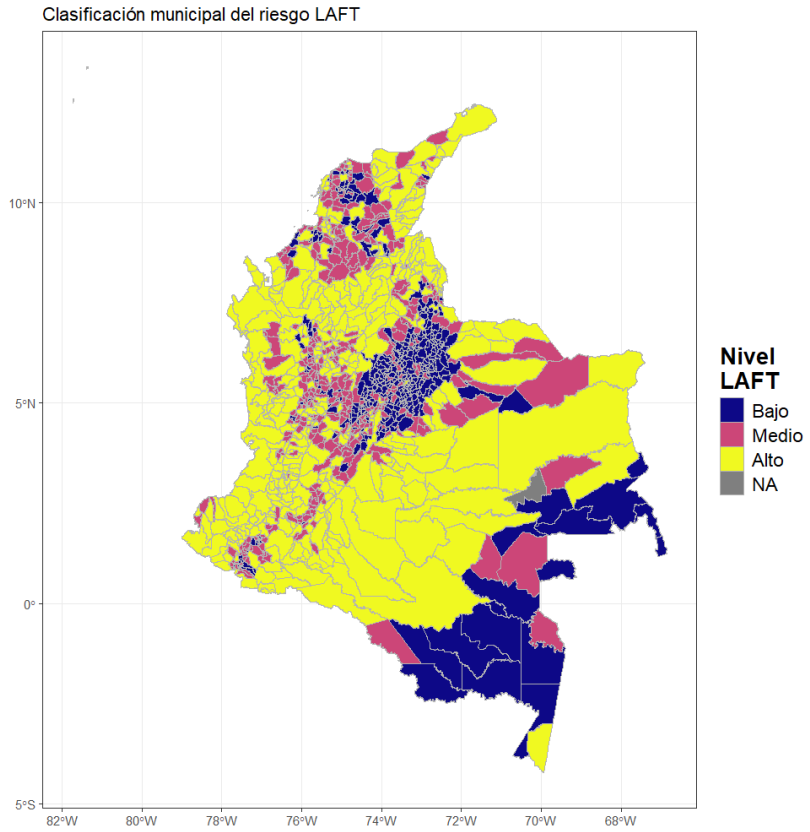


FIGURA 16. Mapa de Colombia a nivel municipal con clasificación en tres niveles de riesgo de LAFT según los terciles de la distribución empírica de las medias posteriores de los factores latentes de riesgo R_i $(i = 1, \ldots, 1122)$ a partir de las muestras del modelo MLR-LAFT-EED.

En consecuencia, consideramos más apropiada la clasificación municipal a partir de los R_i posteriores, debido a la presencia de heterogeneidad interna de los departamentos evidenciada en los indicadores observados, en los factores de riesgo estimados mediante la media posterior de los R_i, y a que, en la clasificación de §§6.2, se deben conformar grupos de 11 departamentos siguiendo únicamente el orden de los valores de las medias posteriores agregadas, independientemente de que no haya puntos de inflexión significativos en los terciles.

7. Conclusiones

(I) En este trabajo, se desarrollaron y compararon tres modelos Bayesianos de ecuaciones estructurales para la estimación del riesgo de lavado de activos y financiación del terrorismo (LAFT) en los municipios de Colombia. La principal motivación consistió en abordar un problema de medición en el que la variable de interés no es directamente observable, mediante la construcción de una variable latente que sintetiza simultáneamente información proveniente de índices estructurales municipales e indicadores observados del fenómeno. Los resultados obtenidos muestran que este enfoque constituye una alternativa estadísticamente sólida para cuantificar el riesgo de LAFT en ausencia de una variable respuesta predefinida.

(II) Desde el punto de vista metodológico, la incorporación de una distribución Gamma cero-inflada dentro del modelo de medición permitió representar adecuadamente indicadores caracterizados por una proporción considerable de observaciones nulas, conservando simultáneamente la información

contenida en los valores positivos. La especificación propuesta resulta especialmente interesante porque la variable latente ejerce un doble efecto sobre la respuesta, explicando tanto la probabilidad de ocurrencia de valores nulos mediante la componente Bernoulli como la intensidad del fenómeno a través de la componente Gamma. Esta formulación proporciona una representación flexible de fenómenos semicontinuos que difícilmente podrían modelarse mediante distribuciones convencionales.

(III) Los algoritmos de inferencia desarrollados permitieron estimar satisfactoriamente modelos de complejidad creciente mediante técnicas MCMC, incorporando múltiples etapas de Metropolis y Metropolis-Hastings dentro de muestreadores de Gibbs. A pesar de la complejidad de las distribuciones condicionales completas inducida por la estructura cero-inflada y espacial del modelo, las cadenas presentaron un comportamiento adecuado en términos de convergencia y estabilidad, obteniéndose estimaciones posteriores con coeficientes de variación reducidos e intervalos de credibilidad suficientemente precisos para la totalidad de los parámetros de interés.

(IV) La comparación entre los tres modelos mediante los criterios DIC, WAIC y las medidas de desempeño predictivo permitió identificar al Modelo 2 como el de mejor comportamiento global. En particular, este modelo presentó valores de DIC y WAIC muy cercanos a los del complejo Modelo 3 con efectos ICAR, así como resultados moderados en términos de MSE, MAE y coeficiente de determinación R^2 para la mayoría de los indicadores observados. Estos resultados evidencian la importancia de complementar los criterios clásicos de selección Bayesiana con evaluaciones explícitas de capacidad predictiva, especialmente en modelos jerárquicos con variables latentes.

(V) Los ejercicios de verificación predictiva posterior mostraron, además, una adecuada capacidad del modelo para reproducir tanto la distribución continua de los indicadores positivos como la masa de probabilidad asociada a las observaciones nulas. En conjunto, estos resultados respaldan la capacidad del modelo para representar las principales características empíricas de los datos observados y constituyen evidencia adicional de su validez como herramienta de inferencia.

(VI) Desde el punto de vista aplicado, las estimaciones posteriores de las variables latentes municipales permitieron construir medidas objetivas del riesgo municipal y departamental de LAFT, así como generar clasificaciones territoriales en niveles de riesgo bajo, medio y alto. Estas clasificaciones ofrecen un criterio cuantitativo susceptible de complementar los mecanismos tradicionales de priorización empleados por las entidades encargadas de la prevención, vigilancia y control del LAFT, proporcionando información útil para orientar procesos de monitoreo y asignación de recursos institucionales.

(VII) Finalmente, esta investigación demuestra que los modelos Bayesianos de ecuaciones estructurales constituyen un marco flexible para abordar problemas de medición de fenómenos no observables, permitiendo integrar información de naturaleza diversa, incorporar incertidumbre de manera explícita y extender naturalmente la modelación hacia estructuras espaciales. En consecuencia, la metodología desarrollada no sólo resulta aplicable al estudio del riesgo de LAFT en Colombia, sino que también puede servir como punto de partida para futuras investigaciones orientadas al análisis de otros fenómenos latentes caracterizados por respuestas semicontinuas, exceso de ceros y dependencia espacial.

8. Limitaciones y posibles extensiones

(I) Aunque los resultados obtenidos evidencian un comportamiento satisfactorio de los modelos propuestos, existen algunas limitaciones que deben considerarse al interpretar los resultados. En primer

lugar, la variable latente construida representa una medida estadística del riesgo de LAFT y no una medición directa del fenómeno, por lo que su interpretación depende de la calidad y representatividad de los indicadores observados utilizados en el modelo de medición. En consecuencia, la incorporación de nuevos indicadores podría modificar la estimación del riesgo latente y enriquecer su capacidad descriptiva.

(II) En segundo lugar, el análisis espacial se realizó a nivel departamental mediante un modelo ICAR. Si bien esta aproximación permitió capturar patrones de dependencia territorial de forma relativamente parsimoniosa, no considera explícitamente la estructura de vecindad existente entre municipios, donde probablemente se manifiestan procesos espaciales de mayor detalle.

(III) Este estudio se desarrolló utilizando información correspondiente a un único periodo de tiempo para algunas variables iniciales y a un acumulado de varios periodos para otras. En consecuencia, los modelos estimados permiten caracterizar la distribución espacial del riesgo, pero no describen su evolución temporal ni los posibles cambios asociados a modificaciones en las dinámicas criminales o en las políticas públicas.

(IV) Una primera extensión consiste en incorporar dependencia espacial directamente entre municipios mediante modelos CAR o ICAR definidos sobre la matriz de vecindad municipal. Esta modificación permitiría representar con mayor precisión los procesos de difusión territorial del riesgo de LAFT y analizar patrones espaciales locales que pueden quedar parcialmente ocultos al trabajar únicamente con efectos departamentales.

(V) Una segunda línea de investigación consiste en extender el modelo hacia un contexto espacio-temporal. La incorporación de información correspondiente a varios años permitiría estudiar la evolución del riesgo municipal de LAFT, identificar tendencias persistentes y evaluar el impacto temporal de intervenciones institucionales o cambios en las dinámicas económicas y criminales.

(VI) Desde el punto de vista metodológico, resulta de interés explorar distribuciones alternativas para el modelo de medición, como distribuciones Tweedie, Gamma *hurdle* o familias más generales de modelos de mezcla, que permitan representar diferentes mecanismos generadores de observaciones nulas. Asimismo, podría evaluarse la incorporación de procesos no lineales o efectos aleatorios adicionales dentro del modelo estructural.

(VII) Otra extensión natural consiste en desarrollar procedimientos Bayesianos de selección de variables o de regularización que permitan identificar automáticamente las covariables estructurales con mayor capacidad explicativa del riesgo latente. Esto facilitaría la construcción de modelos más parsimoniosos y potencialmente más interpretables.

(VIII) Desde el punto de vista computacional, sería de interés explorar métodos de inferencia más eficientes, tales como el algoritmo Hamiltoniano, algoritmos de inferencia variacional o estrategias de paralelización, con el propósito de reducir los tiempos de cómputo asociados a modelos jerárquicos de alta dimensión como los considerados en este trabajo.

(IX) Finalmente, la metodología desarrollada podría adaptarse al estudio de otros fenómenos caracterizados por variables latentes, respuestas semicontinuas con exceso de ceros y dependencia espacial, tales como indicadores de criminalidad, pobreza multidimensional, salud pública, seguridad alimentaria o sostenibilidad ambiental. En este sentido, el modelo propuesto constituye un marco general de modelación más allá de su aplicación específica al riesgo de LAFT.

A. Tasas de aceptación obtenidas

Como lo mencionamos al comienzo de §4, por cada muestreador de Gibbs, introdujimos 1141 pasos de Metropolis-Hastings: 1133 de Metropolis (propuestas normales) y 8 de Metropolis-Hastings (propuestas log-normales). En particular, empleamos los algoritmos en sus versiones adaptativas dado el considerable número de parámetros involucrados, realizando las adaptaciones de los 1141 parámetros de ajuste durante las 10000 iteraciones del periodo de calentamiento con una ventana de adaptación de 500 iteraciones. Dada la importancia de los algoritmos de Metropolis y Metropolis-Hastings en nuestros modelos, vemos pertinente reportar a continuación las tasas de aceptación obtenidas tras la ejecución de cada uno de los muestreadores, las cuales establecimos que hicieran parte de la salida de las funciones en R mediante un mensaje tras cada ejecución, y a las cuales se puede llegar con del código adjunto a este informe, pues garantizamos reproducibilidad de los resultados (véanse las Tablas 11-12).

Modelo	**Parámetro**										
MLR-LAFT	μ_1	μ_2	μ_3	μ_4	λ_2	λ_3	λ_4	ϕ_1	ϕ_2	ϕ_3	ϕ_4
	0.344	0.318	0.377	0.406	0.339	0.295	0.397	0.407	0.435	0.440	0.428
	δ_{01}	δ_{02}	δ_{03}	δ_{04}	δ_{11}	δ_{12}	δ_{13}	δ_{14}			
	0.439	0.480	0.464	0.334	0.495	0.326	0.347	0.433			
MLR-LAFT-ED	μ_1	μ_2	μ_3	μ_4	λ_2	λ_3	λ_4	ϕ_1	ϕ_2	ϕ_3	ϕ_4
	0.348	0.309	0.374	0.404	0.334	0.286	0.397	0.404	0.434	0.440	0.428
	δ_{01}	δ_{02}	δ_{03}	δ_{04}	δ_{11}	δ_{12}	δ_{13}	δ_{14}			
	0.440	0.481	0.472	0.300	0.477	0.323	0.360	0.419			
MLR-LAFT-EED	μ_1	μ_2	μ_3	μ_4	λ_2	λ_3	λ_4	ϕ_1	ϕ_2	ϕ_3	ϕ_4
	0.346	0.309	0.372	0.405	0.328	0.290	0.398	0.405	0.435	0.441	0.425
	δ_{01}	δ_{02}	δ_{03}	δ_{04}	δ_{11}	δ_{12}	δ_{13}	δ_{14}			
	0.442	0.479	0.475	0.309	0.483	0.326	0.365	0.414			

TABLA 11. Tasas de aceptación para los parámetros únicos de los tres modelos SEM Bayesianos que fueron muestreados mediante el algoritmo de Metropolis o Metropolis-Hastings.

Modelo	**Mínima**	**Media**	**Máxima**
MLR-LAFT	0.411	0.467	0.505
MLR-LAFT-ED	0.368	0.458	0.499
MLR-LAFT-EED	0.366	0.458	0.499

TABLA 12. Resumen de tres números de las tasas de aceptación para los factores latentes R_i ($i = 1, \ldots, 1122$) de los tres modelos SEM Bayesianos, los cuales fueron muestreados mediante el algoritmo de Metropolis.

B. Distribuciones involucradas

Las distribuciones mencionadas en este caso de estudio son caracterizadas a continuación. $\mathcal{X}_I(\mathrm{x})$ denota la función indicadora de x sobre el conjunto I. Parte de la notación empleada fue consultada en Sosa Martínez y Aristizábal Rodríguez (2022).

✤ **Distribución Bernoulli**

Una variable aleatoria X posee distribución Bernoulli con probabilidad de éxito $\pi \in (0,1)$, denotado $X \sim \text{Bernoulli}(\pi)$, si y sólo si su función másica de probabilidad es

$$p(x) = \pi^x (1-\pi)^{1-x} \mathcal{X}_{\{0,1\}}(x).$$

✤ **Distribución uniforme continua**

Una variable aleatoria X posee distribución uniforme continua sobre el intervalo (a,b) con $a < b$ reales, denotado por $X \sim \text{U}(a,b)$, si y sólo si su función de densidad de probabilidad es

$$p(x) = \frac{1}{b-a} \mathcal{X}_{(a,b)}(x).$$

✤ **Distribución normal**

Una variable aleatoria X posee distribución normal con parámetros $\mu \in \mathbb{R}$ y $\sigma^2 \in \mathbb{R}^+$, denotado por $X \sim \text{N}\left(\mu, \sigma^2\right)$, si y sólo si su función de densidad de probabilidad es

$$p\left(x\right) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2}(x-\mu)^2\right] \mathcal{X}_{\mathbb{R}}(x).$$

✤ **Distribución normal multivariada**

Un k-vector aleatorio $\mathbf{X} := (X_1, \ldots, X_k)$ posee distribución normal multivariada con media $\boldsymbol{\mu} \in \mathbb{R}^k$ y varianza $\boldsymbol{\Sigma} \in \mathbb{R}^{k \times k}$, denotado por $\mathbf{X} \sim \text{N}_k\left(\boldsymbol{\mu}, \boldsymbol{\Sigma}\right)$, si y sólo si su función de densidad de probabilidad conjunta es

$$p\left(\mathbf{x}\right) = (2\pi)^{-k/2} |\boldsymbol{\Sigma}|^{-1/2} \exp\left[-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} \left(\mathbf{x}-\boldsymbol{\mu}\right)\right] \mathcal{X}_{\mathbb{R}^k}(\mathbf{x}).$$

✤ **Distribución normal truncada en $\mathbb{R}^+$**

Una variable aleatoria X posee distribución normal truncada en $\mathbb{R}$ con parámetros de localización $\mu \in \mathbb{R}$ y de escala $\sigma^2 \in \mathbb{R}^+$, denotado por $X \sim \text{N}^+\left(\mu, \sigma^2\right)$, si y sólo si su función de densidad de probabilidad conjunta es

$$p(x) = \frac{\phi\left(\frac{x-\mu}{\sqrt{\sigma^2}}\right)}{\sqrt{\sigma^2}\left[1 - \Phi\left(-\frac{\mu}{\sqrt{\sigma^2}}\right)\right]} \mathcal{X}_{\mathbb{R}^+}(x),$$

donde $\phi(\bullet)$ y $\Phi(\bullet)$ son las funciones de densidad y de distribución de probabilidad, respectivamente, de una variable aleatoria con distribución normal estándar.

✤ **Distribución log-normal**

Una variable aleatoria X posee distribución log-normal con parámetros $\mu \in \mathbb{R}$ y $\sigma^2 \in \mathbb{R}^+$, denotado por $X \sim \text{Lognormal}\left(\mu, \sigma^2\right)$, si y sólo si su función de densidad de probabilidad es

$$p\left(x\right) = \frac{1}{x\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2}(\ln x - \mu)^2\right] \mathcal{X}_{\mathbb{R}^+}(x).$$

✤ **Distribución Gamma**

Una variable aleatoria X posee distribución Gamma con parámetros de forma $\alpha \in \mathbb{R}^+$ y de razón $\beta \in \mathbb{R}^+$, denotado por $X \sim \text{Gamma}\,(\alpha, \beta)$, si y sólo si su función de densidad es

$$p\,(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \mathcal{X}_{\mathbb{R}^+}(x).$$

✤ **Distribución Gamma-inversa**

Una variable aleatoria X posee distribución Gamma-inversa con parámetros de forma $\alpha \in \mathbb{R}^+$ y de escala $\beta \in \mathbb{R}^+$, denotado por $X \sim \text{IG}\,(\alpha, \beta)$, si y sólo si su función de densidad es

$$p(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{-(\alpha+1)} \exp\left(-\frac{\beta}{x}\right) \mathcal{X}_{\mathbb{R}^+}(x).$$

✤ **Distribución Gamma cero-inflada**

Una variable aleatoria X posee distribución Gamma cero-inflada con parámetros de probabilidad de inflación de ceros $\pi \in (0,1)$, de forma $\alpha \in \mathbb{R}^+$ y de razón $\beta \in \mathbb{R}^+$, denotado por $X \sim \text{ZIGamma}\,(\pi, \alpha, \beta)$, si y sólo si su función de masa-densidad mixta es

$$p(x) = \pi^{[x=0]} \left[(1-\pi)\frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}\right]^{[x>0]} \mathcal{X}_{[0,\infty)}(x),$$

donde $[\bullet]$ es el corchete de Iverson.

C. Distribuciones condicionales completas de los modelos

Se presentan las distribuciones condicionales completas de los tres modelos especificados en §3, así como una breve demostración de cómo llegar al resultado de cada una.

(I) $\alpha \,|\, \text{resto} \sim \text{N}(m, v)$, donde

$$m := \frac{\frac{\sum_{i=1}^{1122}(R_i - \mathbf{x}_i^\top \boldsymbol{\beta})}{\sigma^2} + \frac{a_\alpha}{b_\alpha}}{\frac{1}{b_\alpha} + \frac{1122}{\sigma^2}} \quad \text{y} \quad v := \frac{1}{\frac{1}{b_\alpha} + \frac{1122}{\sigma^2}} \tag{C.1}$$

Demostración:

$$\begin{aligned}
p(\alpha \,|\, \text{resto}) &\propto \prod_{i=1}^{1122} \text{N}(R_i \,|\, \alpha + \mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2) \text{N}(\alpha \,|\, a_\alpha, b_\alpha) \\
&\propto \exp\left[-\frac{1}{2\sigma^2}\sum_{i=1}^{1122}(R_i - (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta}))^2\right] \exp\left[-\frac{1}{2b_\alpha}(\alpha - a_\alpha)^2\right] \\
&\propto \exp\left[-\frac{1}{2}\left(\frac{-2\alpha}{\sigma^2}\sum_{i=1}^{1122} R_i + \frac{1122\alpha^2}{\sigma^2} + \frac{2\alpha}{\sigma^2}\sum_{i=1}^{1122}(\mathbf{x}_i^\top \boldsymbol{\beta}) + \frac{\alpha^2}{b_\alpha} - \frac{2\alpha a_\alpha}{b_\alpha}\right)\right] \\
&= \exp\left\{-\frac{1}{2}\left[\left(\frac{1122}{\sigma^2} + \frac{1}{b_\alpha}\right)\alpha^2 - 2\left(\frac{\sum_{i=1}^{1122}(R_i - \mathbf{x}_i^\top \boldsymbol{\beta})}{\sigma^2} + \frac{a_\alpha}{b_\alpha}\right)\alpha\right]\right\}
\end{aligned}$$

$$= \exp\left[-\frac{1}{2}\left(\frac{1}{v}\alpha^2 - 2\frac{m}{v}\alpha\right)\right], \qquad \alpha \in \mathbb{R}$$

lo cual corresponde al *kernel* de la pdf de la distribución normal con media m y varianza v, con m y v dados en (C.1). □

Nota: Para los Modelos 2 y 3, se aplica la misma deducción y se llega a que

$$m := \frac{\frac{\sum_{i=1}^{1122}(R_i - \mathbf{x}_i^\top \boldsymbol{\beta} - u_d)}{\sigma^2} + \frac{a_\alpha}{b_\alpha}}{\frac{1}{b_\alpha} + \frac{1122}{\sigma^2}} \quad \text{y} \quad m := \frac{\frac{\sum_{i=1}^{1122}(R_i - \mathbf{x}_i^\top \boldsymbol{\beta} - \psi_d)}{\sigma^2} + \frac{a_\alpha}{b_\alpha}}{\frac{1}{b_\alpha} + \frac{1122}{\sigma^2}}$$

respectivamente, cuando el i-ésimo municipio pertenece al d-ésimo departamento.

(II) $\boldsymbol{\beta} \,|\, resto \sim \mathrm{N}_4(\mathbf{M}, \mathbf{V})$,donde

$$\mathbf{M} := \left(\boldsymbol{\beta}_0^{-1} + \frac{1}{\sigma^2}\sum_{i=1}^{1122}(\mathbf{x}_i\mathbf{x}_i^\top)\right)^{-1}\left(\boldsymbol{\beta}_0^{-1}\boldsymbol{\beta}_0 + \frac{1}{\sigma^2}\sum_{i=1}^{1122}[(R_i - \alpha)\mathbf{x}_i]\right)$$
$$\text{y} \quad \mathbf{V} := \left(\boldsymbol{\beta}_0^{-1} + \frac{1}{\sigma^2}\sum_{i=1}^{1122}(\mathbf{x}_i\mathbf{x}_i^\top)\right)^{-1}. \tag{C.2}$$

Demostración:

$$p(\boldsymbol{\beta} \,|\, \text{resto}) \propto \prod_{i=1}^{1122} \mathrm{N}(R_i \,|\, \alpha + \mathbf{x}_i^\top\boldsymbol{\beta}, \sigma^2)\mathrm{N}_4(\boldsymbol{\beta} \,|\, \boldsymbol{\beta}_0, \mathbf{B}_0)$$

$$\propto \exp\left[-\frac{1}{2\sigma^2}\left(\sum_{i=1}^{1122}R_i^2 - 2\sum_{i=1}^{1122}[R_i(\alpha + \mathbf{x}_i^\top\boldsymbol{\beta})] + \sum_{i=1}^{1122}(\alpha + \mathbf{x}_i^\top\boldsymbol{\beta})^2\right)\right]$$
$$\times \exp\left[-\frac{1}{2}(\boldsymbol{\beta}^\top - \boldsymbol{\beta}_0^\top)\mathbf{B}_0^{-1}(\boldsymbol{\beta} - \boldsymbol{\beta}_0)\right]$$

$$\propto \exp\left\{-\frac{1}{2}\left[\frac{2}{\sigma^2}\sum_{i=1}^{1122}(\boldsymbol{\beta}^\top(\alpha - R_i)\mathbf{x}_i) + \frac{1}{\sigma^2}\sum_{i=1}^{1122}(\boldsymbol{\beta}^\top\mathbf{x}_i\mathbf{x}_i^\top\boldsymbol{\beta}) + \boldsymbol{\beta}^\top\mathbf{B}_0^{-1}\boldsymbol{\beta} - 2\boldsymbol{\beta}^\top\mathbf{B}_0^{-1}\boldsymbol{\beta}_0\right]\right\}$$

$$= \exp\left\{-\frac{1}{2}\left[\boldsymbol{\beta}^\top\left(\frac{1}{\sigma^2}\sum_{i=1}^{1122}(\mathbf{x}_i\mathbf{x}_i^\top) + \mathbf{B}_o^{-1}\right)\boldsymbol{\beta} - 2\boldsymbol{\beta}^\top\left(\mathbf{B}_0^{-1}\boldsymbol{\beta}_0 + \frac{1}{\sigma^2}\sum_{i=1}^{1122}[(R_i - \alpha)\mathbf{x}_i]\right)\right]\right\}$$

$$= \exp\left[-\frac{1}{2}\left(\boldsymbol{\beta}^\top\mathbf{V}\boldsymbol{\beta} - 2\boldsymbol{\beta}^\top\mathbf{V}^{-1}\mathbf{M}\right)\right], \qquad \boldsymbol{\beta} \in \mathbb{R}^4$$

lo cual corresponde al *kernel* de la pdf de la distribución normal 4-variada con vector de medias $\mathbf{M}$ y matriz de varianzas y covarianzas $\mathbf{V}$, con $\mathbf{M}$ y $\mathbf{V}$ dados en (C.2). □

Nota: Para los Modelos 2 y 3, se aplica la misma deducción y se llega a que

$$\mathbf{M} := \left(\mathbf{B}_0^{-1} + \frac{1}{\sigma^2}\sum_{i=1}^{1122}(\mathbf{x}_i\mathbf{x}_i^\top)\right)^{-1}\left(\mathbf{B}_0^{-1}\boldsymbol{\beta}_0 + \frac{1}{\sigma^2}\sum_{i=1}^{1122}[(R_i - \alpha - u_d)\mathbf{x}_i]\right)$$
$$\text{y} \quad \mathbf{M} := \left(\mathbf{B}_0^{-1} + \frac{1}{\sigma^2}\sum_{i=1}^{1122}(\mathbf{x}_i\mathbf{x}_i^\top)\right)^{-1}\left(\mathbf{B}_0^{-1}\boldsymbol{\beta}_0 + \frac{1}{\sigma^2}\sum_{i=1}^{1122}[(R_i - \alpha - \psi_d)\mathbf{x}_i]\right),$$

respectivamente, cuando el i-ésimo municipio pertenece al d-ésimo departamento.

(III) $\sigma^2 \,|\, \text{resto} \sim \text{IG}(F, E)$, donde

$$F := a_\sigma + \frac{1122}{2} \quad \text{y} \quad E := b_\sigma + \frac{1}{2}\sum_{i=1}^{1122}(R_i - (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta}))^2 \tag{C.3}$$

Demostración:

$$\begin{aligned}
p(\sigma^2 \,|\, \text{resto}) &\propto \prod_{i=1}^{1122} \text{N}(R_i \,|\, \alpha + \mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2)\text{IG}(\sigma^2 \,|\, a_\sigma, b_\sigma) \\
&\propto \prod_{i=1}^{1122} (2\pi\sigma^2)^{-1/2} \exp\left[-\frac{1}{2\sigma^2}\sum_{i=1}^{1122}(R_i - (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta}))^2\right] (\sigma^2)^{-(a_\sigma+1)} \exp\left(-\frac{b_\sigma}{\sigma^2}\right) \\
&\propto (\sigma^2)^{-(a_\sigma + \frac{1122}{2}+1)} \exp\left[-\left(\frac{1}{2}\sum_{i=1}^{1122}(R_i - (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta}))^2 + b_\sigma\right)\frac{1}{\sigma^2}\right] \\
&= (\sigma^2)^{-(F+1)} \exp\left(-E \times \frac{1}{\sigma^2}\right), \qquad \sigma^2 \in \mathbb{R}^+
\end{aligned}$$

lo cual corresponde al *kernel* de la pdf de la distribución gamma-inversa con parámetro de forma F y parámetro de escala E, con F y E dados en (C.3). □

Nota: Para los Modelos 2 y 3, se aplica la misma deducción y se llega a que

$$E := b_\sigma + \frac{1}{2}\sum_{i=1}^{1122}(R_i - (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + u_d))^2 \quad \text{y} \quad E := b_\sigma + \frac{1}{2}\sum_{i=1}^{1122}(R_i - (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + \psi_d))^2,$$

respectivamente, cuando el i-ésimo municipio pertenece al d-ésimo departamento.

(IV) $p(\mu_j \,|\, \text{resto}) \propto \exp\left[-\phi_j n_j^+ \mu_j - \frac{(\mu_j - a_\mu)^2}{2b_\mu} - \phi_j \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right]$ con $\mu_j \in \mathbb{R}$ y $j = 1, \ldots, 4$, donde n_j^+ denota la cantidad de municipios para los cuales el j-ésimo indicador observado es positivo.

Demostración:

$$\begin{aligned}
p(\mu_j \,|\, \text{resto}) &\propto \prod_{i=1}^{1122} \text{ZIGamma}\left(y_{i,j} \,|\, \pi_{i,j}, \phi_j, \frac{\phi_j}{\exp(\mu_j + \lambda_j R_i)}\right) \text{N}(\mu_j \,|\, a_\mu, b_\mu) \\
&\propto \prod_{i=1}^{1122} \left(\frac{\phi_j}{\exp(\mu_j + \lambda_j R_i)}\right)^{\phi_j} \exp\left[-\phi_j \sum_{i=1}^{1122}\left(\frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right)\right] \\
&\quad \times \exp\left[-\frac{1}{2b_\mu}(\mu_j - a_\mu)^2\right], \qquad y_{ij} > 0 \\
&\propto \frac{1}{\exp\left[\phi_j n_j^+ \mu_j + \phi_j \lambda_j \sum_{i \,|\, y_{i,j}>0} R_i\right]} \exp\left[-\frac{1}{2b_\mu}(\mu_j - a_\mu)^2 - \phi_j \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right] \\
&\propto \exp\left[-\phi_j n_j^+ \mu_j - \frac{(\mu_j - a_\mu)^2}{2b_\mu} - \phi_j \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right], \qquad \begin{matrix}\mu_j \in \mathbb{R}, \\ j = 1, \ldots, 4.\end{matrix}
\end{aligned}$$

□

Lo anterior en escala log es:

$$\ln p(\mu_j \,|\, \text{resto}) = -\phi_j n_j^+ \mu_j - \frac{(\mu_j - a_\mu)^2}{2b_\mu} - \phi_j \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)} + c, \qquad c \in \mathbb{R}.$$

(v) $p(\lambda_j \,|\, \text{resto}) \propto \exp\left[-\frac{(\lambda_j - a_\lambda)^2}{2b_\lambda} - \phi_j \lambda_j \sum_{i \,|\, y_{i,j}>0} R_i - \phi_j \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right]$ con $\lambda_j \in \mathbb{R}$ y $j = 2, 3, 4$.

Demostración:

$$p(\lambda_j \,|\, \text{resto}) \propto \prod_{i=1}^{1122} \text{ZIGamma}\left(y_{i,j} \,|\, \pi_{i,j}, \phi_j, \frac{\phi_j}{\exp(\mu_j + \lambda_j R_i)}\right) \text{N}(\lambda_j \,|\, a_\lambda, b_\lambda)$$

$$\propto \prod_{i=1}^{1122} \left(\frac{\phi_j}{\exp(\mu_j + \lambda_j R_i)}\right)^{\phi_j} \exp\left(-\phi_j \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right) \exp\left[-\frac{1}{2b_\lambda}(\lambda_j - a_j)^2\right], \quad y_{i,j} > 0$$

$$\propto \frac{1}{\exp(\phi_j \mu_j) \prod_{i \,|\, y_{i,j}>0} \exp(\phi_j \lambda_j R_i)} \exp\left[-\frac{(\lambda_j - a_\lambda)^2}{2b_\lambda} - \phi_j \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right]$$

$$\propto \exp\left[-\frac{(\lambda_j - a_\lambda)^2}{2b_\lambda} - \phi_j \lambda_j \sum_{i \,|\, y_{i,j}>0} R_i - \phi_j \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right], \qquad \lambda_j \in \mathbb{R}, \quad j = 2, 3, 4. \quad \square$$

Nota: Lo anterior en escala log es:

$$\ln(\lambda_j \,|\, \text{resto}) = -\frac{(\lambda_j - a_\lambda)^2}{2b_\lambda} - \phi_j \lambda_j \sum_{i \,|\, y_{i,j}>0} R_i - \phi_j \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)} + c, \qquad c \in \mathbb{R}.$$

(vi) $p(\phi_j \,|\, \text{resto}) \propto \frac{\phi_j^{a_\phi + n_j^+ \phi_j - 1}}{\Gamma(\phi_j)^{n_j^+}} \left(\prod_{i \,|\, y_{i,j}>0} y_{i,j}\right) \exp\left[-\left(b_\phi + n_j^+ \mu_j + \lambda_j \sum_{i \,|\, y_{i,j}>0} R_i + \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right) \phi_j\right]$ con $\phi_j \in \mathbb{R}^+$ y $j = 1, \ldots, 4$.

$$p(\phi_j \,|\, \text{resto}) \propto \prod_{i=1}^{1122} \text{ZIGamma}\left(y_{i,j} \,|\, \pi_{i,j}, \phi_j, \frac{\phi_j}{\exp(\mu_j + \lambda_j R_i)}\right) \text{Gamma}(\phi_j \,|\, a_\phi, b_\phi)$$

$$\propto \prod_{i=1}^{1122} \frac{(\phi_j / \exp(\mu_j + \lambda_j R_i))^{\phi_j}}{\Gamma(\phi_j)} \prod_{i=1}^{1122} y_{i,j}^{\phi_j - 1} \exp\left(-\phi_j \sum_{i=1}^{1122} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right) \exp(-b_\phi \phi_j) \phi_j^{a_\phi - 1}, y_{i,j} > 0$$

$$\propto \frac{\phi_j^{a_\phi + n_j^+ \phi_j - 1}}{\Gamma(\phi_j)^{n_j^+}} \left(\prod_{i \,|\, y_{i,j}>0} y_{i,j}\right) \exp\left[-\left(b_\phi + n_j^+ \mu_j + \lambda_j \sum_{i \,|\, y_{i,j}>0} R_i + \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)}\right) \phi_j\right],$$
$$\phi_j \in \mathbb{R}^+, \quad j = 1, \ldots, 4. \quad \square$$

Nota: Lo anterior en escala log es:

$$\ln p(\phi_j \,|\, \text{resto}) = (a_\phi + n_j^+ \phi_j - 1) \ln \phi_j - n_j^+ \ln \Gamma(\phi_j) + \phi_j \sum_{i \,|\, y_{i,j}>0} \ln y_{i,j}$$

$$- \left(b_\phi + n_j^+ \mu_j + \lambda_j \sum_{i \,|\, y_{i,j}>0} R_i + \sum_{i \,|\, y_{i,j}>0} \frac{y_{i,j}}{\exp(\mu_j + \lambda_j R_i)} \right) \phi_j + c, \qquad c \in \mathbb{R}.$$

(VII) $p(\delta_{0j} \,|\, \text{resto}) \propto \frac{\exp\left(n_j^0 \delta_{0j} - \frac{(\delta_{0j} - a_{\delta_0})^2}{2 b_{\delta_0}} - \delta_{1j} \sum_{i \,|\, y_{i,j}>0} R_i \right)}{\prod_{i=1}^{1122} [1 + \exp(\delta_{0j} - \delta_{1j} R_i)]}$, con $\delta_{0j} \in \mathbb{R}$ y $j = 1, \ldots, 4$.

Demostración:

$$p(\delta_{0j} \,|\, \text{resto}) \propto \prod_{i=1}^{1122} \text{ZIGamma}\left(y_{i,j} \,|\, \frac{\exp(\delta_{0j} - \delta_{1j} R_i)}{1 + \exp(\delta_{0j} - \delta_{1j} R_i)}, \phi_j, \frac{\phi_j}{\mu_{ij}} \right) \text{N}(\delta_{0j} \,|\, a_{\delta_0}, b_{\delta_0})$$

$$\propto \prod_{i=1}^{1122} \left(\frac{\exp(\delta_{0j} - \delta_{1j} R_i)}{1 + \exp(\delta_{0j} - \delta_{1j} R_i)} \right)^{[y_{i,j}=0]} \prod_{i=1}^{1122} \left(1 - \frac{\exp(\delta_{0j} - \delta_{1j} R_i)}{1 + \exp(\delta_{0j} - \delta_{1j} R_i)} \right)^{[y_{i,j}>0]} \exp\left[-\frac{1}{2 b_{\delta_0}} (\delta_{0j} - a_{\delta_0})^2 \right]$$

$$= \frac{\exp\left(n_j^0 \delta_{0j} - \frac{(\delta_{0j} - a_{\delta_0})^2}{2 b_{\delta_0}} - \delta_{1j} \sum_{i \,|\, y_{i,j}=0} R_i \right)}{\prod_{i \,|\, y_{i,j}=0} [1 + \exp(\delta_{0j} - \delta_{1j} R_i)]} \prod_{i \,|\, y_{i,j}>0} \left(\frac{1}{1 + \exp(\delta_{0j} - \delta_{1j} R_i)} \right)$$

$$= \frac{\exp\left(n_j^0 \delta_{0j} - \frac{(\delta_{0j} - a_{\delta_0})^2}{2 b_{\delta_0}} - \delta_{1j} \sum_{i \,|\, y_{i,j}=0} R_i \right)}{\prod_{i=1}^{1122} [1 + \exp(\delta_{0j} - \delta_{1j} R_i)]}, \qquad \delta_{0j} \in \mathbb{R}, \quad j = 1, \ldots, 4. \quad \square$$

Nota: Lo anterior en escala log es:

$$\ln p(\delta_{0j} \,|\, \text{resto}) = n_j^0 \delta_{0j} - \frac{(\delta_{0j} - a_{\delta_0})^2}{2 b_{\delta_0}} - \delta_{1j} \sum_{i \,|\, y_{i,j}=0} R_i - \sum_{i=1}^{1122} \ln[1 + \exp(\delta_{0j} - \delta_{1j} R_i)] + c, \qquad c \in \mathbb{R}.$$

(VIII) $p(\delta_{1j} \,|\, \text{resto}) \propto \frac{\exp\left(-\frac{\delta_{1j}^2}{2 b_{\delta_1}} - \delta_{1j} \sum_{i \,|\, y_{i,j}=0} R_i \right)}{\prod_{i=1}^{1122} [1 + \exp(\delta_{0j} - \delta_{1j} R_i)]}$ con $\delta_{1j} \in \mathbb{R}^+$ y $j = 1, \ldots, 4$.

Demostración:

$$p(\delta_{1j} \,|\, \text{resto}) \propto \prod_{i=1}^{1122} \text{ZIGamma}\left(y_{i,j} \,|\, \frac{\exp(\delta_{0j} - \delta_{1j} R_i)}{1 + \exp(\delta_{0j} - \delta_{1j} R_i)}, \phi_j, \frac{\phi_j}{\mu_{i,j}} \right) \text{N}^+(\delta_{1j} \,|\, a_{\delta_1} = 0, b_{\delta_1})$$

$$\propto \prod_{i=1}^{1122} \left(\frac{\exp(\delta_{0j} - \delta_{1j} R_i)}{1 + \exp(\delta_{0j} - \delta_{1j} R_i)} \right)^{[y_{i,j}=0]} \prod_{i=1}^{1122} \left(\frac{1}{1 + \exp(\delta_{0j} - \delta_{1j} R_i)} \right)^{[y_{i,j}>0]} \exp\left(-\frac{\delta_{1j}^2}{2 b_{\delta_1}} \right)$$

$$\propto \frac{\exp(-\delta_{1j} \sum_{i \,|\, y_{i,j}=0} R_i)}{\prod_{i=1}^{1122} [1 + \exp(\delta_{0j} - \delta_{1j} R_i)]} \exp\left(-\frac{\delta_{1j}^2}{2 b_{\delta_1}} \right)$$

$$\propto \frac{\exp\left(-\frac{\delta_{1j}^2}{2 b_{\delta_1}} - \delta_{1j} \sum_{i \,|\, y_{i,j}=0} R_i \right)}{\prod_{i=1}^{1122} [1 + \exp(\delta_{0j} - \delta_{1j} R_i)]}, \qquad \delta_{1j} \in \mathbb{R}^+, \quad j = 1, \ldots, 4. \quad \square$$

Nota: Lo anterior en escala log es:

$$\ln p(\delta_{1j} \,|\, \text{resto}) = -\frac{\delta_{1j}^2}{2 b_{\delta_1}} - \delta_{1j} \sum_{i \,|\, y_{i,j}=0} R_i - \sum_{i=1}^{1122} \ln[1 + \exp(\delta_{0j} - \delta_{1j} R_i)] + c, \qquad c \in \mathbb{R}.$$

(IX) $p(R_i \,|\, \text{resto}) \propto \dfrac{\exp\left[\frac{2R_i(\alpha+\mathbf{x}_i\boldsymbol{\beta})-R_i^2}{2\sigma^2} - \sum_{j\,|\,y_{i,j}>0}\frac{\phi_j y_{i,j}}{\exp(\mu_j+\lambda_j R_i)} - R_i\sum_{j\,|\,y_{i,j}>0}(\phi_j\lambda_j) - R_i\sum_{j\,|\,y_{i,j}>0}\delta_{1j}\right]}{\prod_{j=1}^4[1+\exp(\delta_{0j}-\delta_{1j}R_i)]}$, con $R_i \in \mathbb{R}$ e $i = 1, \ldots, 1122$.

Demostración:

$$
\begin{aligned}
p(R_i \,|\, \text{resto}) &\propto \prod_{j=1}^4 \text{ZIGamma}\left(y_{i,j} \,|\, \frac{\exp(\delta_{0j}-\delta_{1j}R_i)}{1+\exp(\delta_{0j}-\delta_{1j}R_i)}, \phi_j, \frac{\phi_j}{\exp(\mu_j+\lambda_j R_i)}\right) \\
&\quad \times \text{N}(R_i \,|\, \alpha + \mathbf{x}_i\boldsymbol{\beta}, \sigma^2) \\
&\propto \prod_{j=1}^4 \left(\frac{\exp(\delta_{0j}-\delta_{1j}R_i)}{1+\exp(\delta_{0j}-\delta_{1j}R_i)}\right)^{[y_{i,j}=0]} \prod_{j=1}^4 \left(\frac{1}{1+\exp(\delta_{0j}-\delta_{1j}R_i)}\right)^{[y_{i,j}>0]} \\
&\quad \times \prod_{j=1}^4 [\exp(-\phi_j(\mu_j+\lambda_j R_i))]^{[y_{i,j}>0]} \prod_{j=1}^4 \left[\exp\left(-\frac{\phi_j}{\exp(\mu_j+\lambda_j R_i)}y_{i,j}\right)\right]^{[y_{i,j}>0]} \\
&\quad \times \exp\left[-\frac{1}{2\sigma^2}(R_i - \alpha - \mathbf{x}_i^\top\boldsymbol{\beta})^2\right] \\
&\propto \frac{\exp\left(-R_i\sum_{j\,|\,y_{i,j}=0}\delta_{1j}\right)\exp\left(-\sum_{j\,|\,y_{i,j}>0}(\phi_j\lambda_j R_i)\right)\exp\left(-\sum_{j\,|\,y_{i,j}>0}\frac{\phi_j y_{i,j}}{\exp(\mu_j+\lambda_j R_i)}\right)}{\prod_{j=1}^4[1+\exp(\delta_{0j}-\delta_{1j}R_i)]} \\
&\quad \times \exp\left[-\frac{1}{2\sigma^2}\left[R_i^2 - 2R_i(\alpha+\mathbf{x}_i\boldsymbol{\beta}) + (\alpha+\mathbf{x}_i\boldsymbol{\beta})^2\right]\right] \\
&\propto \frac{\exp\left[\frac{2R_i(\alpha+\mathbf{x}_i\boldsymbol{\beta})-R_i^2}{2\sigma^2} - \sum_{j\,|\,y_{i,j}>0}\frac{\phi_j y_{i,j}}{\exp(\mu_j+\lambda_j R_i)} - R_i\sum_{j\,|\,y_{i,j}>0}(\phi_j\lambda_j) - R_i\sum_{j\,|\,y_{i,j}>0}\delta_{1j}\right]}{\prod_{j=1}^4[1+\exp(\delta_{0j}-\delta_{1j}R_i)]},
\end{aligned}
$$

$$R_i \in \mathbb{R}, \quad i = 1, \ldots, 1122.$$ □

Nota: Lo anterior en escala log es:

$$
\begin{aligned}
\ln p(R_i \,|\, \text{resto}) &= \frac{2R_i(\alpha+\mathbf{x}_i\boldsymbol{\beta})-R_i^2}{2\sigma^2} - \sum_{j\,|\,y_{i,j}>0}\frac{\phi_j y_{i,j}}{\exp(\mu_j+\lambda_j R_i)} - R_i\sum_{j\,|\,y_{i,j}>0}(\phi_j\lambda_j) - R_i\sum_{j\,|\,y_{i,j}>0}\delta_{1j} \\
&\quad - \sum_{j=1}^4 \ln[1+\exp(\delta_{0j}-\delta_{1j}R_i)] + c, \quad c \in \mathbb{R}.
\end{aligned}
$$

Nota: Para los Modelos 2 y 3, se aplica la misma deducción y se llega a que

$$
\begin{aligned}
\ln p(R_i \,|\, \text{resto}) &= \frac{2R_i(\alpha+\mathbf{x}_i^\top\boldsymbol{\beta}+u_d)-R_i^2}{2\sigma^2} - \sum_{j\,|\,y_{i,j}>0}\frac{\phi_j y_{i,j}}{\exp(\mu_j+\lambda_j R_i)} - R_i\sum_{j\,|\,y_{i,j}>0}(\phi_j\lambda_j) \\
&\quad - R_i\sum_{j\,|\,y_{i,j}=0}\delta_{1j} - \sum_{j=1}^4 \ln[1+\exp(\delta_{0j}-\delta_{1j}R_i)] + c, \qquad c \in \mathbb{R}
\end{aligned}
$$

y

$$
\ln p(R_i \,|\, \text{resto}) = \frac{2R_i(\alpha+\mathbf{x}_i^\top\boldsymbol{\beta}+\psi_d)-R_i^2}{2\sigma^2} - \sum_{j\,|\,y_{i,j}>0}\frac{\phi_j y_{i,j}}{\exp(\mu_j+\lambda_j R_i)} - R_i\sum_{j\,|\,y_{i,j}>0}(\phi_j\lambda_j)
$$

$$- R_i \sum_{j \,|\, y_{i,j}=0} \delta_{1j} - \sum_{j=1}^{4} \ln\left[1 + \exp(\delta_{0j} - \delta_{1j} R_i)\right] + c, \qquad c \in \mathbb{R}$$

respectivamente, cuando el i-ésimo municipio pertenece al d-ésimo departamento.

(X) $u_d \,|\, \text{resto} \overset{\text{ind}}{\sim} \text{N}(m, v)$, donde

$$m := \frac{\sum_{i=1}^{n_d} (R_i - \alpha - \mathbf{x}_i^\top \boldsymbol{\beta})}{n_d + \frac{\sigma^2}{\omega^2}} \quad \text{y} \quad v := \frac{1}{\frac{n_d}{\sigma^2} + \frac{1}{\omega^2}}, \tag{C.4}$$

con n_d el número de municipios pertenecientes al departamento d y $d = 1, \ldots, 33$.

Demostración:

$$\begin{aligned}
p(u_d \,|\, \text{resto}) &\propto \prod_{i \,|\, \xi_i = d} \text{N}(R_i \,|\, \alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + u_d, \sigma^2)\, \text{N}(u_d \,|\, a_u := 0, \omega^2) \\
&\propto \exp\left[-\frac{1}{2\sigma^2} \sum_{i \,|\, \xi_i = d} \left[R_i^2 - 2R_i(\alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + u_d) + (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta} + u_d)^2 \right] \right] \exp\left(-\frac{u_d^2}{2\omega^2} \right) \\
&\propto \exp\left[-\frac{1}{2} \left(\frac{n_d u_d^2}{\sigma^2} + \frac{2u_d}{\sigma^2} \sum_{i=1}^{n_d} (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta}) - \frac{2u_d}{\sigma^2} \sum_{i \,|\, \xi_i = d} R_i + \frac{u_d^2}{\omega^2} \right) \right] \\
&= \exp\left\{ -\frac{1}{2} \left[\left(\frac{n_d}{\sigma^2} + \frac{1}{\omega^2} \right) u_d^2 - 2 \left(\frac{\sum_{i \,|\, \xi_i = d} (R_i - \alpha - \mathbf{x}_i^\top \boldsymbol{\beta})}{\sigma^2} \right) u_d \right] \right\} \\
&= \exp\left[-\frac{1}{2} \left(\frac{1}{v} u_d^2 - 2 \frac{m}{v} u_d \right) \right], \qquad u_d \in \mathbb{R}, \quad d = 1, \ldots, 33
\end{aligned}$$

lo cual corresponde al *kernel* de la pdf de la distribución normal con media m y varianza v, donde m y v son dados en (C.4). □

(XI) $\omega^2 \,|\, \text{resto} \sim \text{IG}(F, E)$, donde

$$F := a_\omega + \frac{33}{2} \quad \text{y} \quad E := b_\omega + \frac{1}{2} \sum_{d=1}^{33} u_d^2. \tag{C.5}$$

Demostración:

$$\begin{aligned}
p(\omega^2 \,|\, \text{resto}) &\propto \prod_{d=1}^{33} \text{N}(u_d \,|\, 0, \omega^2)\, \text{IG}(\omega^2 \,|\, a_\omega, b_\omega) \\
&\propto \prod_{d=1}^{33} (2\pi\omega^2)^{-1/2} \exp\left(-\frac{1}{2\omega^2} \sum_{d=1}^{33} u_d^2 \right) (\omega^2)^{-(a_\omega + 1)} \exp\left(-\frac{b_\omega}{\omega^2} \right) \\
&\propto (\omega^2)^{-\left(a_\omega + \frac{33}{2} + 1\right)} \exp\left(-\frac{b_\omega + \frac{1}{2} \sum_{d=1}^{33} u_d^2}{\omega^2} \right) = (\omega^2)^{-(F+1)} \exp\left(-\frac{E}{\omega^2} \right),
\end{aligned}$$

lo cual corresponde al *kernel* de la pdf de la distribución gamma-inversa con parámetro de forma F y de escala E, donde F y E son dados en (C.5). □

Nota: Para el Modelo 3, se aplica la misma deducción y se llega a que

$$F := a_\omega + 16 \quad \text{y} \quad E := b_\omega + \frac{1}{2}\sum_{d<\ell}\left[w_{d\ell}(\psi_d - \psi_\ell)^2\right]$$

con $d, \ell = 1, 2, \ldots, 33$. (Se recomienda ver §§3.3 para más detalles acerca de la notación y la condicional completa que viene a continuación para conocer la distribución conjunta de los ψ_d bajo el modelo ICAR).

(XII) $\psi_d \,|\, \text{resto} \sim \text{N}(m, v)$, donde

$$m := \frac{\frac{1}{\sigma^2}\sum_{i\,|\,\xi_i=d}(R_i - \alpha - \mathbf{x}_i^\top\boldsymbol{\beta}) + \frac{1}{\omega^2}\sum_{\ell\sim d}\psi_\ell}{\frac{n_d}{\sigma^2} + \frac{m_d}{\omega^2}} \quad \text{y} \quad v := \frac{1}{\frac{n_d}{\sigma^2} + \frac{m_d}{\omega^2}} \tag{C.6}$$

con $d, \ell = 1, \ldots, 33$, n_d como se estableció previamente y m_d y $\ell \sim d$ como se especifican en §§3.3.

Demostración: Besag, York y Mollié (1991) demostraron que, bajo el modelo ICAR, la distribución conjunta de los efectos aleatorios espaciales está dada por

$$\begin{aligned} p(\boldsymbol{\psi} \,|\, \omega^2) &\propto (\omega^2)^{-\frac{k-1}{2}} \exp\left[-\frac{1}{2\omega^2}\boldsymbol{\psi}^\top(\mathbf{D} - \mathbf{W})\boldsymbol{\psi}\right] \\ &= (\omega^2)^{-\frac{k-1}{2}} \exp\left[-\frac{1}{2\omega^2}\sum_{d<\ell}\left[w_{d\ell}(\psi_d - \psi_\ell)^2\right]\right], \end{aligned}$$

donde k es el número de áreas, $\mathbf{W}$ es la matriz de vecindad y $\mathbf{D} := \text{diag}\{m_1, \ldots, m_{33}\}$. En nuestro caso, $k = 33$ y $\boldsymbol{\psi} := (\psi_1, \ldots, \psi_{33})$, siendo las matrices $\mathbf{D}$ y $\mathbf{W}$ de tamaño 33×33 ambas. De esta manera:

$$\begin{aligned} p(\psi_d \,|\, \text{resto}) &\propto \prod_{i\,|\,\xi_i=d} p(R_i \,|\, \alpha, \boldsymbol{\beta}, \psi_d, \sigma^2, \mathbf{x}_i)\, p(\boldsymbol{\psi} \,|\, \boldsymbol{\psi}_{-d}, \omega^2) \\ &= \prod_{i\,|\,\xi_i=d}\left\{\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left[-\frac{1}{2\sigma^2}(R_i - (\alpha + \mathbf{x}_i^\top\boldsymbol{\beta} + \psi_d))^2\right]\right\}(\omega^2)^{-\frac{33-1}{2}}\exp\left[-\frac{1}{2\omega^2}\sum_{d<\ell}\left[w_{d\ell}(\psi_d - \psi_\ell)^2\right]\right] \\ &\propto \exp\left[-\frac{1}{2\sigma^2}\sum_{i\,|\,\xi_i=d}(R_i - (\alpha + \mathbf{x}_i^\top\boldsymbol{\beta} + \psi_d))^2\right]\exp\left[-\frac{1}{2\omega^2}\sum_{\ell\neq d}\left[w_{d\ell}(\psi_d - \psi_\ell)^2\right]\right] \\ &= \exp\left\{-\frac{1}{2\sigma^2}\left[\sum_{i\,|\,\xi_i=d}R_i^2 - 2\sum_{i\,|\,\xi_i=d}\left[R_i(\alpha + \mathbf{x}_i^\top\boldsymbol{\beta} + \psi_d)\right] + \sum_{i\,|\,\xi_i=d}(\alpha + \mathbf{x}_i^\top\boldsymbol{\beta} + \psi_d)^2\right]\right\} \\ &\quad \times \exp\left[-\frac{1}{2\omega^2}\sum_{\ell=1}^{33}\left[w_{d\ell}(\psi_d - \psi_\ell)^2\right]\right] \\ &\propto \exp\left\{-\frac{1}{2\sigma^2}\left[-2\sum_{i\,|\,\xi_i=d}(R_i\psi_d) + \sum_{i\,|\,\xi_i=d}(\alpha + \mathbf{x}_i^\top\boldsymbol{\beta})^2 + 2\sum_{i\,|\,\xi_i=d}\left[(\alpha + \mathbf{x}_i^\top\boldsymbol{\beta})\psi_d\right] + \sum_{i\,|\,\xi_i=d}\psi_d^2\right]\right\} \\ &\quad \times \exp\left[-\frac{1}{2\omega^2}\left(\psi_d^2\sum_{\ell=1}^{33}w_{d\ell} - 2\psi_d\sum_{\ell=1}^{33}(w_{d\ell}\psi_\ell)\right)\right] \end{aligned}$$

$$\propto \exp\left\{-\frac{1}{2\sigma^2}\left[-2\psi_d \sum_{i\,|\,\xi_i=d} R_i + 2\psi_d \sum_{i\,|\,\xi_i=d} (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta}) + n_d \psi_d^2\right]\right\}$$
$$\times \exp\left[-\frac{1}{2\omega^2}\left(m_d \psi_d^2 - 2\psi_d \sum_{\ell=1}^{33} (w_{d\ell}\psi_\ell)\right)\right]$$
$$= \exp\left[-\frac{1}{2}\left(-\frac{2\psi_d}{\sigma^2} \sum_{i\,|\,\xi_i=d} \Big[R_i - (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta})\Big] + \frac{n_d\psi_d^2}{\sigma^2} + \frac{m_d\psi_d^2}{\omega^2} - \frac{2\psi_d}{\omega^2}\sum_{\ell=1}^{33}(w_{d\ell}\psi_\ell)\right)\right]$$
$$= \exp\left\{-\frac{1}{2}\left[\left(\frac{n_d}{\sigma^2} + \frac{m_d}{\omega^2}\right)\psi_d^2 - 2\left(\frac{1}{\sigma^2}\sum_{i\,|\,\xi_i=d}\Big[R_i - (\alpha + \mathbf{x}_i^\top \boldsymbol{\beta})\Big] + \frac{1}{\omega^2}\sum_{\ell\sim d}\psi_\ell\right)\psi_d\right]\right\}$$
$$= \exp\left[-\frac{1}{2}\left(\frac{1}{v}\psi_d^2 - 2\frac{m}{v}\psi_d\right)\right], \qquad \psi_d \in \mathbb{R}, \quad \psi_d \in \boldsymbol{\psi}, \quad \psi_\ell \in \boldsymbol{\psi}_{-d}, \quad d = 1, \ldots, 33$$

lo cual corresponde al *kernel* de la pdf de la distribución normal con media m y varianza v, donde m y v son dados en (C.6). □

D. Tratamiento de los datos

La base de datos utilizada en este proyecto corresponde a una compilación de Muñoz Chamorro (2024) con índices, conteos y clasificaciones de elementos involucrados en el estudio del riesgo de LAFT por cada uno de los 1122 municipios del país. El Marco Geoestadístico Nacional (MGN) registra 1123 municipios al incluir a Mapiripana, Guainía, pero, en realidad, es un corregimiento de Barrancominas y no aparece dentro de la base de datos de Muñoz Chamorro. La autora propone una metodología para asignar niveles de riesgo a partir de la información recogida en dicha base de datos. Ésta contiene 55 variables, con reportes para el total de los municipios colombianos (no hubo presencia de datos faltantes), organizadas en ocho grupos temáticos:

(I) *Contexto estructural*
(II) *Contexto político*
(III) *Contrabando*
(IV) *Sectores susceptibles a lavado de activos*
(V) *Terrorismo*
(VI) *Conflicto*
(VII) *Criminalidad*
(VIII) *Narcotráfico*

Las variables de los primeros cuatro grupos temáticos fueron consideradas en el presente trabajo como covariables estructurales, orientadas a explicar por qué algunos municipios presentan mayor o menor nivel de riesgo; y las de los últimos cuatro fueron consideradas como indicadores observados del riesgo de LAFT.

Se resumió la información recolectada por Muñoz Chamorro (2024) en ocho puntajes temáticos, uno por cada bloque definido, siendo $y_{i,1}, y_{i,2}, y_{i,3}$ y $y_{i,4}$ los indicadores que resumen los últimos cuatro bloques temáticos respectivamente, y $x_{i,1}, x_{i,2}, x_{i,3}$ y $x_{i,4}$ los de los primeros, donde $i = 1, \ldots, n := 1122$. Para obtener tales cantidades, fue necesario transformar adecuada y cuidadosamente ciertas variables de la base de datos original, con el fin de reducir asimetrías y hacer comparables las escalas dentro de cada bloque. Cada indicador se construyó como la media aritmética por municipio de las variables transformadas.

Variable	Tipo	Descripción	Transformación
Población	De razón	Proyecciones poblacionales para el año 2023 (DANE).	$-\ln(1+x^*_{i,1})$ estandarizados
IPM	De razón	Índice de pobreza multidimensional en porcentaje (DANE).	$x^*_{i,2}$ estandarizados
IDF	De razón	Índice de desempeño fiscal en una escala de 0 a 100 (DNP).	$-x^*_{i,3}$ estandarizados
Educación	De razón	Cobertura neta en educación en porcentaje, donde puede suceder que un porcentaje supere el 100 % (MEN).	$-x^*_{i,4}$ estandarizados
Acueducto	De razón	Cobertura de acueducto en porcentaje (DANE).	$-x^*_{i,5}$ estandarizados
Alcantarillado	De razón	Cobertura de alcantarillado en porcentaje (DANE).	$-x^*_{i,6}$ estandarizados
Energía	De razón	Proporción de cobertura de energía eléctrica (DANE).	$-x^*_{i,7}$
Gas	De razón	Cobertura de gas natural en porcentaje (DANE).	$-x^*_{i,8}$ estandarizados
Internet	De razón	Cobertura de internet en porcentaje (DANE).	$-x^*_{i,9}$ estandarizados
Analfabetismo	De razón	Tasa de analfabetismo en porcentaje (DANE).	$x^*_{i,10}$ estandarizados
Pob_Rural	De razón	Porcentaje de población rural (DANE).	$x^*_{i,11}$ estandarizados
Bancos	De razón	Número de oficinas y corresponsales bancarios (BO).	$-\ln(1+x^*_{i,12})$ estandarizados

TABLA 13. Descripción de las variables involucradas en el bloque temático de *Contexto estructural*, con las cuales se calculó la covariable estructural $x_{i,1}$ como el promedio de los $x^*_{i,j}$ por cada municipio, donde $i = 1, \ldots, 1122$ y $j = 1, \ldots, 12$.

En particular, para los indicadores observados, se buscó que valores altos mostraran un mayor nivel de incidencia del problema (terrorismo, conflicto, criminalidad o narcotráfico), y valores bajos lo contrario. Además, se evidenció en los datos recogidos para estos últimos cuatro bloques alta presencia de ceros (e.g., número de actos terroristas, índice de incidencia del conflicto, reclutamientos ilegales, entre otros), con lo cual hubo municipios donde el índice final dio un valor mínimo, en algunos casos, repetido por varias observaciones. Esto nos llevó a los autores a considerar una escala más interpretable para estos puntajes: restando a todos los valores este valor mínimo, todos estos se desplazaron hacia el intervalo $[0, \infty)$, de modo que el valor 0 captura realmente la noción de 'ausencia de...', conservando el orden y las proporciones originales. Al graficar los respectivos histogramas, encontramos evidencia de sesgo positivo (el indicador observado se extendía en algunos municipios a valores considerablemente alejados de la región de alta densidad), de manera que, para preservar esta esencia, no aplicamos ninguna normalización o transformación adicional, sino que vimos apropiado modelar los indicadores observados con una distribución sesgada positivamente; escogimos la distribución Gamma. No obstante, ésta tiene soporte positivo y no logra capturar los ceros. Pensamos en aplicar una leve perturbación aleatoria a los ceros para que

entraran dentro de $(0, \infty)$, mas consideramos finalmente que resulta congruente con la naturaleza modelar la ausencia absoluta de problemáticas asociadas al LAFT. Por ello, elegimos la distribución Gamma cero-inflada, la cual describimos con más detalle en §§3.1. Los histogramas de estos cuatro puntajes temáticos finales pueden verse en la Figura 5 de §§2.2.

La descripción de cada una de las 55 variables empleadas por Muñoz Chamorro (2024), así como las transformaciones aplicadas en el presente trabajo para cada una de éstas con el objetivo de obtener las 8 medidas resumen, se sintetizan en las Tablas 13-20, para las cuales mantuvimos los nombres originales de las variables y sus respectivas descripciones reportadas por Muñoz Chamorro (2024, pp. 29-35).

Variable	Tipo	Descripción	Transformación
Presidencia	Binaria	Inclinación política del candidato presidencial ganador en las votaciones del 2022 ('Izquierda' o 'Derecha') (MOE).	$\begin{cases} 0 & \text{si } x^*_{i,1}\texttt{=='DERECHA'} \\ 1 & \text{si } x^*_{i,1}\texttt{=='IZQUIERDA'} \end{cases}$
Zona franca	Binaria	Presencia de al menos una zona franca ('Sí' o 'No').	$\begin{cases} 0 & \text{si } x^*_{i,2}\texttt{=='SI'} \\ 1 & \text{si } x^*_{i,2}\texttt{=='NO'} \end{cases}$
Riesgo electoral	Ordinal	Nivel de riesgo electoral ('Bajo', 'Medio', 'Alto' o 'Extremo') (MOE).	$\begin{cases} 0 & \text{si } x^*_{i,3}\texttt{=='Bajo'} \\ 1 & \text{si } x^*_{i,3}\texttt{=='Medio'} \\ 2 & \text{si } x^*_{i,3}\texttt{=='Alto'} \\ 3 & \text{si } x^*_{i,3}\texttt{=='Extremo'} \end{cases}$

TABLA 14. Descripción de las variables involucradas en el bloque temático de *Contexto político*, con las cuales se calculó la covariable estructural $x_{i,2}$ como el promedio de los $x^*_{i,j}$ por cada municipio, donde $i = 1, \ldots, 1122$ y $j = 1, 2, 3$.

Variable	Tipo	Descripción	Transformación
Frontera	Binaria	Indica si el municipio colinda con territorio extranjero ('Sí' o 'No').	$\begin{cases} 0 & \text{si } x^*_{i,1}\texttt{=='NO'} \\ 1 & \text{si } x^*_{i,1}\texttt{=='SI'} \end{cases}$
Puerto marítimo	Binaria	Presencia de al menos un puerto marítimo ('Sí' o 'No').	$\begin{cases} 0 & \text{si } x^*_{i,2}\texttt{=='NO'} \\ 1 & \text{si } x^*_{i,2}\texttt{=='SI'} \end{cases}$
Aeropuerto	Binaria	Presencia de al menos un aeropuerto ('Sí' o 'No').	$\begin{cases} 0 & \text{si } x^*_{i,3}\texttt{=='NO'} \\ 1 & \text{si } x^*_{i,3}\texttt{=='SI'} \end{cases}$
Puerto fluvial	Binaria	Presencia de al menos un puerto fluvial ('Sí' o 'No').	$\begin{cases} 0 & \text{si } x^*_{i,4}\texttt{=='NO'} \\ 1 & \text{si } x^*_{i,4}\texttt{=='SI'} \end{cases}$

TABLA 15. Descripción de las variables involucradas en el bloque temático de *Contrabando*, con las cuales se calculó la covariable estructural $x_{i,3}$ como el promedio de los $x^*_{i,j}$ por cada municipio, donde $i = 1, \ldots, 1122$ y $j = 1, \ldots, 4$.

De esta manera, $x_{i,1}$, $x_{i,2}$, $x_{i,3}$ y $x_{i,4}$ resultan de las medias aritméticas por cada municipio de las respectivas variables transformadas según las Tablas 13-16. Lo propio para $y_{i,1}$, $y_{i,2}$, $y_{i,3}$ y $y_{i,4}$ según las Tablas 17-20 respectivamente, y considerando la traslación discutida previamente para obtener indicadores en $[0, \infty)$.

Variable	Tipo	Descripción	Transformación
Act_Prim	De razón	Valor agregado en miles de millones de pesos de actividades primarias (agricultura, ganadería, silvicultura y pesca, explotación de minas y canteras) con datos del 2022 (DANE).	$\ln(1+x^*_{i,1})$ estandarizados
Títulos_Min	De razón	Número de títulos mineros otorgados por la ANM al municipio, actualizados hasta el 2023.	$\ln(1+x^*_{i,2})$ estandarizados

TABLA 16. Descripción de las variables involucradas en el bloque temático de *Sectores susceptibles a lavado de activos*, con las cuales se calculó la covariable estructural $x_{i,4}$ como el promedio de los $x^*_{i,j}$ por cada municipio, donde $i = 1, \ldots, 1122$ y $j = 1, 2$.

Variable	Tipo	Descripción	Transformación
Victimización	De razón	Índice de riesgo de victimización (0 es menor riesgo, 1 es mayor riesgo).	$y^*_{i,1}$
Act_Terro	De razón	Número de actos terroristas registrados 2023.	$\ln(1+y^*_{i,2})$ estandarizados
Terrorismo	De razón	Número de actos terroristas registrados por la PN en 2023.	$\ln(1+y^*_{i,3})$ estandarizados

TABLA 17. Descripción de las variables involucradas en el bloque temático de *Terrorismo*, con las cuales se calculó el indicador observado de riesgo $y_{i,1}$ como el promedio de los $y^*_{i,j}$ por cada municipio, donde $i = 1, \ldots, 1122$ y $j = 1, 2, 3$.

Así, la base de datos que empleamos para los procedimientos del presente trabajo quedó compuesta por 1122 observaciones y 8 variables, de las cuales cuatro son covariables estructurales y cuatro son indicadores observados de fenómenos asociados al riesgo municipal de LAFT. Para ver un análisis descriptivo detallado, véase §2.

Variable	Tipo	Descripción	Transformación
Minas_Inter	De razón	Número de unidades productoras mineras intervenidas por la Fuerza Pública por explotación ilícita en 2023 (MDN).	$\ln(1+y^*_{i,1})$ estandarizados
Minas_Anti	De razón	Número de eventos de minas antipersona registrados del 2002 al 2021 (DAICMA).	$\ln(1+y^*_{i,2})$ estandarizados
IICA	De razón	Índice de incidencia del conflicto armado para el año 2021 (0 es nula incidencia, 1 es la mayor incidencia posible) (DNP).	$y^*_{i,3}$
Reincorporados	De razón	Número de personas en proceso de reincorporación para el año 2022 (ART).	$\ln(1+y^*_{i,4})$ estandarizados
Resguardos	De razón	Número de resguardos indígenas en el territorio para el año 2022 (DNP).	$\ln(1+y^*_{i,5})$ estandarizados
Desaparecidos	De razón	Número de personas registradas como desaparecidas hasta el año 2023 (INMLCF).	$\ln(1+y^*_{i,6})$ estandarizados

TABLA 18. Descripción de las variables involucradas en el bloque temático de *Conflicto*, con las cuales se calculó el indicador observado de riesgo $y_{i,2}$ como el promedio de los $y^*_{i,j}$ por cada municipio, donde $i = 1, \ldots, 1122$ y $j = 1, \ldots, 6$.

Variable	Tipo	Descripción	Transformación
Delitos	De razón	Número de noticias de prensa por delitos relacionados con el lavado de activos en 2023.	$\ln(1+y^*_{i,1})$ estandarizados
Tráfico de estupefacientes	De razón		$\ln(1+y^*_{i,2})$ estandarizados
Extorsión	De razón		$\ln(1+y^*_{i,3})$ estandarizados
Tráfico de armas	De razón		$\ln(1+y^*_{i,4})$ estandarizados
Homicidio culposo	De razón		$\ln(1+y^*_{i,5})$ estandarizados
Homicidio doloso	De razón	Número de crímenes de esta índole registrados por el SPOA desde 2010 hasta 2023 (FGN).	$\ln(1+y^*_{i,6})$ estandarizados
Hurto	De razón		$\ln(1+y^*_{i,7})$ estandarizados
Reclutamiento	De razón		$\ln(1+y^*_{i,8})$ estandarizados
Secuestro extorsivo	De razón		$\ln(1+y^*_{i,9})$ estandarizados
Trata de personas	De razón		$\ln(1+y^*_{i,10})$ estandarizados
Trata de menores	De razón		$\ln(1+y^*_{i,11})$ estandarizados
Administración pública	De razón	Número de delitos contra la Administración pública registrados por el SPOA desde 2010 hasta 2023 (FGN).	$\ln(1+y^*_{i,12})$ estandarizados
Concierto para delinquir	De razón		$\ln(1+y^*_{i,13})$ estandarizados
Corrupción administrativa	De razón		$\ln(1+y^*_{i,14})$ estandarizados
Corrupción electoral	De razón		$\ln(1+y^*_{i,15})$ estandarizados
Corrupción judicial	De razón	Número de crímenes de esta índole registrados por el SPOA desde 2010 hasta 2023 (FGN).	$\ln(1+y^*_{i,16})$ estandarizados
Corrupción privada	De razón		$\ln(1+y^*_{i,17})$ estandarizados
Delitos ambientales	De razón		$\ln(1+y^*_{i,18})$ estandarizados
Desaparición forzosa	De razón		$\ln(1+y^*_{i,19})$ estandarizados
Desplazamiento	De razón		$\ln(1+y^*_{i,20})$ estandarizados
Homi_Inten	De razón	Número de homicidios intencionados registrados por la PN en 2023.	$\ln(1+y^*_{i,21})$ estandarizados

TABLA 19. Descripción de las variables involucradas en el bloque temático de *Criminalidad*, con las cuales se calculó el indicador observado de riesgo $y_{i,3}$ como el promedio de los $y^*_{i,j}$ por cada municipio, donde $i = 1, \ldots, 1122$ y $j = 1, \ldots, 21$.

Variable	Tipo	Descripción	Transformación
Hec_Coca	De razón	Número de hectáreas cultivadas de coca en 2022 (ODC).	$\ln(1+y^*_{i,1})$ estandarizados
Hec_Errad_Coca	De razón	Número de hectáreas erradicadas de cultivo de coca en 2022 (ODC).	$\ln(1+y^*_{i,2})$ estandarizados
Kg_Inc_Droga	De razón	Kilogramos de droga incautados (entran bazuco, clorhidrato de cocaína, heroína, hoja de coca, marihuana prensada y base de coca) en 2022 (ODC).	$\ln(1+y^*_{i,3})$ estandarizados
Laboratorios	De razón	Unidades de laboratorios desmantelados en 2022 (ODC).	$\ln(1+y^*_{i,4})$ estandarizados

TABLA 20. Descripción de las variables involucradas en el bloque temático de *Narcotráfico*, con las cuales se calculó el indicador observado de riesgo $y_{i,4}$ como el promedio de los $y^*_{i,j}$ por cada municipio, donde $i = 1, \ldots, 1122$ y $j = 1, \ldots, 4$.

Referencias

Besag, J.E. (1972). 'Nearest-Neighbour Systems and the Auto-Logistic Model for Binary Data'. *J. R. Stat. Soc. Ser. B Methodol.*, **34** (1), 75–83. http://www.jstor.org/stable/2985051

Besag, J.E., York, J. y Mollié, A. (1991). 'Bayesian image restoration, with two applications in spatial statistics'. *AISM*, **43** (1), 1-20. https://doi.org/10.1007/BF00116466

Departamento Administrativo Nacional de Estadística - DANE. (s. f.). *Tabla de municipios*. Recuperado de https://www.dane.gov.co/files/censo2005/provincias/subregiones.pdf

Financial Action Task Force. (2012). *International standards on combating money laundering and the financing of terrorism & proliferation: The FATF Recommendations*. https://www.fatf-gafi.org/content/dam/fatf-gafi/recommendations/fatf-recommendations-2012.pdf

Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A. y Rubin, D. B. (2013). *Bayesian Data Analysis* (3a ed.). Chapman and Hall.

Gelman, A., Hwang, J. y Vehtari, A. (2014). 'Understanding predictive information criteria for Bayesian models'. *Stat Comput*, **24**, 997–1016. https://doi.org/10.1007/s11222-013-9416-2

Levi, M. y Reuter, P. (2006). 'Money laundering'. *Crime and Justice*, **34** (1), 289–375. https://orca.cardiff.ac.uk/id/eprint/3154/1/Levi%202006.pdf

Ministerio de Justicia y del Derecho. (s.f.). *Delitos relacionados con lavado de activos*. https://www.minjusticia.gov.co/programas-co/ODC/Paginas/delitos-relacionados-lavado-activos.aspx

Muñoz Chamorro, D.V. (2024). 'Desarrollo de modelo de aprendizaje estadístico para la identificación del riesgo de lavado de activos y financiación del terrorismo', *M.Sc. Tesis*, Universidad Nacional de Colombia. Recuperado de https://repositorio.unal.edu.co/handle/unal/87731

Schott, P. A. (2006). *Reference guide to anti-money laundering and combating the financing of terrorism*, 2a ed. (The World Bank / International Monetary Fund). https://openknowledge.worldbank.org/server/api/core/bitstreams/b135c8cf-9533-5612-bf7a-1ee82859525c/content

Sosa Martínez, J. C. y Aristizábal, J. P. (2022). 'Some Developments in Bayesian Hierarchical Linear Regression Modeling'. *CoJS*, **45** (2), 231-55.

Sosa Martínez, J. C. (Comp.) (2025). 'Regresión con errores correlacionados' en [*2016364*] *Estadística Bayesiana*. Universidad Nacional de Colombia, Bogotá, D. C. Recuperado de https://rpubs.com/jstats1702/1328550

Sosa Martínez, J. C. (Comp.) (2026a). 'Estadística Bayesiana - Muestreador de Gibbs' en [*2016364*] *Estadística Bayesiana*. Universidad Nacional de Colombia, Bogotá, D. C. Recuperado de https://rpubs.com/jstats1702/1291098

Sosa Martínez, J. C. (Comp.) (2026b). 'Criterios de información' en [*2016364*] *Estadística Bayesiana*. Universidad Nacional de Colombia, Bogotá, D. C. Recuperado de https://rpubs.com/jstats1702/1317978

Superintendencia Financiera de Colombia. (2022). *Concepto 20221867 29-001* del 9 de diciembre de 2022. Sistema de Administración de Riesgo de Lavado de Activos y Financiación del Terrorismo-SARLAFT, clientes de mayor riesgo, acceso al sistema financiero.

Superintendencia Financiera de Colombia. (2012, octubre 1). *Sistema de administración de riesgo de lavado de activos, financiación del terrorismo y financiación de la proliferación de armas de destrucción masiva*. https://www.superfinanciera.gov.co/publicaciones/10086577/indu

strias-supervisadassistema-de-administracion-de-riesgo-de-lavado-de-activos-y-financiacion-del-terrorismo-10086577/

Unidad de Información y Análisis Financiero. (2024). *Lavado de activos y financiación del terrorismo*. https://www.uiaf.gov.co/sistema-nacional-ala-cft/lavado-de-activos-y-financiacion-del-terrorismo